

复旦大学 · 中国大学MOOC · 付伟教授团队

人工智能 药物设计

学习笔记 · 科研上手详细版

公式推导 · 模型方程 · 算法步骤 · 工具实操 · 数据库用法
靶标挖掘 · AlphaFold · 分子对接 · 生成模型 · 逆合成 · ADMET · 企业实战

◆ 读完能动手 ◆ 70 页 · 12 章 ◆ 理论+代码+流程

说明：本笔记以课程公开大纲为主线，结合配套教材《药物设计学》《计算机辅助药物设计导论》与领域公开资料，将每一节展开到「公式 + 步骤 + 工具」的科研上手粒度。视频课件原文以平台为准；关键论文与工具网址见附录。

整理于 2026 年 9 月

第 0 章 · 如何开始学习 AIDD

0.1 课程介绍

0.2 课程大纲

0.3 参考资料

0.4 学习方法


先修自查

环境搭建

科研路线

① 课程定位：三门学科的交叉点

药学回答「什么是好药、为什么有效」；计算机回答「怎么从数据里学出规律」；化学/生物信息回答「分子与生命系统的语言是什么」。AIDD 的每一个具体任务，都是把一个药学问题翻译成一个机器可学习的问题：



② 三遍学习法（把课变成自己的手艺）

- ★ 第一遍·看懂主线：只抓「这一章解决研发哪一环、输入输出是什么」，跟本笔记每章开头的「知识地图」走，不抠数学。
- ★ 第二遍·复现细节：对着每章「上机」小节亲手跑：RDKit 算描述符 → 查 PDB/AFDB → Vina 对接一次 → 训练一个小 QSAR 模型 → 跑一次在线 ADMET。代码跑通才算学会。
- ★ 第三遍·项目串联：做一个贯穿式小项目（附录 P70 有完整流程）：选靶 → 下数据 → 建模 → 对接验证 → 写报告。科研能力 = 知识 × 工作流。

③ 12 章功能地图（学习时挂在墙上）

篇章	章节	解决什么问题 / 产出什么技能
基础篇 第0-3章	第0章 入门指引	搭环境、明先修、定路线
	第1章 导论 / 第2章 应用	懂行业语言：研发流程、痛点、AI 切入点
	第3章 AI 基础	CNN/RNN/Transformer/GNN 的方程级理解
方法篇 第4-6章	第4章 靶标挖掘	组学+网络+知识图谱 → 靶点候选表
	第5章 结构预测	AlphaFold2/3 原理与使用、口袋分析
	第6章 药物设计	对接/打分/药效团/QSAR/表征全家桶
进阶篇 第7-9章	第7章 递送系统	处方逆向设计、LNP 案例
	第8章 生成与逆合成	VAE/GAN/RL/扩散方程级 + 逆合成规划
	第9章 性质预测	亲和力三路线 + ADMET 建模与工具
实战篇 第10-11章	第10-11章 企业案例	英矽智能两大新药完整复盘
	思政 + 附录	速记卡、工具网址、文献清单、项目流程

④ 先修清单（缺哪补哪，别等「准备好」）

板块	必须会（入门线）	进阶会（科研线）
数学	向量/矩阵乘法；均值方差；导数=斜率、链式法则；概率=频率观点	矩阵求导、似然与贝叶斯、熵与 KL 散度、特征值
编程	Python：变量/列表/字典/循环/函数；会用 pip/conda 装包	NumPy 向量化、Pandas 表处理、Matplotlib 画图、Git 版本管理
药学	认官能团与结构式；知道激动剂/拮抗剂、IC ₅₀ 越小越强	SAR 思想、药代基本参数、靶点家族（GPCR/激酶…）
化学信息	会写乙醇 SMILES「CCO」；知道分子可以存成文件	RDKit 常用 API、分子图概念、构象与能量面

⑤ 四个「最低限度」概念（第 3 章之前必须懂）

1. 损失函数：衡量模型预测与真值差距的一个数，如均方误差 $MSE = (1/n)\sum(y_i - \hat{y}_i)^2$ 。训练 = 把这个数变小。
2. 梯度下降：参数沿损失下降最快的方向挪一小步： $\theta \leftarrow \theta - \eta \cdot \partial L / \partial \theta$ (η =学习率)。类比下山：看坡度、迈小步。
3. 过拟合：训练集分高、测试集分差 = 死记硬背没学规律。药学好比：只认识训练的那些骨架，换个骨架就抓瞎。
4. 数据划分：训练集学、验证集调参、测试集只考一次。药学特殊处：必须「骨架划分」（第 3 章详解），否则等于考前看了考卷。

教材三件套（按顺序读）

- 《药物设计学》付伟主编，高等教育出版社 2023（第 4 版，国家级规划教材）——主干，CADD 部分与本课第 6 章一一对应。
- 《计算机辅助药物设计导论》付伟、叶德泳，化工出版社 2017——对接、QSAR、药效团的操作级细节。
- 《人工智能药学》李洪林、付伟，人民卫生出版社——AI 方法与药学场景结合的最新视野。

💡 心态：AIDD 科研者的稀缺能力不是「会调包」，而是「能把药学问题翻译成学习问题，再把模型输出翻译回实验」。两个翻译能力都要练。

⑥ 一小时搭好科研环境

1) 装 Miniconda 后建独立环境 (避免污染系统 Python)

```
conda create -n aidd python=3.10 -y && conda activate aidd
```

2) 化学信息学三件套 + 建模框架

```
pip install rdkit scikit-learn pandas matplotlib
```

```
pip install torch torch_geometric # PyTorch + PyG (图神经网络)
```

```
pip install deepchem # 可选: 分子建模工具箱 (自带数据集)
```

- 无 GPU 也能学：本课实践 CPU 足够；要训练生成模型时再租云 GPU。
- 零代码替代路径：网页工具先行——AlphaFold Server、SwissADME、ADMETlab、Pharmit (附录 P69 有完整网址表)。

⑦ 第一个 30 分钟上机：验证环境 (跟着敲)

```
from rdkit import Chem
```

```
from rdkit.Chem import Descriptors, rdMolDescriptors, Draw
```

```
m = Chem.MolFromSmiles('CC(=O)Oc1ccccc1C(=O)O') # 阿司匹林
```

```
print(Descriptors.MolWt(m)) # 分子量 180.16
```

```
print(rdMolDescriptors.CalcTPSA(m)) # 拓扑极性表面积 63.6
```

```
Draw.MolToImage(m).save('aspirin.png') # 画出结构式
```

跑通 = 你的机器已经能「读懂分子」。后面每一章的上机都建立在这条命令之上。

⑧ 科研入门路线 (学生 → 独立做课题)

阶段	做什么	产出 / 检验标准
1 跟复现	复现一个 QSAR 小项目：ChEMBL 下载某靶点活性数据 → ECFP 指纹 → RF 建模 → scaffold split 评估	能独立写出 AUC/ RMSE，并解释每个选择
2 换对象	把同一套流程换到自己感兴趣的靶点/端点 (如 hERG)	一张规范的「数据-模型-指标」结果表
3 加深度	换 GNN / 预训练模型对比基线；做误差分析 (哪些骨架预测差)	知道模型边界，形成改进假设
4 进闭环	生成/对接产出的虚拟分子 → 逆合成检查 → (有条件) 送合成与测试	完整「干-湿」闭环经验

📖 文献习惯：每周精读 1 篇 (方法部分逐式核对) + 泛读 5 篇摘要；读过的论文登记「问题-数据-方法-指标-可借鉴点」五行表——半年后这张表就是你的选题库。

目录·上

第0章 如何开始学习 AIDD	P4	GNN: 分子图·MPNN 三步方程·	P19
课程定位·三遍学习法·12章功能地	P4	四变体	
图		GNN 药学任务·PyG 上机·四模型	P20
先修自查清单·四个最低限度概念	P5	对比表	
一小时搭环境·30分钟上机·科研路	P6	第4章 AI 挖掘潜在药物靶标	P21
线		靶标定义·家族与代表药·好靶四要	P21
第1章 AI 药物设计学导论	P7	素	
研发八大阶段逐段拆解	P7	RNA-seq/GWAS/CRISPR/单细胞	P22
双十定律·Eroom 定律·漏斗数字	P8	PPI 网络·中心性·六步挖掘流程·	P23
AI 三起两落编年史	P9	RWR	
四大里程碑案例(细节版)	P10	知识图谱 TransE·NLP·CMap 老	P24
AIDD vs CADD 全维对比·三处融合	P11	药新用	
接口		多组学+ML 总装·从靶点到项目三关·	P25
第2章 AI 在药物设计中的应用	P12	数据库详表·找靶一天速通实操	P26
方法全家福(按输入形态选模型)	P12	第5章 AI 预测靶蛋白结构	P27
十环节应用地图(做法+工具+代表) ..	P13	结构四层次·X-ray/NMR/Cryo-EM	P27
优势局限辩证·数据挑战专题	P14	对比	
第3章 人工智能基础	P15	同源模建五步·threading·	P28
损失函数·梯度下降·偏差方差	P15	CASP/GDT_TS	
数据划分与泄漏·分类回归指标	P16	AF2 三段式架构·双表示·三角更新·	P29
CNN: 卷积运算·输出公式·架构演	P17	IPA 结构模块·pLDDT/PAE 使用·	P30
进		四不能	
RNN/LSTM 门机制·Transformer	P18	AF3 三升级·2024 诺奖·	P31
注意力		RFdiffusion/MPNN	
		拿结构四条路·质量检查·fpocket	P32
		上机	

第6章 AI 辅助药物结构设计	P33	扩散前向/反向方程 ·	P51
锁钥→诱导契合·结合能账本	P33	DiffSBDD/TargetDiff	
米氏方程·Cheng-Prusoff·配体效率 LE	P34	逆合成术语·切断五法则	P52
口袋识别三法·对接盒子定义	P35	模板 vs 无模板对比·MCTS/A* 多步搜索	P53
采样五策略·打分函数四流派·SPDS	P36	第9章 AI 预测药物性质	P54
Vina 实操七步·防坑清单	P37	SPR/ITC· ΔG 手算·四大数据	P54
VS 五级漏斗·共识打分·FBDD	P38	结构三路线(对接/MMGBSA/FEP 热力学循环)	P55
药效团特征/构建/应用	P39	DeepDTA 双塔拆解·泄漏专题	P56
QSAR: Hansch/CoMFA·六步 SOP · OECD	P40	Ro5/Veber 理化依据·PK 公式卡	P57
SMILES 语法六规则·指纹算法解剖 ...	P41	ADMET 五维端点地图·hERG/Ames/CYP	P58
3D/USR 表征·RDKit 实操·总装图 ...	P42	建模四板斧·性质体检上机	P59
第7章 AI 药物递送系统设计	P43	第10章 企业案例 I·英矽智能	P60
载体类型速查·高维试错困境	P43	Pharma.AI 三引擎·企业版 AlphaFold	P60
处方双引擎·脂质筛选三铁律·LNP 链条	P44	INS018_055 逐段对账·证明/未证明	P61
摄取/蛋白冠/BBB/分布四问建模	P45	第11章 企业案例 II·靶点发现	P62
第8章 AI 在分子生成和合成中的应用	P46	ISM5411 复盘·方法论飞轮	P62
化学空间 10^{60} ·VUN/FCD 指标·管线坐标	P46	行业图谱·合作模式·中国力量	P63
SMILES 陷阱·SELFIES 原理·图/3D 表征	P47	贯穿式课题 8 步 SOP·结课自测	P64
自回归分解·预训练-微调·MolGPT ...	P48	思政+附录	P65
VAE: ELBO 推导·潜空间优化三玩法	P49	公式速记卡(12 条)	P65
GAN 极小极大·REINFORCE·REINVENT	P50	规则清单·缩写词典	P66
		数据库与工具完整索引(含网址)	P67
		必读文献清单·结语	P68

笔记符号约定

重点 必考核心
 工具 上机要用
 案例 企业实战
 公式 手算保命
 黄底 = 关键词必记
蓝底 = 方法/模型名
红字 = 易错点
 = 老师提醒/经验之谈
 代码块 = 可直接跑的命令

第 1 章 · AI 药物设计学导论

- 1.1 研发流程与痛点
- 1.2 AI 发展史
- 1.3 里程碑案例
- 1.4 AIDD vs CADD
- 1.5 总结

① 新药研发八大阶段（逐段拆开记）

阶段	耗时	具体做什么 / 关键产出	失败主因 & AI 切入点
1 靶点发现与验证	1-2 年	从疾病机制中找到「因果且可干预」的生物分子：组学差异、遗传证据（GWAS）、CRISPR 功能筛选；产出经验证的靶点	假靶点（关联≠因果）→ 第4章 多源证据整合排序
2 苗头化合物发现 hit	1-2 年	HTS 高通量筛选（10 ⁵ -10 ⁶ 化合物）、虚拟筛选、片段筛选、文献挖掘；产出 μM 级活性 hit	假阳性/漏筛 → 第6章 AI 打分虚拟筛选
3 先导化合物优化 lead	1-2 年	SAR 循环：合成→测活性→改结构→再合成，几十至上百轮；优化活性、选择性、ADMET；产出 nM 级先导	多目标打架 → 第6/8/9章 QSAR+生成+多目标优化
4 候选药物 PCC	数月	综合评估确定临床前候选（结构锁定，进入开发）	决策靠经验 → AI 综合打分辅助
5 临床前	约 1 年	ADMET 系统评价、药效学（动物模型）、毒理（安全药理/遗传毒/重复给药）、制剂开发	毒性暴露晚 → 第9章 早筛 ADMET
6 临床 I 期	1 年	20-100 健康志愿者，安全性与耐受性、药代（PK）	疗效不足+安全性问题占临床失败 ~2/3 → 患者分层、临床结果预测
7 临床 II 期	1-2 年	100-500 患者，初步疗效（II a 探索剂量、II b 确证概念）——成功率最低 ~30%	
8 临床 III 期+NDA	2-4 年	1000-5000 人确证疗效与罕见不良事件；申报上市（NDA/BLA）、IV 期监测	

② 阶段产出行话表（读文献/听报告不再懵）

术语	定义	典型门槛
hit 苗头	初步确认活性与结构的分子	μM 级活性、结构确认（非假阳性）
lead 先导	活性确认 + 有优化空间 + 初步 SAR	nM~亚 μM、结构新颖可专利
candidate 候选（PCC）	结构锁定、全面临床前评价通过	活性/选择性/ADMET/可生产全达标
tool compound 工具药	活性好但成药性差，供机制研究	「能用的探针」，不是药

🔪 考试与科研通用逻辑：AI 的价值按「失败成本」排序——越早淘汰坏分子省得越多。故 AIDD 主战场在研发前端（找靶/设计/成药性），这正是第 4-9 章的布局顺序。经费分布记忆点：临床段占研发总花费一半以上——AI 压缩早期成本后，临床段成为新瓶颈（第 63 页行业分析呼应）。

② 双十定律 (Rule of Ten)

一款新药从立项到上市平均 10 年以上、10 亿美元以上；若计入全部失败项目分摊，每款获批新药的真正研发成本按 2014 年 Tufts 大学研究估计高达 ~26 亿美元。时间分布见上页表格（临床阶段占一半以上）。

③ Eroom 定律 (反摩尔定律, Scannell 2012)

每 10 亿美元研发投入产出的获批新药数
每隔 9 年约减半 (1950s 至今持续成立)

四大原因 (论述题模板): ①「更好的选择」——倾向挑难度更高的靶点 (容易的做完了); ②「后蛋糕时代」——从优化 Me-too 转向全新机制, 回报递减; ③「避错负担」——监管与安全标准提高, 重复审批成本增加; ④「确实倒霉」——科学本身的负结果累积。核心结论: 投入指数增长、产出线性增长 → 效率危机, AI 是当前最强的效率变量。

④ 漏斗数字 (背下来, 写引言直接用)



★ 临床失败原因构成 (大致): 疗效不足 ~40-50%、安全性/毒性 ~30%、商业/策略 ~15%、PK 问题 ~10%。

★ 对应 AI 解法: 疗效 ← 好靶点 (第 4 章) + 强亲和力预测 (第 9 章); 毒性 ← ADMET 早筛 (第 9 章); PK ← DMPK 建模。

⑤ 为什么 AI 恰好在现在爆发? (三要素齐备)

要素	过去	现在
数据	PDB 2 万结构、ChEMBL 未整合	PDB>23 万、AFDB 2 亿+预测结构、ChEMBL ~240 万化合物活性、公共组学爆发 (GEO/SRA)
算力	CPU 时代, 训练神经网络不现实	GPU/TPU 使深度模型数小时可训; 云算力按需租用
算法	浅层模型 + 手工特征	深度学习端到端表征 (2012 AlexNet) → 注意力/Transformer (2017) → 扩散/大模型 (2020s)

⑥ 三起两落编年史（每一行都要能讲出意义）

时间	事件	为什么重要 / 落点
1943	McCulloch-Pitts 神经元数学模型	第一次把「神经活动」写成逻辑运算
1950	图灵《计算机器与智能》图灵测试	定义「机器智能」的可操作判据
1956	达特茅斯会议 (McCarthy 提出 AI 一词)	AI 学科诞生
1957	Rosenblatt 感知机	第一个可学习的神经网络（只能线性分类）
1969	Minsky《Perceptrons》指出单层局限	叠加经费退潮 → 第一次寒冬（1974-80）
1980s	专家系统（知识工程）兴起；1986 BP 反向传播复活多层网络	符号主义巅峰 + 连接主义复苏；后因维护成本再度遇冷 → 第二次寒冬（1987-93）
1997	深蓝击败国际象棋世界冠军卡斯帕罗夫	搜索+评估函数路线的胜利
2006	Hinton 深度信念网络逐层预训练	「深度学习」命名，破除深层难训魔咒
2012	AlexNet 横扫 ImageNet (ReLU+Dropout+GPU)	深度学习实用化元年
2016	AlphaGo 4:1 李世石	深度网络+蒙特卡洛树搜索结合 → 后来逆合成的 MCTS 同源
2017	Transformer (Attention Is All You Need)	此后几乎所有 AIDD 模型的骨架
2020	AlphaFold2 CASP14「解决」蛋白折叠	结构生物学与 SBDD 的分水岭（第 5 章）
2022	ChatGPT / ESM 系列蛋白语言模型	大模型进入生物医药文本与序列
2024	AlphaFold3；诺贝尔化学奖授予 Hassabis、Jumper (AF2) 与 Baker（蛋白设计）	AI for Science 获科学界最高背书

🔪 答题框架：两落的共性 = 期望超出技术现实（算力/数据跟不上 + 问题定义过难）；三起的共性 = 新算法 × 新算力 × 新数据同时到位。用这个框架分析「为什么 AIDD 现在靠谱」。

深度学习时代的「三波浪潮」（药物视角细分）

浪潮	标志	药学对应物
判别式（2012-）	CNN 判别「这是什么」	性质/毒性预测、图像表型筛选
生成式（2016-）	GAN/VAE/扩散「无中生有」	de novo 分子生成、逆合成、蛋白设计
基础模型（2020-）	超大规模自监督预训练+涌现能力	ESM 蛋白语言模型、多模态药物助手、零样本性质预测

判断一个新工具属于哪一波：它输出「标签/数值」（判别）、「新结构」（生成）还是「通用表征/对话能力」（基础模型）——三波能力可叠加（预训练大模型 + RL 目标化 = REINVENT 4 与 ChemCrow 的形态）。

⑦ 四大标志性案例（细节版）

案例	完整故事	方法论意义
DSP-1181 2021 · 日本	Exscientia 与住友制药合作，用 AI 平台设计 5-HT1A 受体超级激动剂治疗强迫症（OCD）：AI 提出「长效、低剂量」的结构方案，临床前周期约 12 个月（传统同类项目平均 ~4.5 年），2021 年 1 月在日本进入 I 期临床	证明「AI 设计的分子」能通过临床前全部关卡，进入人体试验
巴瑞替尼 治新冠 2020 · 英国	BenevolentAI 知识图谱扫描数万篇文献，2020 年 2 月初提出：JAK1/2 抑制剂巴瑞替尼可同时抑制新冠相关的 AP2-associated kinase 1 等炎症信号；随后 ACTT-2 试验证实，2020 年 11 月获 FDA 紧急使用授权（与瑞德西韦联用），2021 年完全获批	知识图谱+文献挖掘做老药新用：从假设提出到临床证据仅数月
INS018_055 Rentosertib 英矽智能	AI 发现靶点 TNIK + AI 设计分子，治疗特发性肺纤维化：18 个月到临床前候选、合成测试 <80 个分子、花费数百万美元级；2023 年进入 II 期（中美双报）；II a 期结果 2025 年登上 Nature Medicine（12 周剂量依赖改善肺功能）；2025 年 6 月启动 III 期（第 10 章全复盘）	全球首个「AI 发现靶点 + AI 设计分子」走到 III 期的药物，端到端范式成立
ISM5411 英矽智能	PandaOmics 发现 PHD 靶点用于炎症性肠病，12 个月提名 PCC，Nature Biotechnology 2024；肠道限制性设计降低系统性副作用（第 11 章全复盘）	证明方法可复制——同一平台跨适应症量产候选

⑧ 案例的公共启示（写综述/申请书的金句）

- ★ AI 已经在「提出假设」（靶点/适应症）与「设计方案」（分子结构）两处证明自己，而不只是「加速计算」。
- ★ 但所有成功案例都有湿实验与临床的闭环——AI 从未单独造出药物，它重构的是「假设→验证」循环的效率。
- ★ 从 DSP-1181（AI 设计分子）到 INS018_055（AI 靶点+分子+临床）：五年内 AI 参与深度持续加深，全流程 AI 药物已到 III 期。

⑨ CADD 与 AIDD 全维对比 (高频考点)

维度	CADD 计算机辅助药物设计	AIDD 人工智能药物设计
哲学	第一性原理: 物理化学规律演绎	数据归纳: 从样本中学习统计规律
核心方法	分子对接、分子动力学 (MD)、自由能计算、药效团、经典 QSAR	深度学习 (CNN/GNN/Transformer)、生成模型 (VAE/GAN/RL/扩散)、知识图谱、大模型
特征工程	人工定义 (描述符、打分项)	端到端自动学习表征
数据需求	小数据可用, 结构先验重要	数据 hungry, 小数据需迁移学习救场
可解释性	高 (能量项、相互作用可拆解)	低 (黑盒; 需注意力/SHAP 补救)
擅长	机理明确的精修: 结合模式、自由能差、动力学	大空间搜索: 虚拟筛选加速、de novo 生成、多目标优化
外推能力	物理规律保证泛化 (换靶仍成立)	受训练分布限制 (适用域外危险)
代表工具	AutoDock Vina、Glide、AMBER/GROMACS、MOE	DeepDTA、REINVENT、RFdiffusion、Chemistry42

⑩ 融合而不是替代 (三处接口)

1. AI 学打分: 对接打分函数不准 → 神经网络打分 (如 GNINA 的 CNN 打分) 学习「正确构象 vs 错误构象」, 超越手工能量项 (第 6 章)。
2. AI 生成 + 物理验证: 生成模型出分子 → 对接/MD/FEP 精修排序 → 只把物理合理者送实验 (第 8 章闭环)。
3. 知识注入: 知识图谱把机理先验喂给模型, 弥补纯数据的解释性短板 (第 4 章)。

第 1 章一页总结

研发慢贵险 (双十 + Eroom + 10% 成功率) → AI 三要素齐备后入场, 已在靶点、设计、老药新用全面落地 (DSP-1181 / 巴瑞替尼 / INS018_055) → AIDD 与 CADD 从并行走向融合: 物理给正确性、数据给效率。科研选题口诀: 用 AI 补你手头最贵的那一步。

第 2 章 · AI 在药物设计中的应用

- 2.1 方法谱系
- 2.2 全链条应用
- 2.3 优势局限
- 2.4 数据挑战
- 2.5 评价指标
- 2.6 机遇

① 机器学习方法全家福（按「输入形态」选模型）

方法族	输入形态	代表算法	药学任务匹配
经典监督学习	定长特征向量 (表格)	线性回归、SVM、随机森林 RF、XGBoost	QSAR、ADMET 端点预测 (千级样本最稳)
无监督学习	任意特征向量	聚类 (K-means/层次)、PCA、t-SNE、UMAP	化合物库分簇去冗余、化学空间可视化
卷积网络 CNN	网格 (图像/格点/定长编码)	ResNet 等; 3D-CNN	高内涵筛选、蛋白口袋格点、DeepDTA 序列分支
循环网络 RNN	序列	LSTM、GRU	SMILES 生成 (第一代)、蛋白序列建模
图神经网络 GNN	图 (分子/PPI/残基网络)	GCN、GAT、GraphSAGE、MPNN、GIN	分子性质、DTA、反应预测 (第 3 章方程级)
Transformer	序列/集合 (注意力无需网格)	BERT/GPT 系、蛋白语言模型 ESM	SMILES 生成、文献挖掘、蛋白表征
生成模型	潜空间/噪声 → 分子	VAE、GAN、RL、扩散模型	de novo 分子设计 (第 8 章方程级)
强化学习 RL	状态-动作-奖励	REINFORCE、PPO	目标导向生成 (奖励=活性+ADMET)
知识图谱	三元组 (头,关系,尾)	TransE、R-GCN、图嵌入	靶点-疾病关联推理、老药新用

🔪 选型心法 (第 6.8 节展开): 样本 <1 万先试 RF/XGBoost; 有结构 (图) 上 GNN; 要「造新分子」上生成模型; 要机理可解释回物理模型。基线先行, 深度在后——没有基线的深度学习论文不可信。

② 按研发环节记应用 (每条: 做什么→怎么做→谁做过)

环节	AI 具体做法	代表工具 / 工作	详see
靶点发现	多组学差异 + PPI 网络挖掘 + 知识图谱推理 + 文献 NLP, 对候选基因「新颖性×成药性×安全性」三维打分	英矽 PandaOmics、Open Targets、DisGeNET	第4章
蛋白结构	从序列直接预测三维结构; 预测蛋白-配体复合物; 反向设计全新蛋白	AlphaFold2/3、RoseTTAFold、RFdiffusion	第5章
虚拟筛选	深度打分函数替代/增强物理打分; 图像化口袋-配体匹配	AtomNet (Atomwise)、GNINA	第6章
de novo 生成	在化学空间中「定向生成」满足多目标约束的分子, 而非被动筛选	ChemVAE、REINVENT、TargetDiff	第8章
SAR/优化	机器学习 QSAR 预测活性指导下一轮合成; 匹配分子对 (MMP) 分析	RF/XGBoost QSAR、DeepChem	第6章
ADMET/毒性	多端点并行预测: CYP 抑制、hERG、Ames、DILI; 早期排雷	admetSAR、ADMETlab、Tox21 基准	第9章
逆合成	单步反应预测 (模板/无模板) + 多步路线搜索	SCROP、Retro*、ASKCOS (MIT)	第8章
递送系统	处方组成→性能建模; 可电离脂质虚拟筛选	LNP-ML 案例 (mRNA 疫苗)	第7章
临床试验	患者分层 (组学+ML)、试验结果预测、真实世界证据挖掘	英矽 InClinico、TriNetX	第10章
老药新用	疾病签名 vs 药物扰动签名反向匹配; 知识图谱链接预测	CMap/clue、BenevolentAI (巴瑞替尼)	第4章
晶型/盐型	晶体结构预测 (CSP) + ML 排序多晶型稳定性, 避免后期晶型翻车	晶泰科技 (XtalPi)、CSP 竞赛体系	第10章
生产与质控	工艺参数优化、批次质量预测、连续制造控制	制药 4.0 (与 PAT 过程分析技术结合)	—

📌 记忆锚点: 上面十二行正好覆盖「靶点→结构→分子→性质→递送→临床→生产」全链条; 每行都能在第4-11章找到方程级展开。

③ 优势 vs 局限 (辩证题满分模板)

真实优势

- 速度: 虚拟筛选从月级到天级; 生成从「筛 10^6 」变「造 10^3 」;
- 成本: INS018_055 早期发现仅数百万美元;
- 空间: 能探索 10^{60} 化学空间中人想不到的区域;
- 整合: 组学+文献+结构异构数据一次吃下;
- 一致: 模型不会疲劳、无主观偏好。

真实局限 (科研中必须面对)

- 数据少且偏: 阴性数据几乎不发表 (发表偏倚);
- 测量噪声: 不同实验室 IC_{50} 可差 10 倍;
- 分布外失效: 新骨架/新靶标上性能骤降;
- 可解释性: 药监与化学家需要理由;
- 验证鸿沟: $in\ silico \neq in\ vitro \neq in\ vivo \neq$ 临床。

④ 数据挑战专题 (AIDD 科研第一课)

问题	表现	对策
数量少	单靶点高质量数据常仅几百-几千条	迁移学习 (大库预训练)、多任务学习 (端点共享)、数据增强
质量差	实验条件不一致、单位混乱 ($nM/\mu g/mL$)、重复测量冲突	数据清洗 (单位统一、活性阈值化)、可信来源 (ChEMBL curation)
偏倚	只有阳性数据 (活性的才发表); 专利数据集中于热门靶点	混入 DuD-E/DEKOIS 类平衡负样本; 注意适用域
泄漏	随机划分使近同物 (同骨架/同盐形式) 跨训练-测试集, 指标虚高	骨架划分 + 时间划分 (第 3 章详解); 报告两种结果
基准缺失	各论文自设数据, 无法横向比较	MoleculeNet、TDC (Therapeutics Data Commons) 公共基准

⑤ 机遇与趋势 (结课展望)

- 蛋白语言模型 (ESM-2/3): 只靠序列学出结构与功能表征, 小数据下游迁移;
- 多模态大模型: 文本 (文献) + 分子 + 结构 + 组学统一表征;
- 自动化实验室: AI 提方案 $\rightarrow$ 机器人合成测试 $\rightarrow$ 数据回流 (自驱动实验室 self-driving lab);
- 产业验证: AI 管线进入临床 II/III 期 (第 10-11 章), 方法论被资本市场与药监双重检验。

🔪 一句话辩证: AI 放大「数据和算力能解决的问题」, 解决不了「机理未知与验证缺失」。科研者的价值在补后两者。

第 3 章 · 人工智能基础

3.0 机器学习地基

3.1 CNN

RNN/Transformer

3.2 GNN

评价指标

分子图工程

① 三大学习范式（对号入座药学任务）

范式	机制	药学例子
监督学习	带标签 (x, y), 学 $x \rightarrow y$ 映射, 最小化损失	分子 $\rightarrow$ IC ₅₀ (回归); 分子 $\rightarrow$ 毒性 (分类)
无监督学习	无标签, 找数据内在结构	化合物库聚类 (多样性分析)、化学空间降维可视化
强化学习	智能体在环境中动作, 靠奖励信号学策略	逐原子「搭」分子, 奖励=预测活性+类药性 (第 8 章)

② 损失函数：把目标写成一个数

- 回归: $MSE = (1/n) \sum (y_i - \hat{y}_i)^2$ (对离群值敏感); $MAE = (1/n) \sum |y_i - \hat{y}_i|$ (更稳健)。
- 分类: 交叉熵 $L = -\sum y_i \cdot \log \hat{y}_i$; 二分类时化为 $-[y \cdot \log p + (1-y) \cdot \log(1-p)]$ 。概率预测越「自信且对」, 损失越小。
- 正则项: $L2 = \lambda \sum \theta^2$ (权重衰减, 防过拟合); $L1 = \lambda \sum |\theta|$ (还能稀疏特征选择)。

总目标 = 拟合项 + 正则项

$$\min_{\theta} \quad (1/n) \sum L(f_{\theta}(x_i), y_i) + \lambda \cdot R(\theta)$$

③ 梯度下降与反向传播（手算一遍就懂）

1. 前向: 输入 x 过网络得预测 $\hat{y}$, 算损失 L 。
2. 反向: 从 L 出发用链式法则逐层回算 $\partial L / \partial \theta$ (每个参数的「责任」) ——这就是反向传播, 本质是求导的自动化。
3. 更新: 每个参数 $\theta \leftarrow \theta - \eta \cdot \partial L / \partial \theta$; η 是学习率 (太大震荡、太小龟速)。
4. 变体: 批量梯度下降 (全量数据)、SGD (单样本, 快而抖)、Mini-batch (折中, 最常用)、Adam (自适应学习率, 默认首选)。

④ 偏差-方差权衡与过拟合处方

- ★ 欠拟合 (高偏差): 训练/测试都差 $\rightarrow$ 加模型容量、加特征、训更久。
- ★ 过拟合 (高方差): 训练好测试差 $\rightarrow$ 更多数据、正则化 ($L2$ /Dropout $p \approx 0.1-0.5$)、早停 (验证集 loss 不再降就停)、降容量、交叉验证选超参。
- ★ k 折交叉验证: 数据切 k 份轮流当验证集, 报 k 次均值 $\pm$ 方差——小数据集的标配 (药学 $k=5$ 或 10)。

🔬 科研习惯: 每个实验固定随机种子、记录超参与数据划分方式——AIDD 论文复现失败的第一死因就是这些「小事」。

⑤ 数据划分：药学与通用 ML 的分水岭（必考）

划分方式	怎么做	模拟什么现实 / 风险
随机划分	按比例随机抽 (8:1:1)	「认识分子的近亲」——同骨架分子跨集 → 指标虚高，仅在基线对比用
骨架划分 scaffold split	先抽 Murcko 骨架，整族骨架只进一个集合	「预测全新骨架」——最接近真实筛选场景，论文必须报告
时间划分	按专利/发表年份切，旧的训练新的测试	「用历史预测未来」——最严格，工业界金标准
靶点留出	整个靶点不留训练	「换靶泛化」——DTA 多靶模型的诚实考法

骨架划分实操 (RDKit + sklearn 思路)

```
from rdkit.Chem.Scaffolds import MurckoScaffold
```

```
df['scaffold'] = df.smiles.apply(lambda s: MurckoScaffold.MurckoScaffoldSmiles(smiles=s))
```

按 scaffold 分组，整组整组地划入 train/val/test (勿组内拆散)

⑥ 分类指标：从混淆矩阵到 AUC

★ 混淆矩阵四格：TP（真阳性）、FP（假阳性）、FN（假阴性）、TN。

★ 精确率 $P = TP/(TP+FP)$ 「报出的有多少真」；召回率 $R = TP/(TP+FN)$ 「真阳性找到多少」； $F1 = 2PR/(P+R)$ 。

★ ROC-AUC：遍历所有判决阈值画 TPR vs FPR 曲线下面积；0.5=瞎猜，0.7 可用，0.85 优秀（不平衡下偏乐观）。

★ PRC-AUC：精确率-召回率曲线面积；正例稀少时（毒性筛选 1:100）只看它。

⑦ 回归指标与「药学换算」

• RMSE / MAE 单位与目标一致；对 pIC_{50} 回归，RMSE<1 个 log 单位算可用。

• 分类化处理：活性阈值（如 $IC_{50} \leq 1 \mu M$ 记阳性）→ 分类指标；写论文要报告阈值选择。

• 类不平衡对策：类别权重、过采样、focal loss；永远先看正负比例再选指标。

🔪 审稿人三连问：scaffold split 了吗？正负比例多少？指标是不是 PRC？——答不上来会被当作「没做过药学 ML」。

⑧ 卷积到底在算什么 (3.1 上)

一个 3×3 卷积核 (可学习的小权重窗口) 在输入上滑动, 每个位置做逐元素相乘求和, 得到特征图上的一个数。直观: 核 = 「特征探测器」(横边、圆弧……在分子图像里就是键、环、官能团的样子)。

输出尺寸公式 (必背)

$$O = \lfloor (W - F + 2P) / S \rfloor + 1 \quad W \text{ 输入宽} \cdot F \text{ 核宽} \cdot P \text{ 填充} \cdot S \text{ 步长}$$

- 例: 输入 32×32 , 核 3×3 , $P=0$, $S=1 \rightarrow$ 输出 30×30 ; $P=1 \rightarrow$ 尺寸不变 (「same」卷积)。
- 参数共享: 同一核扫全图 $\rightarrow$ 参数量 $= F \times F \times C_{in} \times C_{out}$, 与图像大小无关 (对比全连接的指数爆炸)。
- 多通道: 每层多个核并行, 输出堆叠成通道 (初代可理解为「多种特征探测器并行」)。
- 池化: max/avg 降采样, 缩小尺寸、提供小平移不变性; 现代网络常用步长卷积替代。

⑨ 经典架构进化线 (一句话记住贡献)

架构	年份	关键创新
LeNet-5	1998	卷积+池化+全连接的祖师爷 (手写数字)
AlexNet	2012	ReLU (防梯度消失) + Dropout (防过拟合) + GPU 训练 $\rightarrow$ 深度学习元年
VGG	2014	堆叠 3×3 小核代替大核 (同感受野、更深、参数更少)
GoogLeNet	2014	Inception 多尺度并行卷积
ResNet	2015	残差连接 $y = F(x) + x$, 梯度直通, 网络深到 152 层不退化——Transformer/AF2 全在用

⑩ CNN 在药物设计中的四个落点

1. 高内涵筛选 (HCS): 细胞图像 $\rightarrow$ 细胞表型分类 (凋亡/分化/细胞器形态), 找表型改变物。
2. 分子图像: 把结构式画成图像喂 CNN 做性质预测 (布局无关, 同一分子多画几张当增强)。
3. 3D 格点: 把口袋/配体周围物理量 (电荷、疏水) 装进 3D 网格 $\rightarrow$ 3D-CNN 直接学「结合与否」; GNINA 的 CNN 打分即此。
4. 序列编码: SMILES/蛋白序列 one-hot+嵌入 $\rightarrow$ 1D 卷积捕捉局部 motif (DeepDTA 的双 CNN 通路, 第 9 章详拆)。

🔪 为什么 CNN 天生适合「局部特征」任务: 卷积的归纳偏置 = 局部性 + 平移不变——恰好匹配「药效取决于局部官能团排布」的化学直觉。

⑪ RNN: 按时间步读序列

隐状态循环更新 (核心方程)

$$h_t = \tanh(W_x \cdot x_t + W_h \cdot h_{t-1} + b) \quad \hat{y}_t = \text{softmax}(W_y \cdot h_t)$$

- x_t = 当前字符 (如 SMILES 的一个原子符号), h_t = 「读到现在的记忆」。
- 致命伤: 长序列梯度消失/爆炸 (BPTT 连乘), 记不住长程依赖; SMILES 超 50 字符就吃力。
- LSTM 加三门自救: 遗忘门 $f_t = \sigma(\dots)$ 、输入门 i_t 、输出门 o_t , 细胞态 $C_t = f_t \odot C_{t-1} + i_t \odot C_t$ 提供「信息高速路」(梯度直通)。GRU 简化为两门, 效果相当更快。

⑫ Transformer: 注意力取代循环 (2017)

缩放点积注意力 (必背)

$$\text{Attention}(Q, K, V) = \text{softmax}(Q \cdot K^T / \sqrt{d_k}) \cdot V$$

- ★ 直觉: Q (查询) $\times K$ (键) 相似度 $\rightarrow$ softmax 权重 $\rightarrow$ 对 V (值) 加权求和 = 「按相关性取信息」。 $\sqrt{d_k}$ 防止点积过大 softmax 饱和。
- ★ 多头注意力: h 组独立 QKV 并行 (不同子空间学不同关系: 化学键/空间邻近/电荷互补...), 拼接后投影。
- ★ 位置编码: 无循环无卷积 $\rightarrow$ 用正弦 $\text{PE}_{(\text{pos}, 2i)} = \sin(\text{pos}/10000^{2i/d})$ 或可学习嵌入注入顺序信息。
- ★ 堆叠结构: 每层 = 多头注意力 + 前馈网络 (FFN), 各配残差连接与 LayerNorm (Pre-LN 训练更稳)。
- ★ 两用法: 编码器 (BERT 式, 双向理解分子); 解码器 (GPT 式, 自回归逐 token 生成 SMILES, 第 8 章生成模型主力)。

⑬ 药学落点

模型	怎么用 Transformer
MolGPT / ChemGPT	海量 SMILES 预训练 $\rightarrow$ 生成/条件生成分子 (类 GPT)
ESM-2 (蛋白语言模型)	2.5 亿序列预训练, 表征直接预测结构接触图/功能; AF2 的 MSA 替代品
MolBERT 类	掩码恢复预训练 SMILES $\rightarrow$ 下游性质预测微调
ChemBERTa	同上, HuggingFace 生态直接可用的分子编码器

🔪 面试高频: 为什么 Transformer 取代 RNN 做分子生成? ——①全连接并行训练快; ②长程依赖直接一跳到达; ③规模法则: 堆参数堆数据持续涨点 (GPT 同款逻辑)。

⑭ 分子 = 图：为什么以及怎么建 (3.2 上)

- 节点=原子，特征向量 one-hot 拼接：元素类型、度、形式电荷、杂化类型 ($sp^3/sp^2/\dots$)、是否芳香、是否在手性中心、氢原子数。
- 边=化学键，特征：键型 (单/双/三/芳香)、是否共轭、是否在环中——用消息矩阵或邻接矩阵+边特征张量存。
- 对比 SMILES：图无书写顺序偏置 (同一分子 N 种 SMILES 应同表示——置换不变性)，天然保留拓扑；对比指纹：图可微分、可端到端。

⑮ 消息传递神经网络 MPNN (方程级，必背)

每一轮迭代分三步，跑 k 轮后每个原子「看到」k 键以外的世界：

$$\textcircled{1} \text{ 消息聚合: } m_v^{(t)} = \text{AGG}_{u \in N(v)} (M(h_v^{(t-1)}, h_u^{(t-1)}, e_{uv}))$$

$$\textcircled{2} \text{ 节点更新: } h_v^{(t)} = U(h_v^{(t-1)}, m_v^{(t)}) \quad (\text{如 GRU/LINEAR+ReLU})$$

$$\textcircled{3} \text{ 读出 (图级): } \hat{h}_G = \text{READOUT}(\{h_v^{(T)} \mid v \in G\}) \quad (\text{SUM/MEAN/ATTENTION 池化})$$

- M = 消息函数 (通常是 MLP); AGG = 聚合 (求和最保信息, 均值最稳, $\max$ 抓显著特征); READOUT 把原子级表示汇成分子级向量, 接分类/回归头。
- 「k 层 = k 键感受野」: 要捕捉跨分子的长程药效团, 加深或加全局注意力 (如 UNIMP/Graphormer 加虚拟全局节点)。

⑯ 四大变体各自的更新方程

模型	核心方程 (第 $l+1$ 层)	一句话特点
GCN	$H^{(l+1)} = \sigma(D^{-1/2} \tilde{A} D^{-1/2} H^{(l)} W^{(l)}) \quad (\tilde{A} = A + I)$	邻接归一化加权平均, 简单稳定
GraphSAGE	$h_v = \sigma(W \cdot [h_v \parallel \text{AGG}_{\text{采样邻居}}])$	邻居采样, 能上亿级节点大图 (PPI)
GAT	$\alpha_{ij} = \text{softmax}_j(\text{LeakyReLU}(a^T [Wh_i \parallel Wh_j])); h_v' = \sigma(\sum_j \alpha_{ij} \cdot Wh_j)$	注意力权重自动学「听哪个邻居」
GIN	$h_v^{(l+1)} = \text{MLP}^{(l)}((1+\epsilon) \cdot h_v^{(l)} + \sum_{u \in N(v)} h_u^{(l)})$	判别力理论上限 $\approx$ WL 同构测试, 分类分子最强

🔪 通病过平滑：层数深 $\rightarrow$ 所有节点表示趋同。处方： ≤ 3 -5 层、残差连接、跳跃聚合 (JK-Net)、或上图 Transformer。

⑪ GNN 在药物设计中的任务清单 (按图类型记)

图是什么	任务	代表工作
小分子图	图级性质/毒性回归分类	MoleculeNet 基准上的 GCN/GIN 系
	分子生成 (图上生成)	MolGAN、GraphAF、GraphDF
	反应产物预测 (反应中心识别)	WLN (Weisfeiler-Lehman Network)
蛋白残基图	残基网络→功能/相互作用位点	蛋白质残基接触 GNN
蛋白-配体复合物二部图	亲和力预测 (原子级界面建模)	GraphDTA、DGraphDTA
PPI/疾病-基因网络	节点分类、链接预测 (找靶)	GCN/GAE 用于靶点-疾病关联
知识图谱	三元组补全 (推理新关联)	R-GCN、TransE (第 4 章)

⑫ 上机: 10 行代码跑一个 GNN 性质预测 (PyG)

```

from torch_geometric.datasets import MoleculeNet
from torch_geometric.nn import GCNConv, global_mean_pool
dataset = MoleculeNet(root='./esol', name='ESOL') # 水溶解度, 1128 分子
class Net(torch.nn.Module):
    def forward(self, data):
        x = F.relu(self.conv1(data.x, data.edge_index)) # 消息传递×2 轮
        x = F.relu(self.conv2(x, data.edge_index))
        return self.lin(global_mean_pool(x, data.batch)) # 读出→回归

```

跑通后动手实验: ①把 GCNConv 换成 GATConv/GINConv 比指标; ②加深到 6 层看过平滑; ③把随机划分改成 scaffold split 看掉多少分——这三个实验就是第 3 章的期末大礼包。

⑬ 第 3 章总结表 (贴墙版)

	CNN	RNN/LSTM	Transformer	GNN
输入	网格/图像	序列	集合+位置	任意图
偏置	局部+平移不变	时序因果	全连接注意力	置换不变+拓扑
药学主场	图像/格点/序列分支	早期 SMILES 生成	预训练+生成	分子图/DTA/反应
代表	ResNet/GNINA	ChemV LSTM	MolGPT/ESM	GIN/GraphDTA

第 4 章 · AI 挖掘潜在药物靶标

- 4.1 靶标定义与类型
- 4.2 网络药理学
- 4.3 AI 方法
- 4.4 应用场景
- 数据库实操

① 药物靶标：定义与两个层次

- ★ 生物学定义：药物与之结合并产生（治疗或毒性）效应的生物大分子。
- ★ 通行（成药性）定义：不仅「有效」，还必须「可被药物触达与调控」——有可结合口袋（或可降解标签位点）、有合适的功能角色。
- ★ 数量格局：人类 ~2 万蛋白编码基因 → 已成功成药靶标仅 约 500-700 个；疾病相关蛋白中估计 >80% 仍属「不可成药」（PPI 界面平坦、无序蛋白、离子通道难选择性等）——靶标发现是整个链条最大的蓝海。

② 靶标家族与代表药物（认脸题库）

家族	特点	代表靶点 / 药物
G 蛋白偶联受体 GPCR	7 次跨膜；信号「总线」；成药之王（约 1/3 上市药）	β_2 肾上腺素受体/沙丁胺醇；CCR5/马拉维若
蛋白激酶	磷酸转移酶；肿瘤靶向药主战场（ATP 口袋竞争/变构）	BCR-ABL/伊马替尼；BRAF ^{V600E} /维莫非尼
离子通道	膜电位与兴奋性；选择性难	hERG（要躲开的「反靶」）；Nav1.7/镇痛
核受体	配体激活的转录因子	雌激素受体 ER/他莫昔芬；PPAR α /非诺贝特
酶（其他）	催化口袋明确、好成药	HMG-CoA 还原酶/他汀；DPP-4/西格列汀；PHD/ISM5411
转运体	跨膜转运底物	SGLT2/达格列净；P-gp（外排泵，ADMET 常客）
结构蛋白/其他	新兴难成药	微管蛋白/紫杉醇；PCSK9（抗体）/依洛尤单抗

③ 「好靶标」四要素（评价新靶点的 checklist）

1. 疾病因果性：人遗传证据（GWAS/OMIM） > 动物模型 > 细胞表型；「相关性」不算数，要「因果性」。
 2. 可药性 druggability：有口袋/可结合面（AlphaFold 结构 + fpocket 评估）；或可被降解（PROTAC）。
 3. 安全窗：敲除/抑制后的生理后果（组织分布、必需基因排除）；有反向证据（human genetics）最好。
 4. 可行性与价值：已有工具化合物？适应症市场/竞争格局/专利空间。
- ❖ 靶点验证铁律：至少两条独立证据链（如遗传+CRISPR；或组学+动物表型）才能进入管线——单条组学信号的三分之二复现不出来。


④ 湿实验四大技术（原理与局限）

技术	怎么做	读出什么 / 局限
RNA-seq 转录组	病例 vs 对照组织，测序计数 → 差异表达分析 (DESeq2 负二项模型；阈值 $ \log_2FC > 1$ 且 $p_{adj} < 0.05$)	哪些基因表达变了；多是「结果」而非原因
GWAS 全基因组关联	数百万 SNP 与表型做关联检验；显著性阈值 $P < 5 \times 10^{-8}$ (Bonferroni 校正)	遗传因果线索；位点常落在非编码区，需功能注释
CRISPR 筛选 KO / CRISPRi / CRISPRa	全基因组 sgRNA 文库感染细胞 → 处理 (药物/疾病压力) → 测序统计 sgRNA 富集/耗竭 (MAGeCK 等分析)	「删谁会抗药/致病」——因果性最强的功能证据；依赖细胞模型
蛋白/代谢组	质谱定量差异蛋白/代谢物	接近表型；动态范围与定量重现是难点

⑤ 单细胞与时空分辨率（新一代证据）

- 单细胞 RNA-seq (scRNA-seq)：解出组织中每种细胞类型的表达谱 → 靶点必须「在病变细胞里高表达」才算数；细胞类型特异性可解释组织副作用。
- 空间转录组：保留位置信息，看病灶微环境 (免疫浸润 vs 实质细胞)。
- 整合策略：差异基因 × 细胞特异性 × 疾病相关性三矩阵交集 → 候选优先。

⑥ 从「单基因思维」到网络思维



- 网络药理学是中药复方研究的标准框架：活性成分 → 作用靶点 → PPI 网络 → 通路富集 (GO/KEGG) → 核心靶点验证。
- 「关键节点」的直觉：扰动它，网络能回到健康吸引子——比「表达最高」更有价值。

🔪 证据等级速记 (从强到弱)：人遗传学 ≈ CRISPR 功能筛选 > 动物模型 > 细胞表型 > 组学相关 > 文本挖掘假设。

⑦ PPI 网络构建与中心性指标 (定义要背)

- 数据来源: STRING (聚合实验/共表达/文献/共定位证据, 打分 0-1, >0.7 高置信)、BioGRID (curation 为主)。
- 度中心性 DC: 节点直接连接数——hub 倾向「全局要员」(也常是必需基因, 毒性风险高)。
- 介数中心性 BC = $\sum_{s \neq v \neq t} \sigma_{st}(v) / \sigma_{st}$: 经过 v 的最短路比例——「信息桥」, 扰动它断整条信号路。
- 接近中心性 CC: 到全网平均距离倒数——离谁都不远, 信号扩散快。
- 模块 (community): Louvain/Leiden 算法按模块度最大化分簇; 疾病模块假设 = 「致病基因在网络上抱团且彼此邻近」。

⑧ 网络挖掘找靶的标准流程 (六步, 可写进方法学)

1. 收集种子基因: 已知疾病基因 (DisGeNET/OMIM/全基因组关联研究 GWAS 目录)。
2. 建网络: 种子基因 + 一阶邻居 (STRING) → 疾病相关子网。
3. 拓扑分析: 中心性排序 + 模块检测, 找与种子模块重叠的候选节点。
4. 网络传播 (RWR 随机游走): 从种子出发模拟信号扩散, 收敛概率即「疾病关联分」——比纯中心性更稳。
5. 富集分析 (GO/KEGG/Reactome): 候选是否落在疾病相关通路。
6. 过滤排序: 成药性 (有无已知配体/结构可及) + 组织表达 + 安全性, 取 Top 20-50 进实验。

网络传播直觉版 (random walk with restart)

$p_{t+1} = (1-r) \cdot W^T p_t + r \cdot p_0$ # $r \approx 0.7$ 重启概率; p_0 = 种子基因指示向量; 收敛后的 p 即各基因疾病关联分

🔪 网络方法的科学假设: 功能相近的基因在网络拓扑上相近 (「近邻者相像」)。反例提醒: hub 靶点常致死——centrality 高 $\neq$ 好靶点, 要联合安全性与疾病特异性 (细胞类型表达) 过滤。

⑨ 生物医学知识图谱：把文献变成可推理的三元组

- ★ 节点：基因/蛋白、疾病、药物、副作用、通路、组织；边：结合、抑制、上调、关联、治疗……每条边一个三元组（头实体，关系，尾实体）。
- ★ 构建：文献/专利/临床试验登记（PubChem、ClinicalTrials.gov）→ NLP 抽取（命名实体识别 NER + 关系抽取，BioBERT/ PubMedBERT 微调）→ 实体对齐（UniProt ID 归一）。
- ★ 推理 = 链接预测：训练嵌入模型给「不存在的边」打分，分高者即新假设（新靶点-疾病关联、老药新适应症）。

TransE 打分函数（经典知识图谱嵌入）

$$f(h + r \approx t): \text{score}(h, r, t) = -\|h + r - t\| \quad (\text{头向量} + \text{关系向量} \approx \text{尾向量})$$

训练：正样本=已有三元组，负采样=替换尾实体；学到的嵌入空间里「相似靶点」自动聚拢。R-GCN 用图卷积处理多关系边，效果更强。

⑩ 文本挖掘实战路径（巴瑞替尼案例复盘）


1. BenevolentAI 知识图谱收编数千万文献实体关系（2020 年 1 前的病毒学/免疫学知识）。
2. 查询模板：「新冠致病过程涉及的宿主蛋白」 $\cap$ 「已有药物可抑制的宿主蛋白」。
3. 推理命中：AP2 相关激酶 AAK1（巴瑞替尼的已知靶）参与网格蛋白介导的内吞——病毒入胞路径；同时 JAK 抑制压制细胞因子风暴。
4. 输出假设 → 2 月初发表于 Lancet 提议 → ACTT-2 临床验证 → 11 月 FDA EUA。从文本到标签 9 个月。

⑪ 表达谱相似与老药新用（CMap）

- 原理：药物处理细胞产生的「表达签名」与疾病签名反向匹配（连接性得分 < 0 ）→ 该药可能逆转疾病状态。
- 平台：CMap/clue.io（L1000 平台，~1.5 万化合物扰动签名）；新版 Touchstone-RNA-seq。
- 步骤：疾病组织差异基因（上调/下调各 150）→ 查询 CMap → 负分药物列表 → 药理合理性筛选 → 细胞/动物验证。

三类「AI 找靶」弹药分工：网络传播/中心性（结构洞）、知识图谱（文献先验）、表达签名（表型反转）——成熟项目通常三路并跑取交集。

⑫ 多组学 + 机器学习靶标分类器 (把上面全部装起来)



- 标签从哪来: 正例=TTD/DrugBank 已验证治疗靶点 (按疾病分); 负例要小心——「未成药」≠「不可成药」, 可用「安全必需基因」「无关组织基因」等构造可信负例。
- 验证协议: 留一疾病 (leave-one-disease-out) 评估跨病泛化, 避免「背下热门靶」。
- 企业级实现: PandaOmics = 上述流水线产品化 (组学+文献+专利+临床试验 21 种数据源融合, 输出新颖性/成药性/安全性三轴评分, 第 10 章)。

⑬ 从靶点到「可启动项目」还要过三关

关卡	做什么	工具
结构可及性	有无实验结构/AlphaFold 模型质量 (pLDDT、口袋完整性)	PDB / AFDB / fpocket (第 5 章)
配体先验	已知活性化合物、工具化合物、SAR 起点	ChEMBL / BindingDB / 专利
安全预判	必需基因? (DepMap 依赖性筛查) 组织表达? 副作用网络预测	DepMap / GTEx / SIDER

⑭ 应用场景四件套 (4.4 节背诵版)

- ★ 全新靶标发现: 多源证据排序 (英矽 TNiK 的发现路径, 第 10 章)。
 - ★ 老药新用: CMap 反转 + 知识图谱 (巴瑞替尼)。
 - ★ 靶点优先级: 新颖性 × 成药性 × 安全性三维打分。
 - ★ 生物标志物/患者分层: 药物反应相关分子特征 (组学+ML), 为临床试验找对人群。
- 🔪 答题万能五步: 多源数据 → 统一表征 → 学习已知关联 → 推理新关联 → 实验闭环。第 10-11 章两个企业案例会逐字印证这套流程。

⑮ 靶标数据库详表 (上机手册级)

库	内容 / 规模	典型查询场景
TTD	治疗靶标: 成功/临床/试验阶段全覆盖 (靶点→药物→适应症映射)	「这个靶做到几期了? 竞争格局?」
DrugBank	~1.5 万药物条目: 靶标、代谢酶、转运体、DDI 全注释	「这个药打到哪些靶/被谁代谢?」
Open Targets	遗传/文本/动物/药物多源证据给「靶-病关联」打分 (0-1)	某病的候选靶排序首选
DisGeNET	基因-疾病关联 (GS 得分), 可下载	批量取某病种子基因
OMIM	孟德尔遗传病-基因 (人遗传证据金标准)	强因果证据来源
GWAS Catalog	全基因组关联位点汇总 (含 P 值、效应量)	复杂疾病遗传线索
PharmGKB	药物基因组学: 变异→剂量/反应	个体化用药证据
STRING / BioGRID	PPI 网络 (STRING 有 API 可批量下载)	建子网、算中心性
GTEEx / DepMap	正常组织表达谱 / 基因依赖性 (CRISPR 敲除存活)	安全性预判两件套
SIDER	药物副作用-药物关联	安全信号与老药新用线索

⑯ 实操串联: 给「某肿瘤」找新靶 (1 天速通)

1. Open Targets 搜该癌种 → 导出关联分 Top 300 基因 (证据类型分层看, 重点遗传学)。
2. DisGeNET + GWAS Catalog 补种子基因; 剔除已在 TTD 有 III 期竞品的 (保留差异化)。
3. STRING 拉一阶 PPI 子网 (置信度 0.7+) → NetworkX 算度/介数 → RWR 传播分。
4. GTEEx 看组织表达 (病变高、必要器官低); DepMap 排除必需基因。
5. AlphaFold/AFDB 查结构可及性 + fpocket 估口袋 → 输出 Top 20 候选靶档案 (证据/网络/安全/可药性四栏)。

🔪 这个流程就是一次组会汇报的完整骨架: 候选表 + 每个候选的四栏证据 + 你自己的取舍理由。

第 5 章 · AI 预测靶蛋白结构

5.1 结构基础与实验解析	5.2 传统预测三路线	5.3 AlphaFold2 详解	AF3 与诺奖	5.4 AI 蛋白设计
上机实操				

① 结构层次（用药物设计语言重述）

层次	内容	与药物设计的关系
一级	氨基酸序列（20 种字母的字符串）	靶标发现与 AF2 的输入；序列同一性判断同源
二级	α 螺旋、 β 折叠、转角（氢键骨架模式）； Ramachandran 图界定允许的 φ/ψ 角	口袋壁的「建材」；螺旋偶极参与静电互补
三级	整条链折叠成 3D（疏水内核+氢键网络+盐桥）	结合口袋/活性位点的直接来源——SBDD 的地基
四级	多链组装（同源二聚体、复合物）	PPI 界面靶点；抗体-抗原界面

- Anfinsen 定理：多数蛋白的天然结构由序列唯一决定（热力学最低能态）——结构预测之所以可能的物理前提。
- 结构决定功能：酶催化三联体的空间排布、受体跨膜区构象变化，都只有 3D 能解释。

② 实验结构解析三件套（对比着记）

	X-ray 晶体衍射	NMR 核磁	Cryo-EM 冷冻电镜
样品	必须结晶（最大瓶颈）	溶液，需同位素标记	冷冻薄冰中的颗粒
适用	几乎全部；小分子-蛋白复合物金标准	<30-50 kDa 小蛋白	>100 kDa 大复合物（膜蛋白福音）
产出	静态平均结构（电子密度图）	系综（能看到动态！）	密度图；分辨率近年 2-3 Å 常见
局限	结晶假象、柔性区无密度	尺寸天花板	小蛋白不行；构象偏向

PDB 现存 >23 万结构，但相对数以亿计的蛋白序列仍是九牛一毛 → 计算预测补位（本章主角）。

✂ 结构拿到后的第一步永远是「看质量」：分辨率（X-ray/EM）、R-free、Ramachandran 允许区占比、配体密度是否支持摆放姿态——盲信任何结构（包括 AF2）都可能在口袋处翻车。

③ 同源模建 Homology Modeling (模板路线)

理论根基: 序列相似 → 结构保守 (同一性 >30% 通常可建可靠模型)。

1. 模板识别: BLASTp 快速搜; 远缘用 HHpred/HHblits (HMM-HMM 比对, 灵敏度高一档)。
2. 序列-模板比对: 多序列比对确定残基对应 (比对错误 = 模型错误的头号来源)。
3. 骨架建模: 保守区拷模板主链; 环区 (loop) 单独搜索/建模 (MODELLER 约束满足; loop 是误差重灾区)。
4. 侧链安装: 旋转异构体库 (rotamer) 按位阻与能量选 (SCWRL 等)。
5. 评估优化: 能量最小化; MolProbity 查 ϕ/ψ 与碰撞; 差则回第 2 步。
 - 精度规律: 同一性 >50% 主链 RMSD~1Å (可信); 30-50% 骨架可用、loop 存疑; <25% 不可靠。
 - SWISS-MODEL (网页全自动) 适合入门; MODELLER (Python 脚本) 适合批量。

④ 折叠识别 threading 与从头预测

路线	原理	能力边界
Threading 折叠识别	序列「穿」过已知折叠库逐个打分 (剖面+二级结构+环境势兼容性), 选最佳折叠	序列同源低但折叠同源的「远房亲戚」; 无法给出全新折叠
从头预测 ab initio	物理能量函数 + 构象采样: 片段组装 (Rosetta 把短片段统计势拼起来)、蒙特卡洛搜索	仅 <100 aa 小蛋白可行; 算力黑洞——AF2 出局前从未真正实用

⑤ 裁判 CASP 与打分 GDT_TS

- CASP: 1994 年起两年一届的「盲测奥运会」——组织方发序列, 参赛队交模型, 与未公开实验结构比对。
- GDT_TS = 在 1/2/4/8 Å 四个距离阈值下「叠合正确的残基百分比」的平均 $\times 100$: >90 视同实验精度; 50 约等于「拓扑对了」。
- 历史: CASP1-13 同源/threading 缓慢爬升; CASP14 (2020) AF2 中位 GDT $\approx$ 92.4 一举「解决」问题——两代技术断崖差的分界线。

🔪 为什么物理路线输给学习路线: 构象空间天文级 (Cyrus Levinthal 悖论: 穷举比宇宙年龄还久), 物理能量项又不完美; 进化信息 (MSA 中「谁和谁共同变化」) 反而携带了折叠约束的最强信号——AF2 的胜利是信息来源的胜利。

⑥ AF2 三段式架构总览 (5.3 核心)



⑦ 两个「表示」是什么

- ★ 单序列表示：每残基一个向量（学了该残基的局部特征与协同进化信号）。
- ★ 残基对表示：每对残基 (i,j) 一个向量——学「i 和 j 的关系」：空间距离/方位/接触概率。这是 AF2 最关键的设计：把「预测结构」转化为「预测残基对几何」。
- ★ 两者在 48 个 Evoformer 块里双向交流：序列信息更新对表示，对信息反过来更新序列表示——每块都有注意力与三角更新。

⑧ Evoformer 里的两个招牌模块

模块	做什么	为什么聪明
轴向注意力	行注意力 + 列注意力分别做（对 N×N 矩阵不全局做注意力，按行/列分解）	复杂度从 N^4 降到 N^3 ；残基对矩阵大，必须省算力
三角更新 triangle update	更新 (i,j) 时强制利用 (i,k) 与 (k,j) 信息（「三角形边传递」），配套 triangle self-attention	把几何一致性写进架构：若 i-k、k-j 距离已知，i-j 距离必受约束（三角不等式）——网络自己学会物理约束

- MSA 用法细节：大 MSA 随机采样 (M=512) 注入噪声防过拟合；MSA 深度（序列条数）也作为「进化信息量」影响置信度——浅 MSA 是精度下降的主因之一。

🔪 科研视角：AF2 的本质是「协同进化信号 + 注意力推理几何」。这也是它怕浅 MSH（孤儿序列/快速进化蛋白）的根本原因——没有进化记录就没有信号。

⑨ 结构模块：IPA 不变点注意力（概念级拆解）

- 1. 每个残基被赋予一个刚体变换（旋转 R + 平移 t ）——骨架自由度天然参数化，避免直接回归坐标的数值灾难。
- 2. 每残基带若干「点」(backbone frames 上的查询点)；IPA 对这些几何不变量做注意力：无论整体旋转平移蛋白质，注意力打分不变（等变性）。
- 3. 注意力同时融合单序列表示与残基对表示（对表示当作注意力偏置）→ 更新刚体 → 逐轮精化侧链（旋转异构体）。
- 4. 端到端可微：坐标直接进损失（FAPE 帧 align 点误差），梯度从结构一路回传 Evoformer——「结构监督」而非手工中间目标。

⑩ 自带置信度：会预测还要会自评（用结构前必看）

指标	含义	用法阈值（经验）
pLDDT	逐残基置信度（局部距离差异检验，0-100）	>90 很高；70-90 主链可信；50-70 低；<50 视为内在无序区（IDR）——直接当柔性尾巴处理
PAE	残基对相对位置误差矩阵	判断结构域之间的相对取向是否可靠：域内低、域间高 → 域间摆放别当真（对接时小心）

- AFDB (AlphaFold DB)：与 EMBL-EBI 合作的开放库，覆盖 >2 亿个蛋白结构（UniProt 全集），免费检索下载——「结构界的维基百科」。
- 本地跑：ColabFold（Colab 免费算力版 AF2，支持 multimer）；RoseTTAFold 为同期双轨网络（1/2/3 轨道信息传递），思想互通。

AF2 的四个「不能」（辨析题常客）

① 不能给动态系综（单一构象 vs 真实构象集合，分子动力学 MD 仍需补位）；② 点突变效应（ $\Delta\Delta G$ ）不可靠——序列几乎不变但功能可变；③ 配体/共因子摆放未经物理优化，口袋侧链姿势对接前建议重优化；④ 复合物链数多时 AF2-Multimer 成功率下降。

⑪ AlphaFold3 (Nature 2024.5)：三大升级

升级点	AF2	AF3
体系范围	蛋白（多聚体靠 Multimer 扩展）	一次预测蛋白+DNA/RNA+小分子+离子+修饰的全原子复合物
结构生成器	IPA 直接回归坐标（单构象）	生成式扩散模块：以条件（Evoformer 输出）为引导，从噪声去噪出多个候选构象——天然支持多样性
药物设计意义	给靶蛋白形状	直接给蛋白-配体结合姿态（对标对接的 pose 预测）与共因子/核酸复合物

- AlphaFold Server：官方免费网页端（学术/非商业），提交多条链+配体 SMILES 即可。
- 局限延续：静态视角、突变效应仍弱；商业使用受限（开源社区有 OpenFold/Chai-1 等替代快速追赶）。

⑫ 2024 诺贝尔化学奖（AI 结构生物学的加冕）

- ★ 一半：Demis Hassabis & John Jumper（AlphaFold2——结构预测）；一半：David Baker（计算蛋白设计，Rosetta/RFdiffusion 体系）。
- ★ 解读：诺奖同时承认「正问题」（序列→结构，AF2）与「逆问题」（结构/功能→序列，Baker）——AI 完整接管蛋白质的读与写。

⑬ AI 蛋白质设计工具箱（5.4，逆问题）

工具	任务	要点
ProteinMPNN	逆折叠：给定期望骨架 → 设计序列	消息传递（骨架上下文→氨基酸概率，自回归生成）；成功率高、速度快，蛋白设计的「序列打印机」
RFdiffusion	全新骨架生成	以 RoseTTAFold 为去噪网络的扩散模型，可「无条件造蛋白」「按动机造结合剂」「填口袋造酶」
标准闭环	设计-验证流水线	RFdiffusion 出骨架 → ProteinMPNN 配序列 → AF2/AF3 预测复核 → 表达纯化 → 结构解析验证（X-ray/Cryo-EM）；多轮循环收敛
传统法对照	理性设计、定向进化	基于催化机制/统计势的改造 + 高通量突变筛选；与 AI 互补，都离不开实验

- 🔪 药物设计者的直接受益：①难结晶靶点用 AFDB 结构开工；②「不可成药」靶可用设计蛋白（mini-binder/PROTAC 元件）新打法；③酶疗法与疫苗抗原设计提速。

⑭ 实操 A: 拿到靶蛋白结构的四条路 (按优先级)

1. PDB 查实验结构 (最优先): rcsb.org 搜 UniProt/名称; 下载时看分辨率与配体复合物 (有共晶更好——口袋姿态参考)。
2. AFDB 查预测结构: alphafold.ebi.ac.uk 按 UniProt accession 下载 PDB (B 因子列 = pLDDT)。
3. AlphaFold Server 自预测: 复杂体系 (含配体/多链) 或新序列; 提交 FASTA + 配体 SMILES → 数小时出结果。
4. ColabFold 本地化批量: 研究性批量预测 + mutimer (免费 Colab GPU)。

⑮ 实操 B: 结构质量检查清单 (对接前必做)

PyMOL 命令速查

spectrum b, rainbow

按 pLDDT (B因子) 着色: 蓝好红差

select resn HOH, resn HOH

挑出结晶水 (对接前删或保留关键水)

fpocket 找口袋 (命令行)

fpocket -f target.pdb

输出各口袋 alpha-sphere 集合与 druggability 分数 (>0.5 优先)

- 检查口袋区: 残基侧链完整? pLDDT 是否 >85? 口袋是否被 tag/膜环境占据?
- 共晶配体在位 → 提取「参照配体」定义对接盒子 (比纯几何口袋更准)。
- 需要的预处理: 加氢 (pH 合适质子化)、补缺失环 (Prime/Modeller)、二硫键核对。

⑯ 第 5 章一页总结

叙事线 (能脱稿讲 3 分钟)

实验解析贵且慢 (X-ray/NMR/Cryo-EM 三件套各有所长) → 传统计算依赖模板 (同源模建/threading/从头) → AF2 用「MSA 协同进化 + Evoformer (三角更新保证几何一致) + IPA (刚体等变) + 端到端 FAPE 损失」在 CASP14 达到实验级精度, AFDB 开放 2 亿结构 → AF3 换扩散模块拿下「蛋白-配体-核酸」全原子复合物 → 逆方向 RFdiffusion + ProteinMPNN 学会造蛋白 → 2024 诺奖收官。对 SBDD: 结构从稀缺资源变为公共设施, 口袋在手, 进入第 6 章。

🔪 常见追问: AF2 会不会取代对接? ——不会。AF3 给「可能的结合姿态」, 对接回答「我的分子放在哪、亲和力和排序如何」; 二者精度口径不同, 管线里互为上下游。

第 6 章 · AI 辅助药物结构设计

- 6.1 基础理论
- 6.2 直接设计 SBDD
- 6.3 间接设计 LBDD
- 6.4/6.5 分子表征
- 6.6/6.7 AI 生成与训练
- 6.8 模型问题

① 分子识别理论的演进

学说	内容	对计算的意味
锁钥学说 Fischer 1894	受体与配体如刚性锁钥精确互补	形状匹配是结合的必要条件（形状互补打分的原型）
诱导契合 Koshland 1958	结合时双方构象相互诱导适配	受体/配体都要柔性处理——对接采样难度的根源
构象选择 (现代综合)	受体本就涨落在多个构象，配体挑「最合适的那个」结合并稳定之	系综对接/多构象口袋（MD 采构象再对接）

② 结合自由能的构成（SBDD 的物理账本）

结合的驱动力（热力学）

$$\Delta G_{\text{bind}} = \Delta H - T\Delta S \approx \Delta G_{\text{静电}} + \Delta G_{\text{vdW}} + \Delta G_{\text{氢键}} + \Delta G_{\text{疏水}} + \Delta G_{\text{去溶剂化}}$$

相互作用	典型贡献	药物设计口诀
氢键（方向性强）	1-5 kcal/mol	要给对方向距离（给体受体的「三明治」）；骨架氢键常是选择性的来源
疏水/去水合	每 CH ₂ ~0.7	口袋疏水空腔要填满——logP 与活性的老朋友
静电/盐桥	强但需去溶剂化补偿	水相中净收益有限，别迷信电荷
范德华	密集堆积的净和	形状互补越好越多点接触
π-π / 阳离子-π	1-3	芳香环的隐藏加分项
熵（平动/转动/构象）	-TΔS 不利	刚性分子预组织占便宜（可旋转键的代价）

🔪 数量级感：1.36 kcal/mol ≈ 10 倍亲和力（25℃）。把一个氢键做「对」可能白拿 1-2 个数量级——这是先导优化的主战场逻辑。

③ 酶动力学三件套 (模型预测的目标函数)

Michaelis-Menten 方程

$$v = V_{\max} \cdot [S] / (K_m + [S])$$

- K_m : 达到半最大速度的底物浓度 ($\approx$ 亲和力的观测代理); $V_{\max} = k_{\text{cat}} \cdot [E]$ 。
- 抑制类型: 竞争性 ($K_m \uparrow$, V 不变, 底物竞争活性位点)、非竞争 ($V \downarrow$)、反竞争 (两者都变) —— 酶抑制剂大多竞争性 (占口袋)。
- 竞争性抑制剂表观 $K_m = K_m(1 + [I]/K_i)$ —— 抑制常数 K_i 才是「分子与酶的亲和力本身」。

Cheng-Prusoff 方程 ($IC_{50} \rightarrow K_i$ 换算, 建模清洗数据必用)

$$K_i = IC_{50} / (1 + [S] / K_m) \quad [S] = \text{底物浓度}$$

④ 活性指标族谱 (数据清洗时统一到 pK_d/pIC_{50})

指标	含义 / 测定语境	建模用法
K_d / K_i	解离/抑制常数, 热力学最纯 (SPR/ITC 直接给出)	首选标签: $pK_d = -\log_{10} K_d$
IC_{50}	功能半抑制浓度 (依赖实验条件: 底物浓度、温育时间)	统一换算后再入库; 不同靶/实验间勿直接混
EC_{50}/AC_{50}	细胞/功能水平半效浓度	ADME 渗透与靶结合共同作用, 回归分开建模
$K_{\text{on}}/K_{\text{off}}$	结合/解离速率 (动力学), $K_d = K_{\text{off}}/K_{\text{on}}$	滞留时间 $\tau = 1/k_{\text{off}}$ 长常与药效持续性相关 (SPR 时代新维度)

⑤ 配体效率: 比大小分子更公平的标尺

Ligand Efficiency (优化必备)

$$LE = -\Delta G_{\text{bind}} / N_{\text{重原子}} \approx 1.37 \cdot pK_d / N_{\text{HA}} \quad (\text{kcal/mol/重原子})$$

- 经验标尺: $LE \geq 0.3$ 优秀; < 0.25 的先导长大后「虚胖」(加基团涨活性但 LE 掉 $\rightarrow$ 成药性崩)。
- 家族变体: $BEI = pK_i/MW$ (大小归一)、 $SEBot = pK_i/\text{clogP}$ (亲脂归一) —— 优化三角「活性-大小-亲脂」都要效率。

🔪 建模启示: 数据集里混入不同底物浓度的 IC_{50} 是 QSAR 噪声大户 —— 高质量数据集 (如 BindingDB 的 K_d 子集) 宁可小而纯, 不要大而脏。

⑥ 从结构到口袋：SBDD 的第一步 (6.2 上)

结合位点/口袋：蛋白表面可被配体占据的空腔+周围残基。三类：口袋型（球腔，激酶 ATP 口袋）、裂隙型（延长槽，蛋白酶底物缝）、界面型（PPI 平面——最难）。

算法家族	原理	代表工具
几何法	把蛋白埋进三维网格，标记「蛋白内部/表面/溶剂」小球，聚集成簇=口袋 (LigSite ^{CS} 经典三态扫描；POCKET)	LigSite+、fpocket (α 球聚类 + druggability 打分)
能量法	撒探针（甲基/水/芳环）做能量图，低能聚集区=结合热点	SiteMap、FTMap（热点也验证可药性）
模板/知识法	相似结构上的已知配体位点映射过来	GalaxySite、共晶配体直接定位（最可靠）

- 可药性评估：fpocket 输出 DrugScore（体积/疏水比/封闭度组合），>0.5 高潜力；<0.3 常是浅槽/水袋。
- 别忘别构位点：正构口袋「卷不动」时找变构口袋（激酶 DFG-out 口袋是经典——伊马替尼就是别构打法）。

⑦ 结合位点定义三法（对接的输入）

1. 共晶配体法（最准）：取 PDB 复合物的配体坐标，盒子=配体范围外扩 4-6 Å。
2. 残基法：文献/UniProt 注明的催化残基（如 Ser-His-Asp 三联体）为球心 8-10 Å 盒子。
3. 纯几何法：fpocket 第一大口袋中心——无先验时的兜底，但要人工核看。

```
# AutoDock Vina 对接配置文件 (config.txt)
receptor = target.pdbqt           # 已加氢/加电荷的受体
center_x = 12.3 center_y = -4.5 center_z = 8.7 # 口袋中心（共晶配体质心）
size_x = 22 size_y = 22 size_z = 22          # 盒子尺寸 (Å)，盖住口袋+余量
exhaustiveness = 32                 # 采样强度（默认8，重要任务用32）
```

🔪 盒子艺术：太小 → 漏掉正确姿态；太大 → 噪声姿态稀释打分。经验：口袋最大跨度 + 4 Å，且别把相邻次口袋圈进来。

⑧ 对接问题 = 「采样+打分」两连问

给定受体结构和小分子：①<搜索> 在亿万姿态中找出能量低洼处的姿态（采样）；②<评分> 给每个姿态快速打分排序（打分函数）。柔性是难点：配体 3N 个自由度（平动 3 + 转动 3 + 可旋转键），受体再柔性则爆炸。

采样策略	原理	代表软件
系统性搜索	每个自由度离散化后穷举组合+逐步剪枝	Glide（组合展开+打分剪枝）
遗传算法 GA	姿态编码为「基因」（二面角串）→ 种群交叉变异 → 打分选择 → 迭代进化	GOLD、AutoDock 4
增量构造	先放核心片段锚定，再逐片段生长并采样连接键	FlexX、Glide（core-first）
蒙特卡洛/模拟退火	随机扰动姿态按 Metropolis 准则接受劣化跳出局部最优	AutoDock Vina（迭代局部搜索 ILS：扰动+局部最小化循环）
形状匹配预筛	先按形状/药效团特征快速把配体塞进口袋（毫秒级），再精化	Pharmit、ROCS（VS 第一级漏斗）

- 柔性处理层次：配体全柔性（默认） > 受体侧链柔性（指定 2-6 个关键残基；全柔性不可行） > 「软受体」近似（侧链原子碰撞半径缩小） > 多构象系统对接（MD 采的多个受体构象分别对接）。
- 水分子：桥连水常参与氢键网络——保留关键水或「可置换水」打分（WaterMap 思路），其余删除。

⑨ 打分函数三大流派（能量项速记）

流派	公式骨架	代表	特点
力场型	$S = w_1 \cdot E_{vdW} + w_2 \cdot E_{elec} + w_3 \cdot \Delta G_{desolv}$	AutoDock 4	物理可解释；去溶剂化项粗糙
经验型	$S = \sum w_i \cdot f_i$ (氢键数, 疏水接触, 芳香堆积, 转动熵罚...), 权重由实验结合能回归	GlideScore、ChemScore、Vina（分段经验势）	快而均衡，VS 主力
知识型	从 PDB 复合物统计「原子对接距离偏好」（-log 频率 = 统计势）	PMF、DrugScore	不需要拟合结合能；对姿态敏感
ML/DL 型	端到端学习「对/错姿态」（分类）或 ΔG （回归）；口袋-配体 3D 表征	GNINA CNN、 $\Delta\Delta G$ 网络	排序能力强；跨靶泛化待证

🔪 打分函数三大能力（SPDS，考试原话）：采样能力（能不能把对的姿态放进前几名）、打分能力（放进来后能不能排第一）、筛选能力（库筛选时能不能把活性分子富集到前排）——没有一个函数三者通吃，所以要共识打分（多个函数投票/排名融合）。

⑩ AutoDock Vina 实操七步 (跑通=入门 SBDD)

1. 受体准备: PDB 删水 (保留关键水另说) → 加氢 (pH 质子化, His 显电性要检查) → 存 pdbqt (AutoDockTools 或 Meeko/MGL 工具链; 收费软件如 Glide 用 Protein Prep Wizard 更细)。
2. 配体准备: SMILES → 3D + 能量最小化 (RDKit/Meeko; 注意互变异构体与手性!) → pdbqt。
3. 盒子定义: 按共晶配体/催化残基/口袋中心 (见 P35)。
4. 对接: `vina --config config.txt --out out.pdbqt; exhaustiveness 8 起步、32 加严`。
5. 结果解读: 输出 9 个构象 + 打分 (kcal/mol, 越负越好; 经验: -6 可用, -8 强, -10 注意假阳性)。
6. 目检 (不可跳过): PyMOL/ChimeraX 看——盐桥/氢键方向对吗? 口袋填满吗? 与共晶配体模式一致吗? 有没有「露在外面」的极性基团没伴侣?
7. 可靠性自查: 把共晶配体抠出来重新对接 (redock), RMSD < 2 Å 说明受体+盒子+参数靠谱——否则先修流程再筛库。

批量对接一个库 (shell 思路)

```
for lig in ligands/*.pdbqt; do
  vina --receptor rec.pdbqt --ligand $lig --config config.txt --out out/$lig --config config.txt --out out/$(basename $lig)
done # 再解析打分列排序 + 按骨架聚类去冗余
```

⑪ 对接结果的「防坑」清单

坑	症状与对策
打分 ≠ 活性	打分只解释部分 ΔG ; 跨分子族比较更不可靠——用「同系列相对排序」心态使用
假强结合	柔性长链分子「贴壁」刷分; 目检+LE 惩罚可滤
质子化错误	His/Asp/Lys 状态错 → 静电全错; 用 PropKa/H++ 检查
忽略互变异构/互变	同一分子不同互变体活性差百倍; 枚举主导互变体再对接
只用一个受体构象	口袋开合态不同结果迥异; 多构象系综对接 + 共识

🔪 AI 落点回顾: GNINA 的 CNN 打分重排 Vina 姿态常能提升富集; AF3/扩散生成直接产「口袋内分子」——对接从「终点裁判」变「中场过滤」, 但目检与实验仍是终审。

⑫ 虚拟筛选 (VS) 五级漏斗 (工程化 SOP)



- ★ 富集因子 EF: 前排命中活性分子的比例提升倍数; ROC-AUC 也可量化——验证流程好坏先做 redock+已知活性分子回掺 (DEKOIS/DUD-E 集就是干这个的)。
- ★ 共识打分: 取 Vina+Glide+GNINA 等多函数排名的几何平均/投票, 稳健优于单一函数。
- ★ PAINS/Brenk 预警: 假阳性惯犯 (反应活性基团、聚集剂、荧光干扰) 先剔除——不剔等于给实验组埋雷。
- ★ 库选择: 真正可买 (in stock)、可合成 (make-on-demand, Enamine REAL ~10⁹) 优先; 「纸上分子」再好也白搭。

⑬ FBDD 片段药物设计 (小而美的路线)

环节	要点
片段库	Rule of 3: MW ≤ 300、HBD/HBA ≤ 3、cLogP ≤ 3、RB ≤ 3; 多样性骨架、高溶解度、可拼接化学柄
筛选技术	SPR (表面等离子共振: RU 信号曲线拟合 $k_{on}/k_{off} \rightarrow K_D$, 免标记、金标准); NMR (¹ H- ¹⁵ N HSQC 化学位移扰动定位结合位点); X-ray 浸泡 (共晶直接看); DSF (热位移初筛); ITC (量热金标准但耗样)
优化三式	生长 (向空腔延长) > 连接 (两个片段共价拼接, beware 连接熵) > 合并 (重叠片段融合)
成败手筋	片段结合弱 (mM) 但 LE 高——优化的起点质量看 LE 不看绝对活性; 明星结局: 维莫非尼 (BRAF ^{V600E} , 片段→2011 上市)

🔪 FBDD 与 VS 的选择逻辑: 口袋深而可药 → 经典 VS; 口袋浅/flat、或靶点全新无配体先验 → 片段法+结构引导生长; 两条路最终都汇入「结构-SAR-优化」循环。

⑭ 什么时候走间接路线 (LBDD)?

- 靶标无结构、AF2 置信度低 (浅 MSA/膜蛋白环区); 但有一批已知活性配体 (文献/专利/内部数据)。
- 核心信念: 结构相似 $\Rightarrow$ 性质相似; 共享药效特征 $\Rightarrow$ 共享活性。

⑮ 药效团模型: 把「活性共识」写成 3D 模板

定义: 与靶标结合并触发活性所需的特征元素及其空间排布 (距离/角度约束)。

特征元素 (六正一负)	说明
氢键供体 HBD / 受体 HBA	方向矢量约束 (不只位置, 还有朝向)
疏水中心 H / 芳香环 RA	脂肪疏水团 / 平面芳香体系 (π 作用)
正电荷 PI / 负电荷 NI	离子化基团 (盐桥伙伴)
排除体积 Exclusion	「禁区」球: 配体不能伸进蛋白实体——提高特异性

- 构建流程: 活性分子集 (去冗余、多构象生成 OMEGA/Confab) $\rightarrow$ 共同特征对齐 (灵活叠合) $\rightarrow$ 特征+距离约束的假设图。
- 验证: 回筛已知活性 (应富集) + 掺入诱饵库 (DUD-E) 看富集因子; 区分力差的假设要删特征。
- 应用: 3D 数据库检索 (Pharmit 网页版千万级库秒搜) $\rightarrow$ 命中即「药效团匹配的新骨架」——骨架跃迁利器。
- 工具: LigandScout (结构 $\rightarrow$ 药效团半自动)、Phase (Schrodinger)、MOE、开放工具 PharmaGist。

经典例子: ACE 抑制剂三特征药效团 (教科书案例)

ACE 活性位点要求: ① 锌配位供体 (巯基/羧基氧, 对应巯基丙氨酸/普利类的 SH 或磷酸氧); ② 氢键受体 (与 His 残基, 对应酰胺羰基); ③ 负电中心 (与 Arg/Lys 阳离子结合, 对应末端羧基)。卡托普利 $\rightarrow$ 依那普利 $\rightarrow$ 赖诺普利的演化 = 在这三特征框架下「换特征载体」做骨架跃迁与口服性优化——药效团不变、骨架可变。

🔪 药效团 vs 对接: 药效团「从配体抽象需求清单」, 轻、快、不需要受体结构; 对接「从受体口袋模拟物理结合」, 重、准、需要结构。实战常用「药效团粗筛 $\rightarrow$ 对接精排」双层漏斗。建模常见坑: 构象生成不充分 (漏掉活性构象) 与特征过拟合 (特征越多召回越低) ——特征数宁少勿多, 先跑通最简模型。

⑩ QSAR 定量构效关系：中心方程与两代方法

QSAR 中心思想

生物活性 = f(结构描述符) 经典 Hansch: $\log(1/C) = a + b \cdot \pi + c \cdot \pi^2 + d \cdot \sigma + e \cdot E_s$

- π =取代基疏水常数 (母体相对值)、 σ =Hammett 电子常数 (吸/给电子)、 E_s =Taft 立体常数——2D 取代基时代三剑客。
- 3D-QSAR: CoMFA 把分子叠合到统一格点, 每格点算立体场/静电场探针能量 → PLS 回归; CoMSIA 场更平滑 (立体/静电/疏水/氢键供体/受体五场)。输出等高图: 直观显示「这里加体积涨活性、那里去电荷掉活性」——改造指南针。
- 现代 QSAR = 描述符 (RDKit 200+) 或指纹 + RF/XGBoost/SVM/NN; CoMFA 精神活在 3D 描述符与 GNN 里。

⑪ QSAR 建模六步 SOP (可作方法学模板)

1. 数据: 同一靶点、同一 (或校正后) 测定条件; 剔除可疑值; 登记单位 (全转 pIC_{50})。
2. 描述符: 理化 (MW/logP/TPSA...) + 拓扑 + 指纹; 初筛 (方差过滤 + 相关性去冗余 + 常数删除)。
3. 划分: scaffold split (第 3 章); 训练:测试 $\approx 8:2$; 训练内再 5 折交叉验证调参。
4. 拟合: MLR (可解释, 描述符少) /PLS (多相关变量) /RF、XGBoost (表格强基线) /NN (数据充足时)。
5. 验证三件套: 内部 q^2 (交叉验证 R^2 , >0.5 及格); 外部测试 R^2_{ext} (>0.6 好); Y 随机化 (打乱标签重建模, 好模型性能应崩塌到随机——防 chance correlation)。
6. 适用域 AD: 预测前检查新分子是否「像训练集」(描述符空间距离/leverage 权限 $h < h^*$ 警戒线); 域外预测必须标注「外推, 可信度低」。

OECD QSAR 验证五原则 (监管口径, 必背)

- ① 有明确定义的终点; ② 有明确算法; ③ 有适用域陈述; ④ 有内部稳健性+预测力评价指标 (q^2/R^2_{ext}); ⑤ 尽可能给出机理解释 (哪些描述符对应什么相互作用)。

🔪 AI 视角: QSAR 就是药学版监督学习; GNN-QSAR 把「人工描述符」换成「自动表征」, 但 OECD 五原则对深度模型同样适用——尤其是适用域 (分布外) 那条, 深度模型更容易踩。

⑱ SMILES 语法六规则 (6.4 核心, 动手必会)

规则	写法	例
原子	元素符号, 脂肪族大写/芳香小写	C 饱和碳、c 芳香碳、N/n、O/o、S/s
键	单键省略; = 双; # 三; : 芳香	C=C、C#N (腈基)
分支	括号 ()	CC(=O)O 乙酸: 主链 C-C, 分支 =O
环	开环/闭环配对数字	c1ccccc1 苯; C1CCCCC1 环己烷; 螺/稠环用不同数字对
立体	@ / @@ 手性; /\ 双键 E/Z	N[C@@H](C)C(=O)O L-丙氨酸; F/C=C/F 反式
电荷/同位素	[] 包裹	[NH4+], [O-]C(=O)C 醋酸根

同一分子多种合法写法 (起点任意、方向任意) → 这是「数据增强」来源, 也是序列模型要解决的「一物多写」问题 (规范 canonical SMILES 缓解)。

⑲ 分子指纹算法解剖 (6.4/6.5)

指纹	算法	用途特点
MACCS	166 条人工定义的结构键 (有无羰基、有无环...)	快、可解释; 粗筛与相似度基线
拓扑/路径	枚举所有原子的 2-7 键路径子结构 → 哈希置位	Daylight 传统相似性检索
ECFP/Morgan	① 每原子初始标识 (元素+度+电荷等哈希) ② 迭代 k 轮: 原子吸收邻居标识集合再哈希 (半径 k 的子结构唯一码) ③ 按出现度去重 ④ 折叠到 2048/1024 位	半径 2 → ECFP4; 子结构敏感、VS 与骨架分析标配; 碰撞少
药效团指纹	三元组: 三特征两两距离分箱	药效团多样性度量

Tanimoto 相似度 (指纹标配)

$$T = c / (a + b - c) \quad ; \quad a, b \text{ 各自置位数, } c \text{ 共同置位数} \quad (>0.85 \text{ 视为近同物, 常作去冗余阈值})$$

🔪 指纹三用途: 相似检索 (找近邻)、去冗余 (聚类挑代表)、作模型输入 («老派但难打败» 的基线——新模型先跟 ECFP+RF 比划)。


②0 3D 与描述符家族 (6.5)

- 构象：一个分子多个 3D 构象 (ETKDG/OMEGA 生成)；3D 任务先问「用哪个构象？」(单构象/系综平均)。
- 形状描述符 USR：分子形状压缩为 12 个数——相对质心的距离分布 (均值/方差/偏度) × 4 类原子 (全部/负电/正电/疏水)；USRCAT 加药效团权重。极快 (形状相似检索 ROCS 同思路)。
- 理化描述符 (QSAR 燃料)：MW、cLogP (疏水，口服第一变量)、TPSA (极性表面积，渗透性变量)、HBD/HBA、RB (构象熵罚)、pKa、Fsp³ (芳环饱和度，「类药三维性」)。
- 选择口诀：快筛→指纹；构效解释→理化描述符；构象敏感→3D/形状；端到端→图。没有全能表征，按任务选 (No Free Lunch)。

②1 RDKit 实操合集 (本章工具箱)

```
from rdkit.Chem import Descriptors, Crippen, rdFingerprintGenerator
mw = Descriptors.MolWt(m); logp = Crippen.MolLogP(m) # 理化描述符
gen = rdFingerprintGenerator.GetMorganGenerator(radius=2, fpSize=2048)
fp = gen.GetFingerprint(m) # ECFP4 (2048 位)
from rdkit import DataStructs
DataStructs.TanimotoSimilarity(fp1, fp2) # 相似度 → 骨架聚类去冗余
```

②2 第 6 章总装图 (背完这一张=会用整章)



🔪 章节地图：6.1 理论 (P33-34) → 6.2 直接设计 (P35-38) → 6.3 间接设计 (P39-40) → 6.4/6.5 表征 (P41-42 上) → 6.6-6.8 的「生成与训练」在第 8 章方程级展开 (P46-53)，这里不重复。

第 7 章 · AI 药物递送系统设计

- 7.1 为什么 AI
- 7.2 处方设计
- 7.3 材料筛选
- 7.4 机制研究
- LNP 案例

① 为什么好分子还需要递送系统 (7.1)


- ★ 成药性四大坑：溶解度差（BCS II/IV 类占新化学实体大半）、半衰期短、组织靶向差、毒性窗窄。
- ★ DDS 定义：调控药物释放速率与空间位置的制剂技术平台——让「到位、适量、适时」。
- ★ 临床成功范式：多柔比星脂质体（Doxil，降低心脏毒性）、亮丙瑞林微球（一月一针）、mRNA-LNP 疫苗（递送即药效）。

② DDS 载体类型速查 (特征+场景)

载体	组成/机制	适用
脂质体	磷脂双分子层囊泡（内水相+双层）；PEG 化延长循环（隐形脂质体）	毒性大化疗药；两性药物装载
LNP 脂质纳米粒	可电离脂质+胆固醇+辅助脂质(DSPC)+PEG 脂质 四组分（~pH 依赖电荷翻转：循环中性、内体正电）	mRNA/siRNA 核酸药物首选
聚合物纳米粒/微球	PLGA 等降解材料包埋；微球可实现周/月级缓释	多肽长效制剂（精神/激素类）
胶束/纳米晶	两亲自组装增溶 / 纯药纳米化（无载体）	难溶口服药
树状大分子/外泌体	多价精确结构 / 天然囊泡低免疫原	前沿研究载体

智能释放设计：pH 敏感（肿瘤/内体弱酸）、酶敏感（MMP 剪切）、还原敏感（GSH 二硫键）——把病理微环境当「开关」。

③ 处方开发的「高维试错」困境 (AI 切入的逻辑)



🔪 与小分子 AIDD 的区别只在特征工程：这里的「分子」是配方（组分向量）与材料描述符（脂质 pKa、尾链长度/不饱和度、HLB、T_m），模型武器库完全共享。

④ AI 辅助处方设计 (7.2) 双引擎

引擎	输入→输出	怎么做 / 效果
正向代理模型	配方 (脂质摩尔比、流速、温度、浓度) → 性能 (粒径、包封率、释放 $t_{50\%}$ 、mRNA 表达量)	少量实验 (DoE 网格+历史数据) 训 NN/RF; 达到 $R^2>0.8$ 即可虚拟扫参, 替代大半试错
逆向优化	目标性能 → 反推配方	贝叶斯优化 (高斯过程代理+采集函数 EI/UCB 平衡探索利用) 每轮只做最有信息量的 5-10 个实验, 10-20 轮收敛——实验数降一个量级

- 特征进阶: 加入分子动力学模拟量 (脂质堆积参数、膜厚度、内体膜融合能障) 作为「物理描述符」, 小数据下比纯配方表格更稳。
- 闭环形态: 自动化微流控合成 + 在线表征 (DLS 粒径) + BO 决策 = 自驱动制剂实验室。

⑤ AI 辅助新型递送材料筛选 (7.3)

- 可电离脂质案例: 头基×可降解尾链组合化学 → 虚拟库 10^4 - 10^6 ; ML 模型 (pKa、logD、融膜性、毒性端点) 初筛 → 顶层 50-100 合成 → 体内外验证迭代 (mRNA 疫苗脂质的工业路径; 代表分子 DLin-MC3-DMA、ALC-0315、SM-102 均经大量配方优化)。
- 可电离脂质设计三铁律: pKa $\approx$ 6.2-6.6 (循环中性/内体带正电)、尾链可降解酯键 (清除外泄)、锥形几何 (促进六角相 H_{II} 膜融合)。
- 聚合物高通量虚拟筛选: 单体组合库 → 性能预测 (载药量、释放曲线、细胞相容); MD+ML 混合建模降算力。

mRNA-LNP 完整链条 (把 7.2/7.3 串起来)

mRNA (药物) → LNP 四组分配方 (可电离脂质是灵魂) → 微流控快速混合自组装 (流速比=粒径旋钮) → 冻干稳定 → 体内: 载脂蛋白吸附→肝细胞摄取→内体酸化→脂质质子化→膜融合→mRNA 逃逸→核糖体翻译。AI 在「配方寻优」与「脂质设计」两处上岗, 把运气变成搜索问题。

⑥ AI 辅助递送机制研究 (7.4) 四问

问题	数据 / 现象	建模方案
细胞摄取多少?	流式/荧光定量摄取 + 颗粒描述符 (尺寸、Zeta、疏水、形变性)	回归模型→「纳米-摄取」规律 (纳米信息学); 指导颗粒设计窗
蛋白冠是什么?	进入血液后纳米粒表面吸附蛋白冠 (决定被谁识别清除/靶向)	冠组成预测 (颗粒性质→蛋白吸附谱); 反向利用冠做靶向 (冠工程)
过 BBB 吗?	血脑屏障穿透数据 (logBB、体内暴露)	分类/回归模型; 与第 9 章 ADMET-D 维度共享方法
体内去哪儿?	biodistribution (各器官荧光/质谱定量)	多输出回归+PK 模型 (QSPkR); MPS 虚拟人群模拟

- 溶酶体逃逸是核酸递送卡脖子步骤: 质子海绵效应 (可电离脂质缓冲) + 膜融合——AI 用 MD+活性学习搜索「高融膜」脂质。
- 免疫清除: PEG 抗药性 (anti-PEG IgM 加速清除) → 替代聚合物 (聚草酸酯、多肽 PEG 替代物) 虚拟筛选新方向。

⑦ 纳米制剂表征五件套 (读文献/报数据的标准栏)

参数	测法	合格线 (LNP 供参考)
粒径	DLS 动态光散射 (强度加权)	50-100 nm (肝摄取窗口)
PDI 分散指数	DLS 拟合	<0.2 (>0.3 体系不均一, 数据不可信)
Zeta 电位	电泳光散射	ζ >30 mV 稳定分散; LNP 近中性最佳 (+30 易毒性)
包封率 EE	SEC/超滤分离游离药后定量	>80% (核酸 RiboGreen 法)
形态	TEM/cryo-EM	球形/核壳结构确认

⑧ 第 7 章总结 (三行背完)

记忆钩子

- ① 为什么: 处方=高维试错, AI 代理+贝叶斯优化降一个数量级实验量;
- ② 三战场: 处方逆向设计 (7.2)、材料虚拟筛选 (7.3, LNP 脂质 $pK_a \approx 6.5$ 等三铁律)、机制数据建模 (7.4 摄取/蛋白冠/屏障/分布);
- ③ 本质: DDS-AI = 小分子 AIDD 方法论在「配方-材料特征空间」的平移。

🔪 科研选题提示: DDS 数据天然小样本 (一次实验一天), 主动学习/迁移学习是必修课; 与制剂学合作者组队时, 你的价值是「把他们的试错历史变成模型」。

第 8 章 · AI 在分子生成和合成中的应用

8.1 概述

8.2/8.3 表征

8.4/8.5 生成家族

8.6 逆合成概述

8.7 模板法

8.8 无模板


① 为什么「生成」是终极武器 (8.1)

- ★ 类药化学空间估计 10^{60} 量级；最大实体库 $\sim 10^9$ ——筛选是被动的（只能挑现成的），生成是主动的（按需创造）。
- ★ 生成任务数学化：从分布 $p(x)$ （训练库分子）学采样，并偏移 to 条件分布 $p(x|目标)$ ——目标=活性、选择性、ADMET、SA、可专利性。
- ★ 与筛选的成本对比：VS 命中要「运气撞上」；生成直接「朝着性质的方向」构造。

② 评价指标体系（审稿人/面试必问）

指标	定义	合格线 / 备注
Validity	生成串能被 RDKit 解析为合法分子的比例	SMII-ES 模型 >90%；SELFIES 理论 100%
Uniqueness	去重后比例（考察模式坍缩复读）	>95%；低=模型只学会几种套路
Novelty	不在训练集的比例	>80% 常见；低≠坏（活性类似物本来就稀疏）
目标命中率	满足多目标性质的分子占比	看任务：对接打分前 1%、QED>0.5 且 SA<4 等
FCD	Fréchet ChemNet Distance：与训练集的分布距离	衡量「整体像不像药」，防跑偏生成垃圾
内部多样性	两两指纹距离均值	别生成一万条「同一骨架的排列组合」

③ 生成器在管线里的位置（先定坐标再学模型）



- 🔪 「多目标」的数学外衣： $\max \sum w_i \cdot f_i(x)$ （加权和，REINVENT 式）或帕累托前沿（NSGA-II 遗传算法）；权重即研发策略——把「要什么」写成权重是化学家在生成管线里最大的话语权。

④ SMILES 的生成陷阱 (8.2)

- 语法自由但化学不自由：括号不配对、环标签未闭合、五价碳——逐字符采样的模型稍走神就产出非法串 (Validity 掉到 60-80%)。
- 数据增强是免费午餐：一个分子枚举 ~100 种等价写法，预训练语料瞬间 $\times N$ 。
- canonical 化 (唯一规范写法) 便于查重与统计，但会让模型偏置——增强与 canonical 各有场景。

⑤ SELFIES: 把化学合法性写进语法 (8.3 亮点)

问题	SMILES	SELFIES
任意字符串变异	大概率解析失败	解码后 100% 合法 (鲁棒语法)
原理差异	字符=原子/括号, 组合自由	符号自带「状态机」: 当前价态决定下一个符号如何解释 (超价时自动转 [Ring]/[Branch] 语义)
最适合谁	—	遗传算法/VAE 潜空间解码 (随机扰动不废)
代价	简短通用	串更长、生态较小 (在涨)

实践建议：预训练与人类交互用 SMILES (生态)，VAE/GA 内部解码用 SELFIES (稳)，两端转换库现成。

⑥ 图与 3D 表征 (生成的另一条路)

- 图生成：逐步「加原子/加键」在图上 (MolGAN 一次成图、GraphAF/GraphDF 自回归+流)，免字符串语法问题，但键序后处理要小心。
- 3D 点云生成：直接生成原子坐标+元素 (口袋条件下)：元素分类 + 坐标回归/去噪——扩散模型主场 (P51)。
- 选择逻辑：性质优化 (2D 够) $\rightarrow$ 字符串/图；基于结构的从头设计 (要契合口袋) $\rightarrow$ 3D。

🔪 表征决定模型上限：SMILES 学「语言统计」，图学「拓扑」，3D 学「几何互补」——口袋里的生成必须上 3D，这是 2022 年后生成领域的主航道。

⑦ 自回归语言模型：把分子当「话」说 (8.4 上)

自回归分解 (链式法则)

$$p(x) = \prod_{t=1 \dots T} p(x_t | x_{<t}) \quad \text{逐 token 预测下一个原子符号}$$

- ★ RNN/LSTM 时代：隐状态携带「写到哪了」的记忆；SMILES 语料 (ChEMBL/ZINC) 预训练即得「分子语法」。
- ★ Transformer 时代 (MolGPT 等)：因果掩码自注意力 + 位置编码；规模法则成立——库越大预训练越强，还能「提示 (prompt)」式条件生成 (给属性前缀)。
- ★ 采样温度 T 控制多样性： T 低 $\rightarrow$ 保守复读， T 高 $\rightarrow$ 狂野犯错；实战 $T \approx 0.7-1.0$ 扫描。

⑧ 预训练-微调范式 (小数据药学的救星)

1. 预训练：百万级通用分子库学「化学语法+常见骨架」。
2. 微调：换到目标库 (某靶点活性分子) 继续训练——分布对齐，几百个分子也够。
3. RL/条件化：再按性质目标调整采样 (下一页 REINVENT)。
4. 同款范式也支撑蛋白语言模型 (ESM) 与逆合成 Transformer——一次学会，处处使用。

HuggingFace 三行得到一个分子 GPT (教学用)

```
from transformers import AutoModelForCausalLM, AutoTokenizer
```

```
tok = AutoTokenizer.from_pretrained('ibm-research/MolGen-xl') # 1.1亿 ZINC 预训练
```

```
out = model.generate(**tok('C1=CC=CC=C1', return_tensors='pt')) # 苯环开头，续写分子
```

采样策略三旋钮 (调多样性的手柄)

- 温度 T : logits/ T 后 softmax—— $T < 1$ 保守 (复读训练集), $T > 1$ 激进 (语法崩坏), 扫 $0.7 \rightarrow 1.2$ 找「多样性-有效率」甜点。
- Top-k / Top-p (核采样): 每步只从概率前 k 个 (或累计 p) 里抽——过滤长尾乱码, 生成 SMILES 的默认保险。
- 重复惩罚: 抑制同一 token 连发 (防苯环标签复读)。

分子语言 $\neq$ 自然语言三差异: ① 语法刚性 (一字错=分子废, 严格校验不可省); ② 一物多写 (SMILES 增强特有权重); ③ 语义外部性 (活性/毒性不在字符串里, 须外接打分器 QSAR/对接才有方向感)。

🔪 自回归的先天缺陷: ① Exposure bias (训练看真值前缀, 生成看自己的——错一步步错); ② 长分子衰减; ③ 采样无「全局目标感」 $\rightarrow$ 需 RL 补 (P50)。

⑨ VAE: 给化学空间装「坐标轴」(8.4 中)

结构: 编码器 $q_{\phi}(z|x)$ 把分子压成连续向量 z (潜变量) $\rightarrow$ 解码器 $p_{\theta}(x|z)$ 从 z 重建分子。

ELBO 目标 (推导骨架: $\log p(x) \geq \text{ELBO}$)

$$L = E_{q(z|x)} [\log p(x|z)] + \beta \cdot (-\text{KL}(q(z|x) \parallel p(z))) \quad p(z) = N(0, I) \text{ 先验}$$

- ★ 第一项=重建准 (解码不还原丢失信息); 第二项=潜空间规整 (KL 拉向标准正态 $\rightarrow$ 连续可插值)。
- ★ 重参数化技巧: $z = \mu + \sigma \odot \varepsilon$, $\varepsilon \sim N(0, I)$ ——把采样挪出计算图, 梯度能回传 (VAE 可训练的关键一步)。
- ★ β -VAE: 调 β 换取「解耦」的潜维度 (某维 $\approx$ 大小、某维 $\approx$ 环数 $\cdots$) ——化学可解释彩蛋。

⑩ 潜空间优化: VAE 真正的价值

玩法	操作	意义
插值	z_A 、 z_B 之间线性取点解码	两活性分子间的「化学渐变带」——骨架跃迁线索
梯度上升	预测头学 $z \rightarrow$ 性质, ∇_z 上山后解码	直接「滑向」更优性质区域
贝叶斯优化	z 空间高斯过程代理+EI 采集	黑箱目标 (对接打分) 也适用——ChemVAE 玩法

- 里程碑 ChemVAE (Gómez-Bombarelli, ACS Cent. Sci. 2018): SMILES-VAE 首次证明潜空间连续可优化 (logP/QED/SA 三性质演示), 开启生成式药物设计时代。
- 短板: 解码器不完美 (优化到的 z 解码不出或解码变样) ——「潜空间骗术」, 需解码多次+过滤兜底; 优点是训练稳、可控性最好。

🔪 科研提示: 先训 VAE 学「化学合法流形」, 再在外层套任意优化器 (BO/CMA-ES/梯度) ——这套「内表征+外优化」架构是许多组的第一篇 AIDD 论文。

⑪ GAN: 对抗的博弈 (8.4 下)

极小极大目标

$$\min_G \max_D E_{x \sim \text{data}} [\log D(x)] + E_{z \sim \text{noise}} [\log(1 - D(G(z)))]$$

- 生成器 G 造假 (从噪声 z 出分子), 判别器 D 鉴真 (真库 vs 生成) ——互相进化到「以假乱真」。
- 分子版: ORGAN (SMILES+RL 奖励混合目标)、MolGAN (图生成, WGAN-GP 稳训练+针对性奖励)。
- 老毛病在分子上更明显: 训练不稳 (模式坍缩=只出几种骨架)、难评价——现在多作对比基线而非主力。

⑫ RL: 目标导向的瑞士军刀 (REINVENT 流水线)

策略梯度 (REINFORCE)

$$\nabla J(\theta) = E[R_t \cdot \nabla_{\theta} \log \pi_{\theta}(a_t | s_t)] \quad \text{奖励强化「带来高分的动作序列」}$$

1. 状态/动作: 已写前缀 / 下一个字符 (或图上「加原子/加键」——GraphAF)。
2. 奖励设计 (成败在此): $R = \sum w_i \cdot s_i$ —— s_i = 合法性、预测活性 (QSAR/DTA)、对接打分、QED、SA、新颖性 (与已知库距离) ……权重=研发策略。
3. REINVENT (阿斯利康) 三段式: 先验 (库预训练自回归) → 代理评分卡 (快速模型代打分, 免得每步跑对接) → RL 微调 + 似然权重防跑飞 (不偏离先验太远)。
4. 迭代闭环: Top 分子送实验 → 数据回填再训代理 → 越代越准 (这是工业界最常用的生成引擎形态)。

🔪 奖励作弊 (reward hacking) 警示: 模型会找到「刷高代理模型但实际无效」的分子 (对抗样本) ——所以代理要定期用新实验数据校准, 且多代理交叉。

⑬ 扩散模型：先学会「破坏」再学会「重建」

前向加噪 (固定)

$$q(x_t|x_{t-1}) = N(\sqrt{(1-\beta_t)} \cdot x_{t-1}, \beta_t I) \quad t \text{ 步后} \approx \text{纯高斯噪声}$$

反向去噪 (学习)

训练网络 $\epsilon_\theta(x_t, t)$ 预测所加噪声；目标 = $E \|\epsilon - \epsilon_\theta(x_t, t)\|^2$ 生成 = 从噪声逐步「显影」

- 直觉：把「无中生有」拆成千百个「去噪一小步」——每步都简单，连起来就能造复杂结构 (Stable Diffusion 同款引擎)。
- 条件生成：把口袋/蛋白特征作为额外输入 (cross-attention 或引导) → 「按口袋定制分子」。

⑭ 3D 口袋条件生成 (当前 SOTA 路线)

模型	生成对象 / 条件	要点
DiffSBDD	口袋 3D 网格/上下文 → 配体原子	把口袋当「图像」做条件去噪；支持 inpainting (保留母核只生成侧链)
TargetDiff	口袋残基点云 → 配体原子坐标+元素	等变 EGNN 去噪网络 (旋转平移不敏感)；原子级条件，采样多样性好；对分子动力学合理性 (Vina 打分、键长分布) 表现强
共性流程	口袋 → N 次采样 → 键序推断 (后处理) → 过滤/对接复检 → 优选	「生成-验证」循环；常用困惑度高的多样性换 hit 富集

- 位置/元素/键序三件套：扩散直接产出坐标与元素，键序由距离规则或独立模型判定 (无键序生成是主要误差源)。
- 等变性：SE(3)-等变网络保证「转着生成也一样」——3D 生成的工程底线。

🔪 四大家族一句话收官：自回归=会说话，VAE=有地图，GAN=能造假，RL=有目标，扩散=会雕塑。现代管线常「预训练自回归/扩散 + RL 目标化」混搭。

⑮ 逆合成分析：合成的「反演问题」(8.6)

- ★ 提出者 E. J. Corey (1990 诺贝尔化学奖)：从目标分子 TM 逆向推到可购买原料——「反向的合成树」。
- ★ 术语四件套：合成子 synthon (理论碎片，带合成极性) / 合成等价物 (真实试剂) / 切断 disconnection (拆哪根键、怎么拆) / FGI 官能团转换 (把 TM 换成「更好切」的等价官能团)。
- ★ 判断好切断的唯一标准：切断处必须对应一个可靠的正向反应 (能在脑子里「正着走一遍」)。

⑯ 切断策略经验法则 (手推功底)

1. 优先拆杂原子键：C-N / C-O (酰胺、酯、醚、胺) → 对应酰化/烷基化，一夜可得。
2. 拆支链点 (分子「瘦身」)：主链保留，侧链接头拆 (SN2/偶联)。
3. C-C 偶联位点：芳基-芳基/芳基-烯基 → Suzuki / Sonogashira / Heck / Negishi (药物化学四大件，逆合成模板库主力)。
4. 活性位点旁官能团转换：酮→烯 (Wittig)、醇→卤 (置换) 先「变形」再切。
5. 对称性利用：对称分子一次切断得两份同原料。

例：对乙酰氨基酚 COCC1=CC=C(NC(C)=O)C=C1 的直觉切断

酰胺键切断 → 对氨基苯酚 + 乙酸酐 (一步酰化，工业现实路线)

AI 做的事：把这个「直觉」变成可规模计算的模板匹配/序列翻译

常备反应模板五件套 (逆合成检索的高频反应)

- ① 酰胺化：胺 + 羧酸 (HATU/EDCI 活化) ——断 C(=O)-N;
- ② Suzuki 偶联：芳基硼酸 + 芳卤 (Pd 催化) ——断芳-芳键;
- ③ SN2 烷基化：伯卤 + 亲核试剂 ——断 C-N/C-O;
- ④ 还原胺化：醛/酮 + 胺 ($\text{NaBH}(\text{OAc})_3$) ——做 C-N 的温和路;
- ⑤ Heck/Sonogashira：芳卤 + 烯/炔 ——做芳-烯/芳-炔键。

药物分子中约一半的键能追溯到这几类反应——模板库覆盖它们，就覆盖了大半药物化学。

🔪 单步逆合成的形式定义：给定产物 SMILES，输出 K 组「反应物集合」+推荐反应类型——本质是「结构到结构集合」的映射学习。

⑰ 单步逆合成：模板 vs 无模板 (8.7/8.8 必考对比)

	基于模板 Template-based	无模板 Template-free
原理	从反应库 (USPTO/Reaxys) 抽取反应模板 (反应中心 SMARTS 泛化); 对产物做模板匹配/相似度检索排序 → 套用前体	seq2seq 翻译: 产物 SMILES → 反应物 SMILES (SCROP 用 Transformer); 或 Graph2Graph (G2Gs 直接图到图)
数据	USPTO-50k (5 万反应, 标准基准) / USPTO-full 480K / Pistachio	同上 (端到端免抽模板)
优点	化学可靠 (模板=真实反应泛化)、可解释 (指认反应类型)、可控 (限定绿色/廉价反应)	覆盖广 (能外推模板库没有的反应模式)、部署简单
缺点	覆盖度受模板库限制 (新反应类型无解); 模板爆炸 (泛化程度两难)	可能产出化学不合理的「反应物」(需严格校验官能团兼容性); 黑盒
代表	RetroSim (相似度检索)、NeuralSym (分类模型)、半模板 GLN (先猜反应中心再补环境)	SCROP (Transformer, USPTO-50k top-1 ~54% 量级)、G2Gs

⑱ 多步规划：搜索问题 (8.6 下)

- 搜索树：节点=中间体，边=单步反应，根=目标，叶=可购原料 (目录：Enamine/eMolecules 价格库)。
- 算法：BFS/DFS/束搜索 (浅层可用); A* (Retro*, 神经网络估值函数引导, 保证最优性); MCTS 蒙特卡洛树搜索 (选择-扩展-仿真-回传, 探索/利用平衡, AlphaGo 同款); 成本函数=路径长度+原料价格+反应成功率。
- 开放工具：MIT ASKCOS (网页可用)、IBM RXN for Chemistry——输入目标 SMILES 即出整树方案。

第 8 章总结 + 科研闭环

生成解决「从 0 到 1 造分子」(四家族：自回归/VAE/GAN+RL/扩散)，逆合成解决「造得出吗、怎么造、多少钱」(模板/无模板 + 树搜索)。完整闭环 = 生成 → 过滤 → 打分 → 逆合成可合成性检查 → 合成 → 实测 → 回灌——英矽智能 Chemistry42 的骨架就是它 (第 10 章对账)。

🔪 上机：把一个生成分子贴进 ASKCOS 或 IBM RXN，看它给的路线与价格——「可合成性」从抽象概念变成一次真实查询，这是生成项目最容易被忽略的收尾。

第 9 章 · AI 预测药物性质

9.1 药物-靶标亲和力

9.2 类药性

9.3/9.4 ADMET

DTA 深度模型

工具实操

① 测亲和力的三台仪器（数据是怎么来的）

方法	原理	读数与特点
SPR 表面等离子共振	配体流过固定在芯片的蛋白，折光率变化实时记录结合/解离曲线	免标记、动力学 (k_{on}/k_{off})， $K_D=k_{off}/k_{on}$ ；金标准但需大容量蛋白
ITC 等温滴定量热	逐滴注射配体测热功率	一次实验得 K_D 、 ΔH 、化学计量 n （热力学全家桶）；耗样多
酶活/细胞功能	底物反应速率抑制百分比曲线	IC_{50} （依赖底物浓度/温育条件）——数据最多的来源，也是噪声最多的来源

② 热力学换算（手算保命题）

结合自由能与平衡常数

$$\Delta G^\circ = R \cdot T \cdot \ln K_d = 2.303 \cdot R \cdot T \cdot \log_{10} K_d \rightarrow 25^\circ\text{C}: \Delta G \approx 1.36 \times \log_{10} K_d (\text{nM})$$

kcal/mol

★ 口算例： $K_d=1 \text{ nM} \rightarrow \Delta G \approx 1.36 \times (-9) \approx -12.3 \text{ kcal/mol}$ ；改善 10 倍亲和 = 多挣 1.36。

★ 建模标签： $pK_d/pIC_{50} = -\log_{10}$ （回归目标要正态化）； ΔG 是把不同实验拉到同一物理标尺的桥梁。

★ 数量级地图：mM 片段（LE 高） $\rightarrow \mu\text{M hit} \rightarrow \text{nM lead} \rightarrow \text{pM 抗体级}$ 。

③ 亲和力数据三大库（建模燃料）

库	内容	建模注意
BindingDB	~240 万化合物-靶标亲和（整合文献 $IC_{50}/K_i/K_d$ ）	按测定类型分子集建模； K_d 子集最纯
ChEMBL	~240 万化合物、2 万靶标的药理活性（含文献链接）	标准值/单位注释好；QSAR 首选
PDBbind	复合物结构+结合数据（~K 受体）	「结构+亲和力」配对，打分函数/对接校准专用
KIBA / DAVIS	激酶全覆盖矩阵（多靶同测）	DTA 模型标准基准（KIBA score 统一标尺）

🔪 数据清洗第一刀： IC_{50} 在不同底物浓度下不可直接混——用 Cheng-Prusoff (P34) 换算或按测定条件分层。

④ 路线 A: 基于结构 (精度阶梯)

方法	原理	精度/成本
对接打分	姿态+经验函数 (第 6 章)	快 (秒级); 排序误差 2-4 kcal/mol, 跨分子不可靠
MM/GB(PB)SA	对 MD 轨迹取样, $\Delta G_{\text{bind}} \approx E_{\text{MM}}(\text{复合物-受体-配体}) + \Delta G_{\text{溶剂化}}(\text{GB/PB 近似}) - T\Delta S$	中 (小时级); 同系列相对比较可用
FEP/ABFE 自由能微扰	热力学循环: $A \rightarrow B$ 变换在蛋白环境与水溶液各算一次 ΔG ; $\Delta\Delta G = \Delta G_{\text{蛋白}}(A \rightarrow B) - \Delta G_{\text{水}}(A \rightarrow B)$	高 (天级、贵): 精度 ~ 1 kcal/mol, 足以指导「改哪个取代基」; Schrödinger FEP+ 工业标配

热力学循环直觉: 同一个化学变换, 环境差异=结合能差异

$A \cdot \text{蛋白} \rightarrow (\Delta G_1) B \cdot \text{蛋白} \quad \Delta\Delta G_{\text{bind}} = \Delta G_1 - \Delta G_2$

$A \cdot \text{水} \rightarrow (\Delta G_2) B \cdot \text{水} \quad \# \text{ 逐窗微扰 } \lambda: 0 \rightarrow 1 \text{ 插值模拟}$

⑤ 路线 B: 基于配体 (QSAR 家族)


- 同靶标家族 (激酶/GPCR) 内数据充足时: 指纹+RF/XGBoost 回归 pIC_{50} , 秒级万分子; 受适用域限制 (新骨架勿信)。
- 相似性最近邻 (k-NN on ECFP): 项目冷启动最诚实的基线。

⑥ 路线 C: 深度学习端到端 DTA (9.1 重点)

- ★ 输入=配体 (SMILES/图) + 蛋白 (氨基酸序列), 输出= pK_d ——免结构、跨靶标, 适合「新靶没结构、序列已知」场景。
- ★ 进化线: KronRLS/SimBoost (相似度核/特征工程) $\rightarrow$ DeepDTA (CNN) $\rightarrow$ GraphDTA (分子图 GIN/GAT + 蛋白 CNN) $\rightarrow$ 注意力/预训练蛋白语言模型版。
- ★ 使用边界: 胜在覆盖面 (几十万对数据), 单点精度仍不如同靶 QSAR + 好结构; 用作「广域初筛/排序」。

🔪 选择树: 有结构+要精修 $\rightarrow$ FEP/MMGBSA; 同靶数据多 $\rightarrow$ QSAR; 新靶无结构+要大范围排序 $\rightarrow$ DTA; 没数据 $\rightarrow$ 对接+目检兜底。

⑦ DeepDTA 结构逐层拆 (上机常客)



- 设计巧思: 蛋白与配体对称双塔——各自学「语言」, 拼接后才交互 (早交互版性能反而易过拟合)。
- 卷积核宽度 4-8: 恰似捕捉官能团大小; 池化提供小平移不变性 (SMILES 写法扰动鲁棒一点)。
- GraphDTA 升级点: 配体塔换成 GIN/GAT (分子图, 第 3 章), 序列塔保留 CNN——图归纳偏置带来稳定提升。

⑧ DTA 数据泄漏专题 (这个领域的天坑)

泄漏姿势	后果	正确做法
随机划分相互作用对	同一配体 (或同一蛋白) 横跨训练/测试 → CI 虚高 0.9+, 实际 0.5-0.7	「冷启动」划分: 留配体 / 留靶点 / 双留
同盐/互变体不同 SMILES	测试集其实是训练集的别名	规范 canonical + InChIKey 去重
时间泄漏 (新论文数据混入训练)	未来信息穿越	按发表/专利年份划分

评价指标与复现要点 (跑通 DeepDTA 的清单)

- CI 一致性指数: 随机抽一对样本, 模型给更高分的是否真的活性更强——DTA 回归的标准指标 (Davis/KIBA 基准 0.85+ 算好)。
- MSE / RMSE (pK_d 单位); 分类化阈值 (如 $pK_d > 7$ 为活性) 时再看 AUC。
- 复现要点: 词表按字符级 (长度 64); 三个卷积块 filters 32/64/96, kernel 4/8/12; batch 256、Adam $1e-3$; KIBA 用「随机+冷靶」两种划分各报一次。

🔪 读 DTA 论文先看什么: ① 划分方式 (random / cold-drug / cold-target); ② 指标 (CI、MSE); ③ 是否报告多重划分。三缺一, 数字当娱乐看。

⑨ 类药性规则的「理化依据」(9.2, 知其所以然)

规则	数值	为什么 (机制)
Lipinski Ro5	MW ≤ 500; cLogP ≤ 5; HBD ≤ 5; HBA ≤ 10 (违反 ≥ 2 条口服难)	被动跨膜吸收的经验边界: 太大/太亲脂/太多氢键伙伴 → 水里聚团、膜里进不去; 例外: 底物、抗生素、天然产物
Veber	RB ≤ 10; TPSA ≤ 140 Å ²	柔性=构象熵罚 (结合吃亏); 极性表面积大 → 跨细胞旁路差 (吸收下降)
Rule of 3 (片段)	MW ≤ 300; HBD/HBA ≤ 3; cLogP ≤ 3; RB ≤ 3	片段靠效率取胜: 小而精才能 mM 亲和也有高 LE
定量指标	QED ∈ [0,1] (类药定量); SA ∈ [1,10] 越低越好; Fsp ³ =sp ³ 碳占比	把「像不像药」变成连续分数, 供生成器当目标函数

规则是筛子不是法律: 超越 Ro5 的成功药一大把 (大环、变构 PPI 抑制剂), 但「超越」要有理由 (如 bRo5 配体主动摄取)。

⑩ 药代动力学 PK 公式卡 (9.3 前置)

$$t_{1/2} = 0.693 \cdot V_d / CL \quad CL = \text{消除率/血浆浓度} \quad F = AUC_{\text{口服}} / AUC_{\text{静注}} \times 100\%$$

- CL 清除率: 肝代谢+肾排泄 (决定日给药次数的分子半边); V_d 分布容积 (组织滞留倾向)。
- 剂量设计的链条: $CL \times C_{\text{有效}} \times \tau$ (给药间隔) $\approx$ 维持剂量; $t_{1/2}$ 决定 τ 与蓄积。
- AUC (浓度-时间曲线下面积) = 暴露量的总账, 生物利用度 F 的分母分子。

剂量计算手算例 (把公式串起来)

设某药 CL=5 L/h, V_d =50 L, 目标稳态浓度 2 mg/L, q8h 给药

$t_{1/2} = 0.693 \times 50 / 5 = 6.9 \text{ h} \rightarrow$ 给药间隔合理 ($\approx t_{1/2}$)

维持速率 = $CL \times C = 5 \times 2 = 10 \text{ mg/h} \rightarrow$ 单次剂量 = $10 \times 8 = 80 \text{ mg q8h}$

若 F=50% 口服: 口服剂量 = $80 / 0.5 = 160 \text{ mg}$ (生物利用度补正)

🔪 「类药性」三问: 进得来吗 (吸收 F)、待得住吗 ($t_{1/2}$)、出得去吗 (CL/毒性) —— 下一页 ADMET 把三问拆成端点逐个建模。

⑪ ADMET 五维端点地图 (9.3/9.4 核心)

维	端点	机制/意义	建模形态
A	口服生物利用度 F、溶解度、Caco-2 渗透、P-gp 底物/抑制剂	P-gp 外排泵=耐药与低吸收元凶 (底物被泵出肠细胞)	回归/分类; 多端点并行
D	血浆蛋白结合 PPB、 V_d 、BBB 穿透	PPB 高 $\rightarrow$ 游离型少 (活性按游离算); 中枢药必须过 BBB、外周药最好别过	logBB 分类; PPB 回归
M	CYP450 底物/抑制剂: 3A4 (约半数药物经其代谢)、2D6、2C9、2C19、1A2	抑制他人代谢酶 $\rightarrow$ DDI 药物相互作用 (联合用药警告的核心)	五亚型 $\times$ (底物/抑制) 多标签分类
E	清除率 CL、 $t_{1/2}$	给药方案的直接依据	人 CL 用跨物种/类器官数据迁移
T	hERG、Ames、DILI、急性毒性、致癌	hERG=心肌 IKr 钾通道, 阻断 $\rightarrow$ QT 延长 $\rightarrow$ 尖端扭转型室速 (临床除名的头号心脏雷); Ames=鼠伤寒沙门菌组氨酸回复突变 (遗传毒标准试验); DILI=药物性肝损伤	二分类 (正/负); 极度不平衡

⑫ 数据与基准

- 公共数据: Tox21 (~1 万化合物 $\times$ 数十 qHTS 端点, 含应激通路)、ToxCast、hERG 专门集; TDC (Therapeutics Data Commons) 把 ADMET/DTA/生成任务打包成统一基准。
- 工具平台: SwissADME (免费网页, 含 BOILED-Egg 吸收图)、admetSAR 2.0、ADMETlab 3.0 (贴 SMILES 出 50+ 端点表)、商业 DEREK (毒性规则专家系统)。

🔪 使用哲学 (老师原话级): ADMET 预测是排雷过滤器不是预言家——预测「高风险」就要求实验确证或结构规避, 预测「安全」不等于安全。永远和实验闭环。

⑬ ADMET 建模四板斧 (9.4, 小数据生存术)

1. 特征: ECFP 指纹 (默认) + 理化描述符 (机制可解释: TPSA $\leftrightarrow$ 渗透、logP $\leftrightarrow$ 代谢); 或 GNN 端到端。
2. 不平衡: 正例 1-5% 是常态 $\rightarrow$ 类别权重 / 过采样 / focal loss; 指标只认 PRC-AUC 与召回率 (毒性端点漏报代价高)。
3. 多任务学习: 几十个端点共享底层表征 (相互迁移, 小端点被大端点带着涨) ——ADMET 建模的默认姿势。
4. 迁移学习: ChEMBL 级 SMILES/图预训练 $\rightarrow$ 端点微调; GROVER/MolBERT 类即插即用。

⑭ 上机: 一次完整的性质体检 (30 分钟)

```
# 1) SwissADME/admetSAR (网页): SMILES  $\rightarrow$  全端点报告 (零代码)
# 2) 本地三行版: 类药过滤 + 毒性端点 (sklearn + DeepChem)
from deepchem.molnet import load_tox21 # Tox21 12 端点多标签
tasks, datasets, tr = load_tox21(featurizer='ECFP', splitter='scaffold') # 注意 scaffold 划分!
# 训练 RandomForest 多标签  $\rightarrow$  报告每端点 ROC-AUC 与 PRC-AUC
```

⑮ 第 9 章总结 (三问三路三板斧)

全章速记

三问: 结得牢吗 (ΔG 换算 1.36/decade、SPR/ITC 数据从哪来)? 像药吗 (Ro5/Veber 的理化依据、QED/SA)? 安全可用吗 (ADMET 多维端点地图)?

三路: 结构路线 (对接 $\rightarrow$ MMGBSA $\rightarrow$ FEP 精度阶梯)、配体路线 (QSAR)、深度路线 (DeepDTA 双塔、防冷启动泄漏)。

三板斧: 指纹+描述符特征、不平衡对策 (PRC-AUC)、多任务+迁移学习。

🔪 科研落点建议: 选一个「数据中等、临床重要」的端点 (如 hERG 或 DILI) 做深——加新特征 (3D/代谢产物)、做严格划分、给可解释分析, 就是一篇扎实的硕士论文体量。

第 10 章 · 企业案例 I : 英矽智能

- 10.1 AI 药物发现应用
- 10.2 AlphaFold 革命 (企业视角)
- 10.3 深度架构与案例
- 10.4 生成式 AI

① 端到端平台三引擎 (背功能与输入输出)

引擎	对标课程章节	功能拆解
PandaOmics 靶点发现	第 4 章	融合 21 类数据源 (组学、文献文本、专利、临床试验、拨款记录); 输出靶点按新颖性 × 成药性 × 安全性三轴评分排序; 支持上传自有组学数据; 内置疾病相关性 (含衰老时钟等专项模型)
Chemistry42 生成化学	第 6+8 章	结构生成引擎 (多种生成模型并跑: 自回归/结构基础生成/RL) + 过滤漏斗 (类药/毒性预警/SA) + 打分排序 (对接/3DQSR/多目标); 输出「合成候选清单」
InClinico 临床预测	第 2 章临床环节	用临床前数据+试验设计特征预测 II 期临床试验成功概率, 辅助管线决策与投融资

② 企业视角的 AlphaFold 革命 (10.2)

- ★ 「结构可得性」从管线瓶颈变成公共设施: 过去 60% 靶点因无结构被弃 → 现在几乎全部可开工。
- ★ 工业用法分工: AFDB 拿整体形状 → 口袋精度不足时共晶/冷冻电镜定点补 (关键项目仍做实验结构) → 生成化学在结构上直接设计。
- ★ AF3 的蛋白-配体复合物预测被直接编进 Chemistry42 的验证链 (生成 → AF3/对接双确认)。

③ 深度架构在企业管线里的位置 (10.3)

- GNN: 性质/毒性端点打分器 (第 3/9 章的工业版); 注意力可解释=化学家与模型的「共同语言」。
- 生成式 AI 全家桶 (10.4): 预训练-RL 目标化 (REINVENT 式) + 3D 口袋生成; 文本大模型用于文献假设挖掘、试验方案起草、机器人调度——「副驾驶」定位, 决策权在科学家。
- 平台战绩 (截至 2024 公开口径): 已提名 20+ 临床前候选 (PCC)、10 个获临床试验许可, 管线覆盖纤维化、肿瘤、免疫、衰老。

🔪 「平台化」的护城河: 单一模型会被论文追平, 但「数据-模型-湿实验-临床」的闭环飞轮与专利管线不会——这是 AI 制药公司的商业本质。

④ INS018_055 (Rentosertib) 逐段对账

阶段	事实	对应课程知识点
疾病	特发性肺纤维化 IPF：进行性、致死性肺纤维化；现有药（吡非尼酮/尼达尼布）仅延缓，需求缺口大	适应症选择逻辑（未满足临床需求）
靶点发现	PandaOmics 整合 IPF 患者肺组织多组学 + 文献挖掘，识别 TNIK (TRAF2/NCK 相互作用激酶) 为高优先级纤维化靶点：与 ≥4 个 IPF 相关基因关联、兼顾抗纤维化与抗炎信号 (TGF-β/Wnt 通路交汇)	第 4 章多源证据整合排序
分子设计	Chemistry42 生成式设计 + 物理验证，得到全球首创 (first-in-class) TNIK 小分子抑制剂	第 8 章生成-过滤-打分闭环
效率	靶点 → PCC 仅 ~18 个月（传统 4-6 年）；合成并测试 <80 个分子（传统数百上千）；早期投入数百万美元级（传统数千万）	Eroom 定律的破解样本
临床推进	I 期（新西兰+中国）安全性良好；2023 年进入 II 期（中美）；II a 结果 2025 年登上 Nature Medicine：12 周治疗呈剂量依赖性肺功能 (FVC) 改善趋势；2025-06-30 启动 III 期——全球首个走到 III 期的「AI 发现靶点 +AI 设计分子」药物	临床验证闭环

⑤ 这个案例「证明了什么 / 没证明什么」（辩证）

证明了 - AI 靶点（非业界跟风靶）可以在临床起效——方法学闭环成立； - 生成化学能产出类药、可合成、有 IP 空间的分子； - 时间/成本压缩一个数量级是可复现的工程事实。	仍未证明 - III 期确证性疗效（进行中）； - 平台对任意靶点/适应症的可复制成功率（ISM5411 是第二个证据，见下页）； - 成本优势能否在临床开发段保持（临床花费占大头）。
--	---

📌 论文线索：研发全流程披露见 Nature Biotechnology (Ren F. et al.)；II a 临床见 Nature Medicine (Xu Z. et al. 2025) ——两篇连读=一个完整「AI 药物」样本。

第 11 章 · 企业案例 II : AI 赋能靶点发现

11.1 行业全景

11.2 炎症性肠病靶点发现


方法论飞轮

从课程到科研

① ISM5411: IBD 项目逐段对账

阶段	事实	知识点对账
疾病	炎症性肠病 IBD (溃疡性结肠炎+克罗恩病): 慢性、致残、需终身用药; 现有生物制剂 (抗 TNF/整合素/IL 通路) 应答率有限、注射为主	适应症缺口分析
靶点	PHD (脯氨酰羟化酶): PandaOmics 组学+文献综合排序发现; 抑制 PHD → 稳定 HIF (低氧诱导因子) → 促进肠道屏障修复与上皮稳态——「修复屏障」而非「压制免疫」的差异化机制	第 4 章: 机制假设从数据里长出来
分子	ISM5411: 口服小分子 PHD 抑制剂; 肠道限制性设计 (局部暴露、系统暴露低) → 预防贫血等系统性 PHD 抑制副作用	第 6 章: 选择性/治疗窗设计
效率	~12 个月提名 PCC; 合成筛选 ~115 个分子; 研究全文登 Nature Biotechnology (2024.12)	生成+过滤漏斗的效率
临床	多个结肠炎模型恢复屏障、降炎症; 已在中国+澳大利亚完成 I 期临床	干湿闭环走到人体

② 两大案例的方法论飞轮 (论述题满分结构)



对比传统: 候选分子数量级从「千」到「百」、时间从「年」到「月」——AI 的价值不是取代化学家, 而是把化学家的时间只留给最有希望的分子。

③ AI 制药玩家图谱 (11.1)

类型	代表	模式特点
端到端 AI-native	英矽智能 (Insilico)、Exscientia	自有平台+自研管线+对外合作三线并进；胜负手=管线临床兑现
数据/筛选驱动	Recursion (表型+数据工厂)、Schrödinger (物理+ML 计算平台)	专攻数据生产或计算引擎，与药企广泛订阅/合作
自动化实验闭环	Emerald Cloud Lab、各类自驱动实验室	机器人+BO 闭环，数据质量可控
跨国大药企	辉瑞、罗氏、诺华、阿斯利康…	自建 AI 部门+与 AI 公司/云厂共建 (如生成平台+自动化化学)
中国力量	英矽智能、晶泰科技 (XtalPi, 结构/晶型预测+自动化实验, 已上市)	从跟跑到并跑：算力、数据、化学家密度三要素齐备

④ 合作模式与行业逻辑 (为什么这么玩)

- ★ 里程碑付款：药企买 AI 公司的靶点/分子 (首付款+里程碑+销售分成) ——AI 价值以管线推进兑现。
- ★ 平台订阅/联合实验室：SaaS 或共建，赌「工具复利」。
- ★ 风险投资逻辑：AI 压缩早期成本 → 单管线试错变便宜 → 组合式下注 (portfolio)。
- ★ 行业共识短板：临床段成本未被 AI 显著压缩；数据孤岛 (药企内部数据不流通)；监管框架仍在追赶 (模型可解释性、数据来源合规)。

⑤ 对个人科研者的启示

- 企业案例=方法论的「放大器版」：你在实验室可以用同样流程做小切口课题 (P64 给出完整路线)。
 - 就业/深造方向：计算化学+ML 复合背景、自动化实验、临床数据科学——三条赛道都在抢人。
 - 阅读习惯：跟踪 Nature Reviews Drug Discovery 的年度 AI 制药盘点 + 各公司管线公告，保持产业地图更新。
- ✎ 思政落点：原创药与工业软件曾长期「卡脖子」；英矽/晶泰们证明中国团队能在第一梯队定义玩法——把生物医药命脉握在自己手里不是口号，是这一代药学人的岗位说明书。

把12章串成一个你自己的课题

① 示例课题：为靶点 X 设计并虚拟评估候选分子（8步全流程）

步	做什么	工具/命令	用到章节
1	选题与靶点档案（证据四栏：遗传/功能/表达/安全）	Open Targets、DisGeNET、GTEX、DepMap	第4章
2	拿结构、查口袋、redock 自检	PDB/AFDB、fpocket、Vina (RMSD<2Å 再继续)	第5-6章
3	收集活性数据、清洗建模（QSAR 基线）	ChEMBL 导出、RDKit ECFP、sklearn RF, scaffold split	第3/6/9章
4	虚拟筛选（或生成）候选集	Pharmit/ROCS 粗筛→Vina 精排；或 MolGen 采样+过滤	第6/8章
5	多目标打分排序（活性+ADMET+SA）	SwissADME/ADMETlab 批量、SA score、共识打分	第9章
6	目检 Top 50、挑选 5-10 个多样性代表	PyMOL 相互作用分析、骨架聚类	第6章
7	逆合成与可购性检查	ASKCOS / IBM RXN / eMolecules 报价	第8章
8	写成报告（数据-方法-指标-局限）	GitHub 留档、可复现脚本	科研规范

② 从课题到论文的三个加深方向

- 方法加深：把 QSAR 基线换成 GNN/预训练模型，做严格对比（scaffold split + 消融）。
- 问题加深：换到冷门靶点/端点（数据稀缺），讲迁移学习的故事。
- 闭环加深：与湿实验组队——Top 分子送测，哪怕 1 个 IC₅₀ 数据点，论文等级完全不同。

结课自测（能全答=课程目标达成）

① 双十/Eroom 定律与 AI 切入点？② AF2 架构三件套与置信度使用？③ 打分函数三流派与 SPDS？④ VUN 指标与四生成家族方程？⑤ Cheng-Prusoff 与 LE 计算？⑥ scaffold split 为什么必须？⑦ INS018_055/ISM5411 各自的「数据→假设→分子→临床」链条？——答不出的回到对应页码复习。

思政专题&考前速记(公式卷)

① 课程思政要点(简答储备)

- 科技自立自强: 创新药、工业软件与自动化曾长期「卡脖子」; 自研 AIDD 平台(英矽智能、晶泰)证明中国力量能进第一梯队——把生物医药命脉握在自己手里。
- 健康中国战略: AI 降本提速让罕见病、被忽视疾病「有药可研」——技术的温度与公共性。
- 科学家精神: Hassabis/Jumper 二十年冷板凳换来 AF2; Baker 从零开创蛋白设计——敢闯无人区、坐得住基础研究。
- 科研诚信与伦理: AI 时代更需数据真实、可重复、可解释; 杜绝「刷指标」; 敬畏生命(临床试验伦理、患者隐私数据合规)。

② 公式总卡(考前 15 分钟过一遍)

公式	用途 / 备注
$\Delta G^\circ = 2.303 \cdot R \cdot T \cdot \log_{10} K_d$	亲和-能量换算; 25°C 每差 10 倍 ≈ 1.36 kcal/mol
$v = V_{\max} [S] / (K_m + [S]); K_i = IC_{50} / (1 + [S] / K_m)$	米氏方程 / Cheng-Prusoff 换算
$LE = 1.37 \cdot pK_d / N_{HA}$	配体效率 (≥ 0.3 优)
$T_{animoto} = c / (a + b - c)$	指纹相似度 (> 0.85 近同物)
$t_{1/2} = 0.693 \cdot V_d / CL; F = AUC_{po} / AUC_{iv}$	PK 双公式
$O = (W \cdot F + 2P) / S + 1$	卷积输出尺寸
$Attention(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k}) V$	缩放点积注意力
$h_v^{(t)} = U(h_v^{(t-1)}, \text{AGG } M(\dots)); \hat{h}_G = \text{READOUT}$	MPNN 消息传递+读出
$ELBO = E[\log p(x z)] - \beta \cdot KL(q(z x) \parallel p(z))$	VAE 目标 (重参数化 $z = \mu + \sigma \odot \epsilon$)
$\nabla J = E[R_t \cdot \nabla \log \pi(a_t s_t)]$	REINFORCE 策略梯度 (RL 生成)
$q(x_t x_{t-1}) = N(\sqrt{1 - \beta_t} x_{t-1}, \beta_t I); L = E \ \epsilon - \epsilon_\theta \ ^2$	扩散前向/训练目标
$\text{score}(h, r, t) = - \ h + r - t \ $	TransE 知识图谱打分

规则 & 缩写速记卷

③ 数字规则清单（按课程出场序）

研发：双十定律；Eroom 每 9 年减半；临床成功率 ~10%	AF2: CASP14 中位 GDT $\approx$ 92.4; AFDB>2 亿
Lipinski: 500 / 5 / 5 / 10 (MW/logP/HBD/HBA)	pLDDT: >90 高 / 70-90 可 / <50 无序
Veber: RB $\leq$ 10、TPSA $\leq$ 140 Å ²	指纹: MACCS 166 位; ECFP4=半径 2; 常用 2048 位
Rule of 3 (片段): 300 / 3 / 3 / 3	redock 合格线 RMSD<2 Å
LE $\geq$ 0.3 优秀; QED $\in$ [0,1]; SA $\in$ [1,10] 低好	QSAR: $q^2>0.5$ 、外部 $R^2>0.6$
GWAS 阈值 $P<5\times 10^{-8}$	INS018_055: 18 个月、<80 分子; ISM5411: 12 个月、~115 分子

④ 缩写词典（按主题分组背）

主题	缩写 $\rightarrow$ 全称/含义
范式	AIDD/CADD; SBDD/LBDD; VS 虚拟筛选; FBDD 片段设计; de novo 从头设计
模型	MLP/CNN/RNN/LSTM/GRU; GNN/GCN/GAT/GIN/MPNN; VAE/GAN/RL; Transformer/MHA; ELBO
结构	PDB/AFDB; MSA 多序列比对; IPA 不变点注意力; pLDDT/PAE; CASP/GDT_TS; IDR 无序区; MD 分子动力学
对接	PDBQT; GA 遗传算法; ILS 迭代局部搜索; RMSD; SPDS; PAINS 假阳性惯犯
QSAR	CoMFA/CoMSIA; PLS 偏最小二乘; q^2/R^2_{ext} ; AD 适用域; OECD 五原则; MMP 匹配分子对
表征	SMILES/SELFIES/InChI; ECFP/Morgan; Tanimoto; USR 形状描述符
生成	VUN 有效性/唯一性/新颖性; FCD; MCTS; RL 奖励; BE/BO 贝叶斯优化
性质	DTA 药物-靶亲和力; DTI 相互作用; IC ₅₀ /EC ₅₀ /K _i /K _d ; pK _d ; LE/BEI; ADMET; DDI; PK/PD; F; CL; V _d ; AUC; BBB
毒性	hERG (QT/TdP); Ames; DILI; CYP450 (3A4/2D6/2C9/2C19/1A2); Tox21/ToxCast/TDC
靶点	GPCR; PPI; GWAS; CRISPRi/a; NER/NLP; CMap; RWR 随机游走; GO/KEGG 富集
递送	DDS; LNP; PEG 化; PDI 分散度; SPR/NMR/ITC/DSF; H _{II} 六角相
产业	PCC 临床前候选; NDA/BLA/IND; EUA; first-in-class/me-too; IP 知识产权

附录 A · 上机资源一页通

⑤ 数据库索引（按任务）

任务	数据库 → 网址（域名）
靶点-疾病关联	Open Targets (platform.opentargets.org)、DisGeNET、TTD (db.idrblab.net/ttd)、OMIM、GWAS Catalog
药物注释	DrugBank (go.drugbank.com)、PharmGKB、SIDER (副作用)
蛋白序列/结构	UniProt (uniprot.org)、PDB (rcsb.org)、AlphaFold DB (alphafold.ebi.ac.uk)
化合物与活性	ChEMBL (ebi.ac.uk/chembl)、BindingDB、PubChem、PDBbind
可购化合物库	ZINC (zinc20.docking.org)、Enamine REAL、eMolecules
互作网络	STRING (string-db.org)、BioGRID
组学/安全性	GEO/SRA、GTEX、DepMap (depmap.org)、CMap (clue.io)
基准数据	MoleculeNet (deepchem.io)、TDC (tdcommons.ai)、DUD-E/DEKOIS (VS 验证集)

⑥ 工具索引（按管线环节）

环节	工具
化学信息底座	RDKit (Python)、Open Babel、KNIME (可视化流程)
结构预测	AlphaFold Server / ColabFold、ESM Atlas、RoseTTAFold
口袋/对接	fpocket、AutoDock Vina (免费)、GNINA (CNN 打分)、Glide/GOLD (商业)、PyMOL & ChimeraX (可视化)
药效团/相似	LigandScout、Phase、Pharmit (pharmit.cswebsearch.com)、ROCS
QSAR/ML	scikit-learn、XGBoost、DeepChem、PyTorch+PyG (DGL 并列)
生成	REINVENT 4 (github 开源)、HuggingFace MolGen、DiffSBDD/TargetDiff (研究开源)
逆合成	ASKCOS (askcos.mit.edu)、IBM RXN (rxn.res.ibm.com)、Retro* 实现
ADMET	SwissADME (swissadme.ch)、admetSAR、ADMETlab 3.0 (admetlab3.scbdd.com)、ProTox-II
分子可视化	PyMOL、ChimeraX、 MarvinSketch (画图)

🔗 网址会变，认「机构+工具名」搜索最稳；商业工具（Schrödinger/MOE）学校通常有站点许可，先问实验室。

附录 B · 必读文献清单

⑦ 里程碑论文（按主题，精读级）

主题	文献
效率危机	Scannell et al., <i>Diagnosing the decline in pharmaceutical R&D efficiency</i> , Nat Rev Drug Discov 2012 (Eroom 定律)
AlphaFold2	Jumper et al., <i>Highly accurate protein structure prediction with AlphaFold</i> , Nature 2021
AlphaFold3	Abramson et al., <i>Accurate structure prediction of biomolecular interactions</i> , Nature 2024
蛋白设计	Watson et al., <i>De novo design of protein structure and function with RFdiffusion</i> , Nature 2023; Dauparas et al., <i>ProteinMPNN</i> , Science 2022
生成里程碑	Gómez-Bombarelli et al., <i>Automatic chemical design using a data-driven continuous representation (ChemVAE)</i> , ACS Cent Sci 2018; Olivecrona REINVENT, J Cheminf 2017
3D 生成	Guan et al., <i>3D Equivariant Diffusion for Target-Aware Molecule Generation (TargetDiff)</i> , ICML 2023
逆合成	Corey 逆合成经典教材; Liu et al., <i>Retrosynthetic Reaction Prediction Using Neural Sequence-to-Sequence Models (SCROP)</i> , ACS Cent Sci 2017
DTA	Öztürk et al., <i>DeepDTA</i> , Bioinformatics 2018; Nguyen et al., <i>GraphDTA</i> , Bioinformatics 2021
企业案例	Ren F. et al., <i>Nature Biotechnology (INS018_055 全流程)</i> ; Xu Z. et al., <i>Nature Medicine 2025 (II a 期)</i> ; Insilico IBD 论文, <i>Nature Biotechnology 2024.12 (ISM5411)</i>

⑧ 综合阅读

- Paul et al., *Artificial intelligence in drug discovery*, Nat Rev Drug Discov 2021 (领域综述标杆)
- 教材三件套（付伟《药物设计学》第 4 版；《计算机辅助药物设计导论》；《人工智能药学》）
- TDC 文档 (tdcommons.ai) ——边跑基准边学指标与划分。

写在最后

68 页走完，回到第一页那句话：AIDD = 药学问题 × 数据 × 模型 × 实验闭环。工具永远在换代 (AF2→AF3→...)，但「先把问题翻译成学习问题、再把输出翻译回实验」的思维方式不会过时。愿你早日做出第一款属于自己的分子。——笔记完

把论文写在祖国大地上，把分子做进患者生命里。