

数据字典

数据字典 | 负责人：衣思淼 | 阶段：第一阶段（暑假）

负责人：衣思淼（数据组）

数据快照：暑期第 6 周末（中期考核版）

1. 原始层 data/raw/

tcm_seed_compounds.csv（王散曼整理，第 1-2 周交付）

字段	类型	说明
compound_id	str	HP-xxx=保肝活性分子；DC-xxx=负参照
name_cn / name_en	str	中英文名
category	str	化合物类别（黄酮类/三萜类/木脂素类/蒽醌类/环烯醚萜苷类/生物碱类/香豆素类/非活性参照...）
source_herb	str	中药来源（负参照为 -）
smiles	str	结构式
label	int	1=有保肝活性证据；0=无保肝活性证据（含肝毒性药物作难负样本）
evidence_level	str	A=临床/系统评价；B=多项动物实验；C=单次动物/细胞实验
evidence_note	str	一句话证据摘要

标签口径：“是否存在保肝活性的公开证据”，不是活性强度。

负样本设计：40 条 = 惰性小分子 + 无保肝证据西药 + 经典肝毒性药物

（对乙酰氨基酚/异烟肼/丙戊酸/氯霉素/甲氨蝶呤等），构成“难负样本”，

迫使模型学习结构-活性关系而非简单的“药物 vs 天然产物”。

novel_terpenes_lignans.csv（第 3-4 周扩充，无标签筛选池）

12 条：三萜类 6 + 二萜类 1 + 木脂素类 4 + 甾体酸阳性参照 1（奥贝胆酸，

NV-011，不占候选名额），字段同上（无 label/evidence），用于最终批量推理排名。

2. 处理层 data/processed/

- cleaned_compounds.csv：解析校验通过的带标签集（88 条）。

新增列：scaffold（Murcko骨架签名）、n_atoms、MW、logP_est、TPSA_est、nHBD、nHBA、nRot、nAromSystems、nHeavy。

- screening_pool.csv：新分子池清洗产物（12 条），字段同上。
- rejected.csv：剔除记录及原因（当前 0 条；第一版曾有 22 条

五环三萜 SMILES 环号未闭合，已修复后重新入库）。

3. 划分层 data/splits/

按骨架组划分（同骨架不跨集合，防泄漏）：train 58（正28）/ val 13（正8）/

test 17（正12）；骨架组共 53 个，无环组 1 个（糖类负参照集中于此）。

4. 描述符口径（衣思淼）

字段	口径
MW	原子量加和（含隐式氢）
logP_est	原子贡献法估算（截距-0.55，芳香修正+0.12/体系，MW>650 渗透罚-0.5）。演示级，服务器版换 Crippen
TPSA_est	N/O 原子贡献近似（ $0 \approx 20.2$ ， $N \approx 12.5$ ，极性H+1.5）。演示级
nHBD/nHBA	带氢 0/N 计数 / 中性 0+N 计数
nRot	非环重原子单键且两端度>1
nAromSystems	芳香原子子图连通分量数（稠环计为1）

已知偏差（需在正式版修正）：

1. 五环三萜类简化骨架 MW 系统性偏高约 5-10%（如齐墩果酸 509 vs 真实 456）；
2. 环烯醚萜苷、五味子木脂素立体化学未展开；
3. logP_est 对强极性小分子（尿素/甘油）偏差较大，但此类仅存在于负参照，不影响候选排名。

5. 适用域 results/ad/ad_report.csv

字段	说明
leverage	$x^T(X^T X)^{-1} x$ ，训练集7维描述符标准化后计算
h_star	$3p/n = 0.362$ （ $p=7$ ， $n=58$ ）
in_domain	0/1，域外分子在排名表中打“域外”预警