

模型说明 (GNN + MC Dropout)

模型说明 | 负责人: 宁显洧 | 阶段: 第一阶段 (暑假)

负责人: 宁显洧 (算法组)

1. 输入表征

- SMILES $\rightarrow$ 分子图 (原子=节点, 键=边), 纯 Python 解析器

`src/chem/smiles_graph.py`, 支持 OpenSMILES 常用子集。

- 节点特征 13 维: 元素 one-hot (10) + 芳香标记 + 度/6 + 氢数/4。

2. 网络结构 (src/models/gnn.py)

```
X' = D-1/2 (A+I) D-1/2 X # 对称归一化 + 自环
H1 = tanh(X' W1 + b1)  $\rightarrow$  Dropout (0.3)
H2 = tanh((A' H1) W2 + b2)
pooled = mean_i (H2)  $\rightarrow$  Dropout (0.3)
z = W3 * pooled + b3, p = sigmoid(z)
```

隐层 32/16, Adam(lr=0.01, wd=1e-4), 300 epoch 全批量。

3. 不确定性估计 (MC Dropout)

推理时不关闭 Dropout, 前向 T=30 次:

- `pred_mean` = 30 次概率均值 (最终预测)
- `pred_var` = 概率方差 (认知不确定性的近似)

选择依据 (第 4 周组会决议): 对比了 MC Dropout 与 5 模型集成的实现成本, 小样本下两者不确定性质量接近, 选前者 (零额外训练开销)。

4. 损失权重实验 (对应分工表"调损失函数的权重")

加权 BCE, 正类权重 $w_{\text{pos}} \in \{1.0, 1.25, 1.5\}$ 按验证集 F1 选优:

<code>w_pos</code>	验证集 F1
1.0	0.625
1.25	0.667
1.5	0.667

取小值 1.25 (同分时偏好更保守的加权)。

5. 结果 (test, n=17, 正12)

AUC 0.967 / ACC 0.824 / BACC 0.875 / F1 0.857;

EOE(10bin) = 0.210 —— 校准偏差明显 (模型过自信),

方差-|误差| Spearman $\rho=0.718$ —— 不确定性排序能力强。

6. 已知问题与下一步

1. 过自信: ECE 0.21 偏高, 计划加温度系数校准 (val 上网格搜 T);
2. 测试集仅 17 条, 指标置信区间宽, 服务器上量后重估;
3. numpy 版反向传播为教学级实现, 服务器端换 PyG 后开启 mini-batch

与早停;

4. 类别口径是"证据有无", 下一步考虑把 evidence_level 折算成序数标签做回归。