

人工核验复现手册 (VERIFY MANUAL)

人工核验手册 | 负责人: 王启龙 | 阶段: 总纲

目的: 任何成员 (或老师) 在不了解代码的情况下, 按本手册逐步操作,

即可核验暑假阶段全部结果的真实性与可复现性。

预计耗时: § 0 - § 2 约10分钟 (一键复现+数字核验); § 3 - § 5 约40分钟 (逐模块人工核验)。

每完成一节, 在文末"核验记录表"打勾签名。

§0 前置条件 (1分钟)

```
python --version # 预期 3.9 及以上
python -c "import numpy; print(numpy.__version__)" # 预期 1.24 及以上
```

无需 GPU、无需联网、无需安装 RDKit/PyTorch。

§1 获取仓库并确认完整性

```
cd hepato-gnn-screening
git log --oneline # 预期能看到12次提交
git shortlog -sn HEAD # 预期5位作者: 王启龙4 衣思淼3 宁显洸2 王散曼2 代维斯丹1
```

§2 一键复现 + 数字核验 (核心, 约2分钟)

2.1 一键复现

```
python run_all.py
```

预期控制台输出 (关键行, 数字必须逐字一致):

```
[clean] 带标签集: 88 条 (正样本 48 / 负样本 40); 筛选池: 12 条; 剔除 0 条
[split] train: 58 条 (正 28)
[split] val: 13 条 (正 8)
[split] test: 17 条 (正 12)
[split] 骨架组总数 53; ACLYCIC(无环)组 1
[baseline] 高斯朴素贝叶斯(描述符): {'AUC': 0.85, 'ACC': 0.706, 'BACC': 0.733, 'F1': 0.762}
[baseline] 逻辑回归(2048bit指纹): {'AUC': 0.967, 'ACC': 0.706, 'BACC': 0.792, 'F1': 0.737}
[gnn] 选定正类损失权重 w_pos=1.25 (验证集F1=0.667)
[gnn] 测试集: {'AUC': 0.967, 'ACC': 0.824, 'BACC': 0.875, 'F1': 0.857, 'ECE': 0.21}; 方差-|误差|
Spearman rho=0.718
[docking] FXR演示评分均值: 保肝活性分子 -5.46 vs 负参照 -5.05 kcal/mol (差距 0.42)
[ad] h*=0.362; 筛选池域外分子 7/12 (58%) 已标记预警
[fuse] 协同评分完成: 60 个候选入库
全流程完成, 用时 ...s; 结果见 results/
```

2.2 确定性核验 (结果可重复)

连跑两次，第二次结束后比较：

```
python run_all.py > /dev/null 2>&1
find results data/processed data/splits -type f -name "*.csv" | sort | xargs md5sum > h1.txt
python run_all.py > /dev/null 2>&1
find results data/processed data/splits -type f -name "*.csv" | sort | xargs md5sum > h2.txt
diff h1.txt h2.txt && echo 一致 # 预期输出：一致
```

2.3 独立数字核验 (45项)

```
python reports/pdf_build/verify.py
```

预期最后一行：通过 45 项；不符 0 项。

该脚本不导入项目任何代码，独立从CSV重算AUC/ ρ /对接均值/Top-10等全部被引用数字。

§3 逐模块人工核验 (可选深度核验，每小节约5分钟)

3.1 SMILES解析器 (宁显泷模块)

```
python -c "
import sys; sys.path.insert(0, 'src')
from chem.smiles_graph import parse_smiles
for smi in ['CCO', 'c1ccccc1', 'O=C1C=C(c2ccc(O)cc2)Oc2cc(O)cc(O)c12', 'OC[C@H]1O[C@@H](O)[C@H](O)[C@H]1O', '[nH]1cccc1']:
    g = parse_smiles(smi)
    print(smi, '->', 'OK' if g else 'FAIL', g and len(g.atoms))
"
```

预期：5行全 OK，重原子数依次 3（乙醇）/ 6（苯）/ 20（芹菜素C15H10O5）/

12（葡萄糖）/ 5（吡咯）。

3.2 描述符 (衣思淼模块)

```
python -c "
import sys; sys.path.insert(0, 'src')
from chem.smiles_graph import parse_smiles
from chem.descriptors import compute_descriptors
g = parse_smiles('O=C1C(O)=C(c2cc(O)c(O)cc2)Oc2cc(O)cc(O)c12') # 槲皮素
print(compute_descriptors(g))
"
```

预期：MW=302.24（与槲皮素真实分子量302.24一致）、nHBD=5、nHBA=7、

nHeavy=22、nAromSystems=2。核对 docs/01_data_dictionary.md 的口径表。

3.3 指纹确定性 (代维斯丹模块)

```
python -c "
import sys; sys.path.insert(0, 'src')
from chem.smiles_graph import parse_smiles
from chem.fingerprints import morgan_fp
a = morgan_fp(parse_smiles('CC(=O)Nc1ccc(O)cc1')) # 对乙酰氨基酚
b = morgan_fp(parse_smiles('CC(=O)Nc1ccc(O)cc1'))
print('一致' if a==b else '不一致', '置位数', sum(a))
"
```

预期：一致（MD5哈希保证跨平台确定性）。

3.4 数据抽查（王散曼+衣思淼模块）

用Excel打开 [data/raw/tcm_seed_compounds.csv](#)：

1. 行数89（含表头）；HP-xxx 48行、DC-xxx 40行；
2. 抽 HP-015（水飞蓟宾）行：label=1, evidence_level=A；
3. 到 [literature/01_classic_evidence.md](#) A级表找到水飞蓟宾条目，两边描述对应；
4. 打开 [data/splits/](#) 三个文件：在 train 里找到“黄芩苷”的 scaffold 值，

确认 test/val 中无相同 scaffold（骨架不跨集合）。

3.5 排名总表（衣思淼+王启龙模块）

打开 [results/rankings/final_ranking.csv](#)：

1. 61行（含表头），rank 列 1 - 60 连续无重复；
2. 第1 - 3行：黄芩苷 / 二氢杨梅素 / 葛根素；
3. 第7行：水飞蓟宾（临床金标准落在前列=体系合理性）；
4. 找 NV-011（奥贝胆酸）：ad_warning=域外、pred_mean $\approx$ 0.26；
5. 任选一行手工验算融合公式：

$$\text{final} = 0.45 \times \text{pred_mean} \times (0.5 + 0.5 \times \text{confidence}) + 0.35 \times (1 - \text{dock名次比例}) + 0.20 \times (1 - 0.25 \times \text{违规数})$$

与 final_score 列在 ± 0.002 内一致（第1行黄芩苷应 ≈ 0.9291 ）。

3.6 结果图（王启龙+代维斯丹模块）

打开 [results/figures/](#)：

- top_candidates.png：条形顺序与 final_ranking.csv 前15行一致；
- reliability_diagram.png：折线整体在虚线上方/下方波动（过自信即低于对角线），与 ECE=0.210 的结论方向一致；
- uncertainty_vs_error.png：散点呈右上趋势（方差大误差大）；
- model_dock_scatter.png：叉号（域外）多位于右侧模型分高但排名低区域。

§4 抽样溯源核验（王散曼主导，下学期WP5完成）

从 [data/raw/tcm_seed_compounds.csv](#) 随机抽10条正样本，逐条到

PubMed/CNKI 检索证据（化合物名 + hepatoprotective / liver injury），

回填 literature/01 对应条目的"已核对"标记。当前 literature/01 头部已声明"引用为整理稿"——正式结题前必须完成本节。

§5 常见问题

现象	原因与处理
CSV中文乱码	读取统一 utf-8-sig; Excel打开用"数据→自文本→UTF-8"
run_all 某阶段报错 ModuleNotFoundError	确认在仓库根目录执行（脚本依赖相对路径 src/）
图中中文方框	正常：图内标签设计为英文，中文在报告正文
指标小数位与文档差千分之一	不应出现；若出现说明结果文件被改动，重跑 § 2

核验记录表

日期	核验人	§0	§1	§2.1	§2.2	§2.3	§3	§4	备注
（示例） 2026-09-02	王启龙	☐	☐	☐	☐	☐	☐	下学期	全过