

WP3 数据扩充与正式库导出 (第3-8周)

工作包 | 主责: 衣思淼 | 阶段: 第二阶段 (第3-8周)

主责: 衣思淼 (数据) | 核验人: 王散曼

前置条件: WP1 完成; TCMSP/PubChem 可访问

目标

用数据库正式导出替换教学版 SMILES 与标签, 带标签数据从 88 条扩到 ≥ 1000 条, 重算全部指标并给出置信区间。

步骤

1. 正式导出 (替换 raw/) :
 - TCMSP 检索保肝相关中药 (肝炎/黄疸/肝纤维化等适应症字段) $\rightarrow$ 导出成分表; PubChem 按名称/InChIKey 批量取标准 SMILES;
 - 新表增加列: source_db、std_smiles (PubChem标准)、inchikey;
 - 保留旧列 compound_id 编号规则 (HP/DC/NV 前缀);
2. 标签复核: 王散曼按 evidence_level 口径复核每条正样本 (文献检索至少到B级证据才保留 label=1, C级降为"待定池");
3. 去重升级: inchikey 完全去重 (替换演示版规范化串去重);
4. 重跑清洗/划分/训练, 测试集预期 ≥ 150 条, 指标加95% bootstrap置信区间 (新脚本 [src/models/bootstrap_ci.py](#));
5. 描述符升级: 服务器端 RDKit Crippen/TPSA 替换演示估算 (descriptors.py 加 rdkit 分支, 列名不变);
6. 三萜简化骨架修正: 正式 SMILES 替换后, MW 系统偏差应消失, 在 01_data_dictionary.md "已知偏差"节回填实测值。

期望输出

- data/raw 正式版 (≥ 1000 条带标签); 新旧数据规模与指标对照表;
- bootstrap 置信区间报告。

验收标准

- ☐ 每条正样本有 source_db 与可溯源证据标记
- ☐ inchikey 零重复 (`python -c` 抽查脚本通过)
- ☐ 指标带置信区间, AUC 区间宽度较 v1 收窄
- ☐ 王散曼抽检30条标签与文献一致

核验记录

日期	核验人	结果	备注
----	-----	----	----