

# WP3 数据扩充与正式库导出（第3-8周）

工作包 | 主责：衣思淼 | 阶段：第二阶段（第3-8周）

主责：衣思淼（数据） | 核验人：王散曼

前置条件：WP1 完成；TCMSP/PubChem 可访问

## 目标

用数据库正式导出替换教学版 SMILES 与标签，带标签数据从 88 条扩到  $\geq 1000$  条，重算全部指标并给出置信区间。

## 来源纪律（老师着重强调，本工作包第一原则）

数据只从公开权威数据库取，白名单与引用规范：

| 要什么         | 只认哪里             | 入库必须记              |
|-------------|------------------|--------------------|
| 分子结构/SMILES | PubChem、ChEMBL   | CID/ChEMBL ID+访问日期 |
| 活性/靶点数据     | ChEMBL、BindingDB | 库内编号+检测类型/单位       |
| 中药成分        | TCMSP、PubChem    | 来源库+成分编号           |
| 成药性         | SwissADME        | 计算条件+日期            |

硬规则：① 百度/百科/公众号/博客只能当找线索，不得当数据源；  
② 每条记录 source\_db+唯一编号+访问日期三要素齐全（对应验收第 1 条）；  
③ AI 提供的任何数字/结构/文献必须到权威库核实后才可入库——AI 只出检索词、不下结论；④ 非权威源数据一经发现，回权威库重查，查不到即删并留处置记录。

## 步骤

1. 正式导出（替换 raw/）：
  - TCMSP 检索保肝相关中药（肝炎/黄疸/肝纤维化等适应症字段）→ 导出成分表；PubChem 按名称/InChIKey 批量取标准 SMILES；
    - 新表增加列：source\_db、std\_smiles（PubChem标准）、inchikey；
    - 保留旧列 compound\_id 编号规则（HP/DC/NV 前缀）；
  - 2. 标签复核：王散曼按 evidence\_level 口径复核每条正样本（文献检索至少到B级证据才保留 label=1，C级降为"待定池"）；
  - 3. 去重升级：inchikey 完全去重（替换演示版规范化串去重）；
  - 4. 重跑清洗/划分/训练，测试集预期 $\geq 150$ 条，指标加95% bootstrap置信区间（新脚本 [src/models/bootstrap\\_ci.py](#)）；
  - 5. 描述符升级：服务器端 RDKit Crippen/TPSA 替换演示估算

(descriptors.py 加 rdkit 分支，列名不变)；

6. 三萜简化骨架修正：正式 SMILES 替换后，MW 系统偏差应消失，  
在 01\_data\_dictionary.md "已知偏差"节回填实测值。

期望输出

- data/raw 正式版（≥1000条带标签）；新旧数据规模与指标对照表；
- bootstrap 置信区间报告。

验收标准

- ☐ 每条正样本有 source\_db 与可溯源证据标记（库名+唯一编号+访问日期三要素齐全，白名单见"来源纪律"节）
- ☐ inchikey 零重复（python -c 抽查脚本通过）
- ☐ 指标带置信区间，AUC 区间宽度较 v1 收窄
- ☐ 王散曼抽检30条标签与文献一致

核验记录

| 日期 | 核验人 | 结果 | 备注 |
|----|-----|----|----|
|----|-----|----|----|