

基于图神经网络与分子对接的保肝中药成分虚拟筛选（暑期课题·中期）

项目总览 | 负责人：王启龙 | 阶段：第一阶段（暑假）

项目概览

- 目标：构建“中药成分 → 图神经网络活性预测(含不确定性) → 分子对接验证 → 协同评分”的虚拟筛选流水线，产出保肝候选分子排名总表。
- 当前阶段：暑期中期。本地小样本全流程已跑通（约 6 秒/次），服务器上量与真实对接为下一阶段任务。
- 快速复现：`python run_all.py`（仅需 `numpy`；`matplotlib` 可选）

目录结构

```
hepato-gnn-screening/
├── 王启龙/ 宁显泷/ 衣思淼/ 代维斯丹/ 王散曼/ # 一级按人：各含 工作台.md(任务/记录)+打卡_姓名.html(学习/打卡)+待核文件/(名下要核验的具体文件快照+清单)
├── learning/ # 学习档案按人一份：王启龙14/宁显泷10/衣思淼7/代维斯丹4/王散曼2 个文件(练习骨架已全部生成)
├── run_all.py # 一键复现全流程
├── data/ # ㄟ
├── src/ # |
├── results/ # | 全队公用一份
├── literature/ # | (不复制，仓库为唯一真相)
├── docs/ # | 总纲:VERIFY_TASKS/MEMBER_WORKBENCH/VERIFY_MANUAL
├── reports/ # ㄟ
└── tools/ # 工程工具(semester_flow.py/exe/生成器)
```

阶段结果速览（详见 reports/midterm_report.md）

模型	AUC	ACC	BACC	F1
高斯朴素贝叶斯(描述符)	0.850	0.706	0.733	0.762
逻辑回归(2048bit指纹)	0.967	0.706	0.792	0.737
GNN+MC Dropout(本项目)	0.967	0.824	0.875	0.857

- 不确定性质量：方差与预测误差的 Spearman 相关 0.718
- 适用域预警正确识别 7/12 个结构新颖分子为域外
- Top-3 候选：黄芩苷、二氢杨梅素、葛根素（60 候选总表见 `results/rankings/`）

分工与成员快速入口

成员	模块	校验线	我的入口（点开就是自己的部分）
王启龙	仓库/环境/一键运行、适用域预警集成、结果自动化	辅助/工程（L1 - L5 · 90文件）	[王启龙/工作台.md] (王启龙/工作台.md) + [打卡] (王启龙/打卡_王启龙.html)
宁显洳	SMILES→图解析、GNN+MC Dropout、损失权重选择	代码验证（N1 - N6 · 12文件）	[宁显洳/工作台.md] (宁显洳/工作台.md) + [打卡] (宁显洳/打卡_宁显洳.html)
衣思淼	数据清洗/骨架划分/适用域边界、协同评分融合	数据线A（Y1 - Y6 · 14文件）	[衣思淼/工作台.md] (衣思淼/工作台.md) + [打卡] (衣思淼/打卡_衣思淼.html)
代维斯丹	对接流程/网格盒子、传统基准线、可靠性评估	数据线B（D1 - D5 · 18文件）	[代维斯丹/工作台.md] (代维斯丹/工作台.md) + [打卡] (代维斯丹/打卡_代维斯丹.html)
王散曼	数据库调研、候选池构建、文献支撑库	文献（M1 - M4 · 4文件）	[王散曼/工作台.md] (王散曼/工作台.md) + [打卡] (王散曼/打卡_王散曼.html)

每位成员三步上手：① 进仓库根目录自己全名的文件夹——

<姓名>/工作台.md（我的一份：任务勾选表/名下文件/操作五步/记录表）；

② 按其中任务表逐条核验（时限 9/13 或 9/20，全队总表

[docs/VERIFY_TASKS.md] (docs/VERIFY_TASKS.md) 公用一份）；③ 每周打开

<姓名>/打卡_<姓名>.html 学习、打卡、生成周报。

打卡页怎么打开：git clone 或 Download ZIP 到本地后浏览器双击（页面互相能跳转；

GitHub 网页端点开 .html 只显示源码，属平台限制）。

学习练习：每人一份 learning/<姓名>/（练习骨架已生成，按周卡片实现后用

python tools/semester_flow.py --member <姓名> check <周号> 核验；负责人版不带 --member）。

数据/文献/结果为公用一份，在各人文件里只放任务与记录、不复制数据本体。

当前 AI 初筛 Top-10 及全部待验结论见 VERIFY_TASKS.md 第 0 节。

复核清单（重要）

本项目在本地演示环境完成，以下事项在正式结题前需复核：

- 1. 对接评分为演示模式（物理启发打分），服务器端需用 src/docking/run_vina.sh 真实复算；
- 2. 种子数据集 SMILES 为教学复现版本，部分复杂天然产物立体化学/稠环做了简化（数据字典有标注），正式运行前以 TCMSP/PubChem 导出为准；
- 3. 文献引用为整理稿，正式使用前逐条核对（见 literature/）；
- 4. GNN 为 numpy 演示实现，服务器端迁移 PyG 版本（接口一致）。