

基于图神经网络与分子对接的保肝中药成分虚拟筛选（暑期课题·中期）

项目总览 | 负责人：王启龙 | 阶段：第一阶段（暑假）

项目概览

- 目标：构建“中药成分 → 图神经网络活性预测(含不确定性) → 分子对接验证 → 协同评分”的虚拟筛选流水线，产出保肝候选分子排名总表。
- 当前阶段：暑期中期。本地小样本全流程已跑通（约 6 秒/次），服务器上量与真实对接为下一阶段任务。
- 快速复现：`python run_all.py`（仅需 `numpy`；`matplotlib` 可选）

目录结构

```
hepato-gnn-screening/
├── run_all.py # 一键复现全流程
├── data/
│   ├── raw/ # 种子数据集(王散曼整理)
│   ├── processed/ # 清洗产物
│   └── splits/ # 骨架划分 train/val/test
├── src/
│   ├── chem/ # SMILES解析/描述符/指纹
│   ├── data/ # 清洗/划分/适用域
│   ├── models/ # GNN+MC Dropout / 传统基准线
│   ├── docking/ # 网格盒子/演示打分/Vina脚本
│   ├── scoring/ # 协同评分融合
│   └── viz/ # 结果图
├── results/ # 指标/预测/对接/排名/图
├── literature/ # 文献支撑库(王散曼)
├── docs/ # 数据字典/环境/模型/对接说明+组会纪要
└── reports/ # 中期考核报告
```

阶段结果速览（详见 reports/midterm_report.md）

模型	AUC	ACC	BACC	F1
高斯朴素贝叶斯(描述符)	0.850	0.706	0.733	0.762
逻辑回归(2048bit指纹)	0.967	0.706	0.792	0.737
GNN+MC Dropout(本项目)	0.967	0.824	0.875	0.857

- 不确定性质量：方差与预测误差的 Spearman 相关 0.718
- 适用域预警正确识别 7/12 个结构新颖分子为域外
- Top-3 候选：黄芩苷、二氢杨梅素、葛根素（60 候选总表见 results/rankings/）

分工与成员快速入口

成员	模块	校验线	我的入口（点开就是自己的部分）
王启龙	仓库/环境/一键运行、适用域预警集成、结果自动化	辅助/工程（L1 - L5 · 90文件）	[个人工作台] (tools/学期推进流_王启龙.html)
宁显洧	SMILES→图解析、GNN+MC Dropout、损失权重选择	代码验证（N1 - N6 · 12文件）	[个人工作台] (tools/学期推进流_宁显洧.html)
衣思淼	数据清洗/骨架划分/适用域边界、协同评分融合	数据线A（Y1 - Y6 · 14文件）	[个人工作台] (tools/学期推进流_衣思淼.html)
代维斯丹	对接流程/网格盒子、传统基准线、可靠性评估	数据线B（D1 - D5 · 18文件）	[个人工作台] (tools/学期推进流_代维斯丹.html)
王散曼	数据库调研、候选池构建、文献支撑库	文献（M1 - M4 · 4文件）	[个人工作台] (tools/学期推进流_王散曼.html)

每位成员三步上手：① 打开 [docs/MEMBER_WORKBENCH.md] (docs/MEMBER_WORKBENCH.md)

找到自己全名那一节（是什么/做什么/怎么操作/名下文件/学习线）；② 按 [docs/VERIFY_TASKS.md] (docs/VERIFY_TASKS.md) 自己小节的任务表逐条核验（时限 9/13 或 9/20）；③ 每周在 [tools/学期推进流_<姓名>.html](#) 打卡页（浏览器双击打开，首屏"□ 我的工作台"）学习、打卡、生成周报。

当前 AI 初筛 Top-10 及全部待验结论见 VERIFY_TASKS.md 第 0 节。

复核清单（重要）

本项目在本地演示环境完成，以下事项在正式结题前需复核：

- 1. 对接评分为演示模式（物理启发打分），服务器端需用 `src/docking/run_vina.sh` 真实复算；
- 2. 种子数据集 SMILES 为教学复现版本，部分复杂天然产物立体化学/稠环做了简化（数据字典有标注），正式运行前以 TCMSP/PubChem 导出为准；
- 3. 文献引用为整理稿，正式使用前逐条核对（见 literature/）；
- 4. GNN 为 numpy 演示实现，服务器端迁移 PyG 版本（接口一致）。