

暑期课题中期考核报告

中期考核报告 | 汇编：王启龙 | 阶段：第一阶段（暑假）

课题：基于图神经网络与分子对接的保肝中药成分虚拟筛选

团队：王启龙、宁显珑、衣思淼、代维斯丹、王散曼

周期：暑期六周（W1-2 环境/数据 → W3-4 全量建模 → W5-6 收敛出表）

复现方式：python run_all.py（全流程约 6 秒，全部随机种子固定）

一、计划节点对照

阶段	计划节点	完成情况
W1-2	小样本端到端跑通；测试数据交付	☐ 100 条原始数据→88 带标签+12 筛选池；全链路无报错
W3-4	模型输出均值+方差；基准线与对接可并表	☐ GNN+MC Dropout 出分；NB/LR 双基准线出表
W5-6	协同评分矩阵+排名总表+机制溯源；中期材料	☐ 60 候选排名总表；药效团归纳；4 张结果图

二、数据

- 带标签集 88 条：正样本 48（经典保肝中药成分，证据分级 A/B/C）、负样本 40（惰性小分子 + 无证据西药 + 经典肝毒性药物作难负样本）。
- 骨架级划分（防同骨架泄漏）：train 58（正 28）/ val 13（正 8）/ test 17（正 12）；共 53 个骨架组。
- 新分子筛选池 12 条：三萜类 6 + 二萜类 1 + 木脂素类 4，另含奥贝胆酸（甾体酸）作方法学阳性参照。
- 数据字典与已知偏差见 [docs/01_data_dictionary.md](#)。

三、方法

- GNN + MC Dropout（本地 numpy 实现，服务器迁移接口一致）：
2 层 GCN（对称归一化）→ 均值池化 → Dropout；推理保持 Dropout 开启
前向 30 次，取概率均值为预测、方差为不确定性。
- 损失权重选择：加权 BCE 正类权重 $w_{pos} \in \{1.0, 1.25, 1.5\}$ 按验证集 F1 选优 → 取 1.25（F1 0.667 vs 基线 0.625）。
- 适用域：7 维描述符杠杆值法，阈值 $h^*=3p/n=0.362$ 。
- 对接（本地演示模式）：FXR(10SH) + Keap1(2FLU) 双靶点，
物理启发打分占位，服务器 Vina 复算脚本已就绪。

5. 协同评分： $\text{final} = 0.45 \times \text{模型分} \times \text{置信权重} + 0.35 \times \text{对接名次} + 0.20 \times \text{类药性}；\text{域外分子} \times 0.9$ 预警降权。

四、结果

4.1 模型对比 (测试集 n=17, 正 12)

模型	AUC	ACC	BACC	F1
高斯朴素贝叶斯 (描述符)	0.850	0.706	0.733	0.762
逻辑回归 (2048bit 指纹)	0.967	0.706	0.792	0.737
GNN+MC Dropout (本项目)	0.967	0.824	0.875	0.857

GNN 与指纹 LR 的 AUC 持平，但平衡准确率/F1 明显更优——小样本下图结构表征的分类边界更稳。

4.2 不确定性与校准

- 方差与 |预测误差| 的 Spearman 相关 $\rho=0.718$ ：不确定性排序能力强，可为置信度加权提供依据；
- $\text{ECE}(10 \text{ bin}) = 0.210$ ：模型整体过自信，已列入下一阶段温度校准任务（如实呈现，不回避）。

4.3 适用域预警

筛选池 12 个新分子中 7 个被正确标记域外（三萜酸类为主）——训练集三萜样本少、结构新颖度高的分子自动降权，机制符合设计预期。

方法论发现：阳性参照药奥贝胆酸（FXR 激动剂）模型分仅 0.26 且判域外。原因：训练集为中药成分化学空间，甾体骨架不在其中。结论：模型分只在中药化学空间内可解释；跨空间筛选必须依赖对接分与适用域标记，这正是协同评分三源融合的价值。

4.4 最终排名 (60 候选, 节选)

#	候选	类别	模型分	方差	置信	对接kcal	域外	总评
1	黄芩苷	黄酮苷	0.961	0.0012	0.86	-6.86	否	0.9288
2	二氢杨梅素	黄酮醇	0.965	0.0017	0.83	-7.14	否	0.8986
3	葛根素	异黄酮苷	0.961	0.0018	0.83	-7.03	否	0.8900
4	姜黄素	多酚	0.890	0.0050	0.71	-6.94	否	0.8819
5	柚皮素	黄烷酮	0.941	0.0021	0.82	-6.54	否	0.8814
6	木犀草素	黄酮	0.978	0.0008	0.89	-6.43	否	0.8704

#	候选	类别	模型分	方差	置信	对接kcal	域外	总评
7	水飞蓟宾	黄酮木脂素	0.967	0.0011	0.87	-6.39	否	0.8493
8	松脂素（新）	呋喃木脂素	0.881	0.0068	0.67	-6.64	否	0.8397
9	槲皮素	黄酮醇	0.972	0.0031	0.78	-6.37	否	0.8200
10	落叶松脂素（新）	开环木脂素	0.791	0.0097	0.61	-6.89	否	0.8181

- 水飞蓟宾（临床金标准保肝药）落在第 7 位——排名体系合理性的事后佐证；
- 新分子 2 个进 Top-10（松脂素、落叶松脂素），且置信度与域内状态合理，木脂素支线（五味子/厚朴/牛蒡子训练来源）延续性强；
- 完整总表：[results/rankings/final_ranking.csv](#)。

4.5 药效团溯源（节选，详见 literature/03）

Top-10 共性药效团要素：①多酚羟基特征（10/10，每分子至少2个酚羟基，其中6/10含严格间/邻二酚结构）；②双芳香环体系（10/10，对应 FXR 疏水口袋 π 堆积）；③C6-C3-C6 或木脂素二聚骨架（9/10，姜黄素为二芳基庚烷例外）。三萜酸类（C-28 羧基+3 β -OH）走胆酸口袋等排的独立路径，本轮置信度低，建议单独成支线。另注：全场最高模型分为大黄素（0.993，蒽醌类），最低 MC 方差为苦参碱（约 1.2×10^{-5} ）——高置信并不总伴随高排名，印证了三源融合的必要性。

五、诚实性声明与复核清单

事项	状态	复核方式
模型指标（AUC/F1/ECE 等）	本地真实计算	<code>python run_all.py</code> 可复现
不确定性/适用域/协同评分	本地真实计算	同上
对接评分	演示模式（物理启发占位）	服务器 <code>run_vina.sh</code> 复算覆盖
种子集 SMILES	教学复现版（三萜/苷类有简化）	TCMSP/PubChem 导出替换
文献引用	调研整理稿	逐条核对原文后引用

六、下一阶段计划

1. 服务器迁移：RDKit/PyG 版模型 + Vina 真实对接，覆盖演示分；
2. 数据扩充：数据库正式导出，目标 ≥ 1000 带标签分子，测试集置信区间收敛；
3. 校准：温度系数法修 ECE（目标 < 0.10 ）；
4. 实验衔接：松脂素/落叶松脂素优先推进体外验证与深度文献挖掘。