

暑期课题 · 第一阶段报告材料汇总

保肝中药成分 虚拟筛选课题

汇总暑假六周五人三线的全部产出：100条数据体系、GNN结合MC Dropout的不确定性建模、双基准线与双靶点对接演示、60候选协同排名，附45项独立校验与人工核验手册入口。

阶段范围 第一阶段（2026年7月至8月，六周）

文档版本 阶段报告 v1.0

完成日期 2026年8月

目 录

1 第一阶段概述	2
1.1 阶段目标达成情况	2
2 组织分工与协作机制	2
2.1 成员人设与职责	2
2.2 版本与过程管理	3
3 六周执行纪要	3
4 数据体系成果	3
4.1 数据构成与标签口径	3
4.2 描述符与适用域	4
5 方法成果	4
5.1 分子图表征与GNN	4
5.2 基准线与对接演示	4
5.3 协同评分融合	4
6 阶段结果	4
6.1 模型对比	4
6.2 协同排名（60候选）	6
6.3 药效团归纳	7
7 质量保证与复核机制	7
8 交付物与文件地图	8
9 下学期工作衔接	8
附录 人工核验十分钟路径	8

1 第一阶段概述

课题总目标是构建“中药成分 → 图神经网络活性预测（含不确定性）→ 分子对接验证 → 协同评分”的虚拟筛选流水线。按两阶段规划（见 docs/PHASE_PLAN.md），暑假为第一阶段：用六周时间在本地零依赖环境完成流程搭建与小样本全链路跑通，产出可复核的阶段结果；数据上量、真实对接与实验衔接安排在下学期五个工作包中执行。

本报告是第一阶段的汇总材料，内容取自仓库各总结文件：中期报告、三次组会纪要、数据字典与模型说明、对接说明、文献支撑库，以及两阶段规划、全文件清单与核验手册，逐文件路径见 docs/MANIFEST.md。全部数字可通过 docs/VERIFY_MANUAL.md 的步骤独立复算。

6 周 三段式执行周期	100 条 数据体系（88带标签+12筛	60 个 候选分子协同排名	45 项 独立数字校验全通过
-----------------------	--------------------------------	-------------------------	--------------------------

1.1 阶段目标达成情况

节点	计划目标	达成	证据
W2末	环境统一，小样本端到端跑通	达成	docs/minutes/week1-2.md
W4末	模型输出均值+方差，基准线可并表	达成	docs/minutes/week3-4.md
W6末	排名总表+机制溯源+中期材料	达成	docs/minutes/week5-6.md
W6末	结果可独立复算	达成	verify.py 45项全过

表 1-1 第一阶段节点对照

2 组织分工与协作机制

2.1 成员人设与职责

成员	人设	第一阶段主责模块	第二阶段去向
王启龙	工程支撑	仓库/环境/一键运行、适用域预警集成、结果自动化、报告汇编	WP1 复现核验工程化
宁显洳	算法	SMILES转图解析器、GNN+MC Dropout、损失权重选择	WP4 模型升级与校准
衣思淼	数据	清洗/骨架划分/描述符、适用域边界、协同评分融合规则	WP3 数据扩充
代维斯丹	验证	双基准线、双靶点对接（演示模式）、可靠性评估	WP2 真实对接

成员	人设	第一阶段主责模块	第二阶段去向
王散曼	化学信息与文献	种子候选池与证据标注、新分子池、机制溯源与药效团	WP5 文献深化与实验衔接

表 2-1 成员×人设×模块（与 CONTRIBUTORS.md、文件头署名一致）

2.2 版本与过程管理

git 仓库共12次提交、5位作者署名，提交归属与分工矩阵一一对应；联合任务按"主责+协作"双署名（如适用域=衣思淼定边界+王启龙写预警代码）。三次组会纪要留档了各节点验收结论与关键决议，包括不确定性方案二选一、损失权重选择规则、阳性参照药排名偏低的原因分析等。

3 六周执行纪要

时段	关键动作	关键决议/问题
W1-2	零依赖环境定案；解析器完成；48+40种子池交付；首版22条三萜SMILES环号错误修复	稠环SMILES逐原子核对环号后入库；CSV统一UTF-8
W3-4	全量清洗与骨架划分，MC Dropout定型（对比集成后选定），双基准线与新分子池12条交付	ECE偏高如实记录待校准；奥贝胆酸排名低确认为适用域机制而非错误
W5-6	模型冻结批量推理；协同评分矩阵；4张结果图；药效团归纳；中期材料闭环	排名自动化定稿；演示对接明确标注待服务器复算

表 3-1 三次组会要点（详见 docs/minutes/）

4 数据体系成果

4.1 数据构成与标签口径

子集	数量	构成与用途
保肝活性分子（HP）	48	黄酮/三萜/木脂素/蒽醌/环烯醚萜苷/生物碱/香豆素等；证据分级A(3)/B/C
负参照（DC）	40	惰性小分子+无证据西药+经典肝毒性药物（对乙酰氨基酚、异烟肼等难负样本）
新分子筛选池（NV）	12	三萜6+二萜1+木脂素4+甾体酸阳性参照1（奥贝胆酸）
骨架级划分	53组	train 58（正28） / val 13（正8） / test 17（正12），同骨架不跨集合

表 4-1 数据体系（清洗后88条带标签+12条筛选池）

标签口径为"是否存在保肝活性的公开证据"（二分类），非活性强度。清洗管线五步：解析校验→规范化去重→Murcko骨架签名→描述符计算→骨架级划分。剔除记录即使在零剔除时也落盘留痕，

留痕文件为 data/processed/rejected.csv。

4.2 描述符与适用域

7维二维描述符（MW/logP_est/TPSA_est/nHBD/nHBA/nRot/nAromSystems）为演示口径，槲皮素MW实测302.24与真实值一致；适用域采用训练集描述符杠杆值法，阈值 $h^*=3p/n=0.362$ ，域外分子在排名中打标并乘0.9预警降权。

5 方法成果

5.1 分子图表征与GNN

自研纯Python SMILES解析器（无RDKit依赖）把分子转为图，节点特征13维；两层GCN（对称归一化邻接）接均值池化与Dropout，sigmoid输出保肝概率。不确定性采用MC Dropout：推理保持Dropout前向30次，取概率均值为预测、方差为不确定性度量（组会对比模型集成后选定，零额外训练成本）。

w_pos	1.0	1.25 (选用)	1.5
验证集F1	0.625	0.667	0.667

表 5-1 加权BCE正类权重实验

5.2 基准线与对接演示

双基准线：描述符+高斯朴素贝叶斯、2048bit哈希指纹+逻辑回归。指纹采用MD5哈希保证跨平台确定性。两条线先于模型出分保证可对比。对接为演示模式：FXR(10SH)与Keap1(2FLU)双靶点盒子参数已定，本地以物理启发打分占位（自检区分度：活性-5.46 对 负参照-5.05 kcal/mol），服务器端run_vina.sh复算后直接覆盖，下游无需改动。

5.3 协同评分融合

$$\text{final} = 0.45 \times \text{模型分} \times (0.5 + 0.5 \times \text{置信}) + 0.35 \times \text{对接名次分} + 0.20 \times \text{类药性分}$$
，域外分子再乘0.9；置信度 $=1 - \min(1, \sqrt{\text{方差}/0.25})$ 。

6 阶段结果

6.1 模型对比

模型	AUC	ACC	BACC	F1
高斯朴素贝叶斯（描述符）	0.850	0.706	0.733	0.762

模型	AUC	ACC	BACC	F1
逻辑回归（2048bit指纹）	0.967	0.706	0.792	0.737
GNN + MC Dropout（本课题）	0.967	0.824	0.875	0.857

表 6-1 测试集指标（n=17，正12；骨架级划分）

不确定性质量：方差与误差的Spearman相关 $\rho=0.718$ ；校准偏差ECE=0.210（模型偏过自信），已列入WP4温度校准任务。两个方法论发现：其一，阳性参照药奥贝胆酸模型分仅0.26且域外——训练集是中药化学空间，甾体骨架不在其中，说明模型分只在域内可解释、三源融合必要；其二，全场最高模型分与最低方差（大黄素/苦参碱）都不在Top-10内，对接与类药性约束了总评。




图 6-1 可靠性图（ECE=0.210，过自信可见）




图 6-2 方差与误差正相关（ $\rho=0.718$ ）

6.2 协同排名 (60候选)

排名	候选	类别	模型分	方差	置信	对接	总评
1	黄芩苷	黄酮苷	0.9612	0.0012	0.863	-6.86	0.9291
2	二氢杨梅素	黄酮醇	0.9653	0.0017	0.837	-7.14	0.8990
3	葛根素	异黄酮苷	0.9614	0.0018	0.832	-7.03	0.8903
4	姜黄素	多酚	0.8898	0.0050	0.718	-6.94	0.8821
5	柚皮素	黄烷酮	0.9413	0.0021	0.815	-6.54	0.8811
6	木犀草素	黄酮	0.9783	0.0008	0.887	-6.43	0.8704
7	水飞蓟宾	黄酮木脂素	0.9666	0.0011	0.869	-6.39	0.8497
8	松脂素（新）	呋喃木脂素	0.8814	0.0068	0.670	-6.64	0.8397
9	槲皮素	黄酮醇	0.9718	0.0031	0.776	-6.37	0.8198
10	落叶松脂素（新）	开环木脂素	0.7912	0.0097	0.606	-6.89	0.8181

表 6-2 协同评分Top-10（单位：对接为kcal/mol）




图 6-3 Top-15候选总评条形图




图 6-4 模型分与对接分一致性（叉号=域外）

6.3 药效团归纳

药效团要素	命中	对应机制
多酚羟基特征（每分子至少2个酚羟基）	10/10（6/10含间/邻二酚）	抗氧化；Keap1口袋氢键网络
双芳香环体系	10/10	FXR疏水口袋 π 堆积
C6-C3-C6或木脂素二聚骨架	9/10（姜黄素例外）	刚性疏水核心+极性锚点
三萜酸C-28羧基+3 β -OH	独立支线	FXR胆酸口袋等排（奥贝胆酸路径）

表 6-3 Top-10药效团要素（详见 literature/03）

7 质量保证与复核机制

三条证据链支撑结果可信度：（1）确定性——全流程随机种子固定，连续两次运行的14个结果文件md5完全一致；（2）独立可复算——verify.py不导入项目代码，从CSV独立重算45项被引用数字全部一致（含AUC 0.967、 ρ 0.718、Top-10全部单元格）；（3）诚实性分级——演示对接分、教学版SMILES、整理稿文献均已显式标注，列入下学期复核任务。

事项	状态	复核方式
模型指标/不确定性/适用域/评分	本地真实计算	run_all.py 复现 + verify.py 45项核验
对接评分	演示模式占位	WP2 服务器Vina复算覆盖
种子集SMILES	教学复现版（三萜有简化）	WP3 数据库正式导出替换
文献引用	调研整理稿	WP5 逐条核对原文附PMID

表 7-1 结果诚实性分级（复核责任已排入工作包）

8 交付物与文件地图

目录	内容	负责人	核验入口
data/	原始/清洗/划分数据（8个CSV）	王散曼/衣思淼	VERIFY_MANUAL § 3.4
src/	五人模块代码（13个py）	五人各自	VERIFY_MANUAL § 3.1-3.3
results/	指标/预测/对接/AD/排名/图	各自模块	verify.py
docs/	数据字典/模型/对接说明+纪要+规划/清单/手册	王启龙汇编	MANIFEST.md
literature/	证据库/新分子调研/机制溯源	王散曼	lit/01逐条溯源
reports/	中期报告+详解PDF+本报告	王启龙	抽查数字与CSV一致
phase2_semester/	下学期五个工作包	各自主责	WP内验收标准

表 8-1 交付物地图（逐文件核验方法见 docs/MANIFEST.md）

9 下学期工作衔接

工作包	内容	周次	主责	核验人
WP1	复现核验与基线固化（v1.0标签）	1-2	王启龙	全员
WP2	真实分子对接（Vina替换演示分）	3-6	代维斯丹	宁显洳
WP3	数据扩充与正式库导出（≥1000条）	3-8	衣思淼	王散曼
WP4	模型升级与校准（PyG/温度校准ECE小于0.10）	7-10	宁显洳	衣思淼
WP5	文献深化与实验衔接（松脂素/落叶松脂素优先）	9-16	王散曼	代维斯丹

表 9-1 第二阶段工作包（详见 phase2_semester/）

执行原则：每个工作包完成后由核验人按包内验收标准逐条打勾签字；WP1是全员入口——先证明暑假结果可复现再动新东西；新文件必须在 MANIFEST.md 登记后才算交付。

附录 人工核验十分钟路径

```
cd hepato-gnn-screening && python run_all.py
python reports/pdf_build/verify.py
```

前者约6秒跑完全流程，控制台关键数字见 docs/VERIFY_MANUAL.md § 2.1（逐字对照）；后者输出"通过45项；不符0项"。两步通过即完成暑假结果的机器核验，人工逐模块核验按手册 § 3执行（约40分钟）。

第一阶段完 · 交接下学期