

暑期课题中期材料 · 详解与阶段结果说明

保肝中药成分 虚拟筛选课题

本文档详解课题“数据—算法—验证”三线架构：以88条带标签成分训练图神经网络并结合MC Dropout不确定性估计，融合对接评分与适用域预警，产出60个候选协同排名。

团队成员 王启龙 · 宁显泷 · 衣思淼 · 代维斯丹 · 王散曼

文档版本 中期考核版 v1.0

完成日期 2026年8月

目 录

1 项目概述	3
1.1 背景与目标	3
1.2 技术路线	3
1.3 交付物清单	3
2 团队分工与协作机制	4
2.1 六周三段式分工	4
2.2 协作与版本管理	4
3 数据体系详解	4
3.1 数据集构成	4
3.2 标签口径与证据分级	5
3.3 清洗管线	5
3.4 二维描述符口径	5
3.5 适用域（AD）判定	6
4 模型方法详解	6
4.1 分子图表征	6
4.2 网络结构	6
4.3 MC Dropout 不确定性估计	6
4.4 损失权重实验	7
4.5 传统机器学习基准线	7
4.6 分子对接（本地演示模式）	7
4.7 协同评分融合	7
5 阶段结果详解	7
5.1 模型对比	7
5.2 不确定性与校准	8
5.3 适用域的方法论发现	9
5.4 最终排名（60候选，节选Top-10）	9
5.5 药效团归纳（Top-10共性）	11
6 复现指南	11
6.1 环境要求	11

6.2 一键运行	11
7 复核清单与下一阶段	12
7.1 结果诚实性分级	12
7.2 下一阶段计划	12

1 项目概述

1.1 背景与目标

中药及其天然产物是保肝药物发现的重要分子来源，但传统"单一成分逐一实验"的筛选模式成本高、周期长。本课题构建一条"计算优先"的虚拟筛选流水线：把中药成分转化为分子图，用图神经网络（GNN）预测保肝活性，并用蒙特卡洛Dropout（MC Dropout）量化每次预测的不确定性；同时以分子对接提供物理维度的交叉验证，最终把两类证据融合成协同评分排名，供后续湿实验按优先级验证。

暑期阶段的定位是"中期"：完成本地小样本全流程跑通与阶段结果产出，服务器上量与真实对接留待下一阶段。全部计算结果由固定随机种子驱动，一键复现（本地全流程约 6 秒）。

6.2 秒 本地全流程复现耗时	60 个 候选分子最终排名	AUC 0.96 GNN 测试集判别力	$\rho = 0.718$ 不确定性与误差相关性
---------------------------------------	-------------------------------------	---	--

1.2 技术路线

技术路线按"数据—算法—验证—融合"四段组织，各段职责与产物如下表。

阶段	核心动作	产物
数据	SMILES解析校验、规范化去重、Murcko骨架签名、骨架级划分、二维描述符计算	清洗集88条 + 筛选池12条 + 描述符表
算法	分子图节点特征构建、2层GCN训练、MC Dropout推理、加权BCE损失权重选择	预测均值 + 方差（test与全候选池）
验证	描述符+朴素贝叶斯、指纹+逻辑回归双基准线；FXR与Keap1双靶点对接评分（演示模式）	基准线指标表 + 对接分表
融合	方差转置信度、与对接名次分、类药性分加权融合；适用域域外降权	60候选协同评分排名总表 + 4张结果图

表 1-1 技术路线四阶段与产物

1.3 交付物清单

类别	文件/位置	说明
排名总表	results/rankings/final_ranking.csv	60候选，含模型分/方差/置信/对接/域外标记
模型预测	results/predictions/fullpool_predictions.csv	全候选池均值+方差；test_predictions.csv 为测试集
指标	results/metrics/baseline.csv、reliability_curve.csv	基准线与GNN指标、可靠性曲线数据

类别	文件/位置	说明
结果图	results/figures/*.png	可靠性图、不确定性-误差、Top-15条形图、模型-对接散点
文档	docs/、literature/、reports/midterm_report.md	数据字典、环境、模型与对接说明、文献库、中期报告
代码	src/ + run_all.py	全部模块一键运行入口

表 1-2 阶段交付物一览

2 团队分工与协作机制

2.1 六周三段式分工

成员	前两周（环境与数据）	中间两周（全量与出分）	最后两周（收敛与闭环）
王启龙	git仓库、零依赖环境方案、首批数据跑通	数据过滤与适用域预警代码、批量对接脚本	排名自动化脚本、结果图、中期材料归档
宁显洧	SMILES转分子图解析器、GNN结构定型	图数据集构建、MC Dropout推理、损失权重选择	模型冻结后全候选池批量推理
衣思淼	数据库调研、清洗接口设计、测试数据交付	全量去重与骨架统一、描述符、适用域边界	方差转置信度、协同评分矩阵、排名总表
代维斯丹	对接引擎与可视化工具配置	双基准线训练、受体网格盒子参数、批量对接	高精度复核（演示模式）、可靠性评估
王散曼	经典保肝成分候选池（48+40）与证据标注	萜类/木脂素新分子池（12条）与成药性记录	Top候选文献溯源、药效团归纳

表 2-1 成员×阶段分工矩阵

2.2 协作与版本管理

仓库按模块归属做作者署名提交，git 历史共 8 次提交、5 位作者，与分工矩阵一一对应；联合任务（适用域、评分融合、出图）以"主责+协作"双作者记录。三次组会纪要（docs/minutes/）记录了各节点验收结论与关键决议，包括不确定性方案二选一（MC Dropout 对比模型集成）、损失权重选择规则、阳性参照药排名偏低的原因分析等。

3 数据体系详解

3.1 数据集构成

子集	编号前缀	数量	用途
保肝活性分子	HP	48	正样本，覆盖黄酮/三萜/木脂素/蒽醌/环烯醚萜苷/生物碱/香豆素等类别
负参照	DC	40	惰性小分子 + 无保肝证据西药 + 经典肝毒性药物（难负样本）
新分子筛选池	NV	12	结构较新颖的萜类/木脂素 + 奥贝胆酸作方法学阳性参照
合计	HP/DC/NV	100	原始输入，清洗后88条带标签 + 12条无标签筛选池

表 3-1 数据集构成

负样本刻意引入对乙酰氨基酚、异烟肼、丙戊酸、氯霉素、甲氨蝶呤等经典肝毒性药物，构成“难负样本”：迫使模型学习“结构是否保肝”的本质规律，而不是简单区分“天然产物与合成药物”的表面特征。

3.2 标签口径与证据分级

标签定义为“是否存在保肝活性的公开证据”（二分类），而非活性强度。证据分级：A 级代表临床研究/系统评价或已上市保肝制剂的主要成分（如水飞蓟宾、甘草酸、姜黄素）；B 级代表至少两类肝损伤动物模型支持；C 级代表单次动物或细胞实验支持。每条正样本附一句话证据摘要，便于溯源。

3.3 清洗管线

步骤	规则	结果
解析校验	自研SMILES解析器逐条建图，失败即剔除并留痕 rejected.csv	首版曾剔除22条五环三萜（环号未闭合），修正后重新入库
规范化去重	DFS重编号规范串作为键，重复结构只保留首条	当前0条重复
骨架签名	迭代剪除度小于等于1的原子，剩余子图即Murcko骨架（近似）	53个骨架组，含1个无环组（糖类负参照）
描述符计算	7维二维描述符（见3.5节）	追加至清洗表
骨架级划分	以骨架组为单位贪心装入test(约20%)/val(约15%)/train(其余)	train 58 (正28) / val 13 (正8) / test 17 (正12)

表 3-2 清洗管线五步

骨架级划分的意义：同一骨架的分子绝不跨集合，防止“训练集见过芹菜素、测试集考木犀草素”式的骨架泄漏，让测试指标反映真实的结构外推能力。

3.4 二维描述符口径

描述符	计算口径	备注
MW	原子量加和（含隐式氢）	三萜简化骨架系统性偏高约5%~10%

描述符	计算口径	备注
logP_est	原子贡献法（截距-0.55，芳香修正+0.12/体系，MW大于650渗透罚-0.5）	演示级，服务器端换Crippen
TPSA_est	N/O原子贡献近似（O约20.2，N约12.5，极性氢+1.5）	演示级
nHBD / nHBA	带氢O/N计数 / 中性O+N计数	Lipinski口径
nRot	非环重原子单键且两端度大于1	
nAromSystems	芳香原子子图连通分量数（稠环计为1）	

表 3-3 7维描述符定义

3.5 适用域 (AD) 判定

以训练集7维标准化描述符计算杠杆值 $h_i = x_i^T (X^T X)^{-1} x_i$ ，阈值取 $h^* = 3p/n = 3 \times 7/58 = 0.362$ 。超过阈值的分子在最终排名中打"域外"标记并乘以0.9预警降权。

筛选池12个新分子中7个（以三萜酸类为主）被正确标记域外——训练集三萜样本少、结构新颖度高的分子自动降权，机制符合设计预期。

4 模型方法详解

4.1 分子图表征

SMILES 经自研解析器转为"原子为节点、键为边"的分子图（纯Python实现，无RDKit依赖）。节点特征13维：元素one-hot（C/N/O/S/P/F/Cl/Br/I/B共10维）+ 芳香标记 + 归一化度数 + 归一化氢数。邻接矩阵加入自环后做对称归一化 $D^{-1/2}(A+I)D^{-1/2}$ ，稳定消息传递的数值尺度。

4.2 网络结构

$$H^{(1)} = \tanh(D^{-1/2}(A+I)D^{-1/2} \cdot X \cdot W_1 + b_1)$$

第一层输出经同样的消息传递进入第二层同构GCN（隐层为32维与16维）。两层消息传递结束后对节点向量做均值池化以得到图级表征。池化向量经Dropout (0.3) 随机失活后送入线性输出层并取sigmoid得到保肝概率。优化器采用Adam：学习率0.01、权重衰减系数 1×10^{-4} 、全批量训练300轮。

4.3 MC Dropout 不确定性估计

推理时不关闭Dropout，前向 $T=30$ 次，得到一组预测概率 $\{p_1, \dots, p_T\}$ 。取均值 pred_mean 作为最终预测，取方差 pred_var 作为认知不确定性的近似：方差大意味着"网络对这类结构没把握"，而不是简单的置信度低。方案在组会上与"5模型集成"二选一：小样本下两者不确定性质量接近，MC Dropout零额外训练成本，故选用之。

4.4 损失权重实验

正类权重 w_{pos} 在 {1.0, 1.25, 1.5} 中按验证集F1选优，同分时取更保守的小权重：

w_{pos}	1.0	1.25 (选用)	1.5
验证集F1	0.625	0.667	0.667

表 4-1 加权BCE正类权重选择

4.5 传统机器学习基准线

为GNN提供可比基准的两条传统线：(1) 7维描述符 + 高斯朴素贝叶斯；(2) 2048bit哈希环形指纹（Morgan型，MD5哈希保证跨平台确定性）+ L2正则逻辑回归。基准线在GNN之前出分，保证最终能并表对比。

4.6 分子对接（本地演示模式）

靶点	PDB	口袋类型	盒子中心(Å)	盒子尺寸(Å)	参考配体
FXR-LBD	10SH	疏水型	15.2, 3.8, 24.5	22×22×24	fexaramine
Keap1-Kelch	2FLU	极性/碱性	-11.5, 20.4, -6.2	20×20×20	Nrf2 ETGE肽

表 4-2 双靶点与网格盒子参数

本地演示机未部署AutoDock Vina，对接分由物理启发打分函数替代：按口袋类型对描述符做加权线性组合（FXR偏好高logP与芳香体系，Keap1偏好氢键供受体），加MW大于550的渗透罚与按"分子+靶点"哈希种子的固定噪声（ $\sigma=0.35$ ），标定到 kcal/mol 量级。自检区分度：FXR上活性分子均分 -5.46 对 负参照-5.05 kcal/mol。该分数仅用于排序流程验证，服务器端运行 run_vina.sh 复算后直接覆盖同名列，下游无需改动。

4.7 协同评分融合

$final = 0.45 \times model_term + 0.35 \times dock_term + 0.20 \times dl_term$ ，其中： $model_term = pred_mean \times (0.5 + 0.5 \times confidence)$ ， $confidence = 1 - \min(1, \sqrt{var} / 0.25)$ ； $dock_term = 1 - rank_pct$ （两靶点对接分均值的名次百分位，结合越强分越高）； $dl_term = 1 - 0.25 \times Lipinski$ 违规数；适用域外分子再乘0.9预警降权。

5 阶段结果详解

5.1 模型对比

模型	AUC	ACC	BACC	F1
高斯朴素贝叶斯（描述符）	0.850	0.706	0.733	0.762
逻辑回归（2048bit指纹）	0.967	0.706	0.792	0.737
GNN + MC Dropout（本课题）	0.967	0.824	0.875	0.857

表 5-1 测试集指标对比（n=17，正12）

GNN与指纹逻辑回归的AUC持平，但平衡准确率与F1明显更优（0.875/0.857 对 0.792/0.737）：小样本下图结构表征学到的分类边界更稳。朴素贝叶斯受描述符维度过低限制，作为“下界”参照。




图 5-1 模型预测分与对接分的一致性散点（叉号=适用域外分子）

5.2 不确定性与校准

不确定性质量：预测方差与绝对误差的Spearman相关 $\rho = 0.718$ ，说明方差确实在“给错得离谱的预测打高分”，置信度加权有据可依。校准偏差：ECE（10桶）= 0.210，模型整体偏“过自信”——预测概率系统性靠近0或1，但实际错误率高于其自报置信。这是如实呈现的中期发现，已列入下一阶段温度校准任务（目标ECE小于0.10）。




图 5-2 可靠性图：预测概率分桶与实际正确率（虚线为完美校准）




图 5-3 MC Dropout方差与预测误差的关系（正相关即不确定性有效）

5.3 适用域的方法论发现

阳性参照药奥贝胆酸（FXR激动剂，临床用药）模型分仅0.26且被判域外——训练集是中药成分化学空间，甾体骨架不在其中。结论：模型分只在中药化学空间内可解释；跨空间筛选必须依赖对接分与适用域标记，这正是三源融合评分的价值所在。

5.4 最终排名（60候选，节选Top-10）

排名	候选	类别	模型分	方差	置信	对接(kcal/mol)	域外	总评
1	黄芩苷	黄酮苷	0.9612	0.0012	0.863	-6.86	否	0.9291
2	二氢杨梅素	黄酮醇	0.9653	0.0017	0.837	-7.14	否	0.8990
3	葛根素	异黄酮苷	0.9614	0.0018	0.832	-7.03	否	0.8903
4	姜黄素	多酚	0.8898	0.0050	0.718	-6.94	否	0.8821
5	柚皮素	黄烷酮	0.9413	0.0021	0.815	-6.54	否	0.8811
6	木犀草素	黄酮	0.9783	0.0008	0.887	-6.43	否	0.8704
7	水飞蓟宾	黄酮木脂素	0.9666	0.0011	0.869	-6.39	否	0.8497
8	松脂素（新）	呋喃木脂素	0.8814	0.0068	0.670	-6.64	否	0.8397
9	槲皮素	黄酮醇	0.9718	0.0031	0.776	-6.37	否	0.8198
10	落叶松脂素（新）	开环木脂素	0.7912	0.0097	0.606	-6.89	否	0.8181

表 5-2 协同评分Top-10（完整60条见 results/rankings/final_ranking.csv）




图 5-4 Top-15候选总评条形图

排名体系的事后合理性佐证：临床金标准保肝药水飞蓟宾落在第7位；木犀草素在Top-10中拿到最高模型分与最低方差（0.978/0.0008）。新分子方面，松脂素（第8）与落叶松脂素（第10）进入Top-10，置信度与域内状态合理——木脂素支线在训练集中有五味子、厚朴、牛蒡子等来源，模型对该骨架的外推可信。三萜酸类新分子（积雪草酸、科罗索酸、马斯里酸等）模型置信度普遍偏低且多为域外，符合训练集三萜样本稀少的预期。另需说明：全场最高模型分与最低方差并不出现在Top-10内——大黄素模型分0.993、苦参碱MC方差约 1.2×10^{-5} ，但二者的对接分与类药性拉低了总评，这恰好印证了三源融合而非单看模型分的必要性。

5.5 药效团归纳 (Top-10共性)

药效团要素	命中	对应机制
多酚羟基特征（每分子至少2个酚羟基）	10/10（6/10含间/邻二酚）	抗氧化清除自由基；Keap1口袋氢键网络
双芳香环体系（黄酮/木脂素核心）	10/10	FXR疏水口袋 π 堆积（fexaramine等排替代）
C6-C3-C6或木脂素二聚骨架	9/10（姜黄素例外）	连接区提供刚性疏水核心，末端酚羟基作极性锚点
三萜酸C-28羧基+3 β -OH	独立支线	FXR胆酸口袋等排（奥贝胆酸成药化路径）

表 5-3 Top-10药效团要素归纳

6 复现指南

6.1 环境要求

本地零依赖策略：只需 Python 3.9+ 与 numpy（matplotlib可选，仅出图用）。SMILES解析、描述符、指纹、GNN全部为纯numpy实现，任何成员的笔记本都可跑通；服务器端迁移清单见 docs/00_environment.md（RDKit/PyTorch/Vina）。

6.2 一键运行

```
cd hepato-gnn-screening && python run_all.py
```

阶段	控制台输出要点	耗时
1 数据清洗	带标签集88条（正48/负40）；筛选池12条；剔除0条	小于1秒
2 骨架划分	train 58 / val 13 / test 17；骨架组53个	小于1秒
3 基准线	NB与LR的AUC/ACC/BACC/F1	约1秒
4 GNN+MC Dropout	w_pos选择过程与测试集指标、 ρ 值	约4秒
5 对接演示	双靶点盒子参数与区分度自检	小于1秒
6 适用域	h*阈值与域外分子计数	小于1秒
7 评分融合	60候选入库与Top-10打印	小于1秒
8 结果图	4张PNG输出	约1秒

表 6-1 run_all.py 八个阶段

全部随机过程固定种子（训练seed=7/42、划分seed=42、对接噪声按分子ID哈希），重跑结果完全一致；CSV统一UTF-8编码，读取用 utf-8-sig。

7 复核清单与下一阶段

7.1 结果诚实性分级

事项	状态	复核方式
模型指标（AUC/F1/ECE等）	本地真实计算	python run_all.py 可复现
不确定性/适用域/协同评分	本地真实计算	同上
对接评分	演示模式（物理启发占位）	服务器 run_vina.sh 复算覆盖
种子集SMILES	教学复现版（三帖/苷类有简化）	TCMSP/PubChem导出替换
文献引用	调研整理稿	逐条核对原文后引用

表 7-1 复核清单

7.2 下一阶段计划

- 服务器迁移：RDKit/PyG版模型 + Vina真实对接，覆盖演示分；
- 数据扩充：数据库正式导出，目标不少于1000条带标签分子，收敛测试集置信区间；
- 校准修复：温度系数法把ECE从0.210压到0.10以下；
- 实验衔接：松脂素、落叶松脂素（Top-10新分子）优先推进体外验证与深度文献挖掘；
- 证据升级：把A/B/C证据分级折算为序数标签，从分类走向活性强度回归。

全文完